

# Hochschule Darmstadt

– Fachbereich Informatik und Mathematik –

## Kommunikation von Bundestagsabgeordneten

*Sprache im Parlament und in den sozialen Medien  
vor und während der Corona Pandemie*

Abschlussarbeit zur Erlangung des akademischen Grades

Master of Science (M.Sc.).

vorgelegt von

**Lisa Stolz**

Referent : Prof. Dr. Arnim Malcherek

Korreferent : Prof. Dr. Michael von Rüden

## EHRENWÖRTLICHE ERKLÄRUNG

---

Ich versichere hiermit, dass ich die vorliegende Arbeit selbständig verfasst und keine anderen als die im Literaturverzeichnis angegebenen Quellen benutzt habe.

Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder noch nicht veröffentlichten Quellen entnommen sind, sind als solche kenntlich gemacht.

Die Zeichnungen oder Abbildungen in dieser Arbeit sind von mir selbst erstellt worden oder mit einem entsprechenden Quellennachweis versehen.

Diese Arbeit ist in gleicher oder ähnlicher Form noch bei keiner anderen Prüfungsbehörde eingereicht worden.

*Darmstadt, 30. September 2020*

---

Lisa Stolz

## ZUSAMMENFASSUNG

---

Das Thema "Kommunikation von Bundestagsabgeordneten" ist in den letzten Jahren in den Fokus gerückt. Zum einen weil mit dem Einzug einer rechten Partei in den Bundestag zu befürchten ist, dass die "Verschiebung des Sagbaren" nicht mehr nur indirekt wirkt, sondern direkt im Plenum stattfindet. Zum anderen äußert sich heutzutage die große Mehrheit der Abgeordneten auf Twitter, wo zwischen freundlichen Grüßen und aggressiven Beleidigungen ein breites Spektrum an Inhalten zu finden ist.

In dieser Arbeit soll überprüft werden, ob rechte Abgeordnete auf Twitter tatsächlich aggressiver auftreten als andere Politiker\*innen. Dem gegenüber steht die Frage, welche Unterschiede in der Kommunikation sich im Plenum nachweisen lassen. Dabei werden besonders aufgeladene Themenkomplexe wie Migration oder Linksextremismus genauer betrachtet, um mögliche Muster zu erkennen. Schließlich wird der Frage, wie Corona sich auf die Kommunikation auf Twitter und im Plenum ausgewirkt hat, nachgegangen. Dieses extreme Ereignis hatte im März und April zu einer großen Verunsicherung geführt, und es soll geklärt werden, in wie weit Politiker\*innen möglicherweise zurückhaltender in ihrer Kommunikation geworden sind.

Zur Untersuchung der Fragestellungen wird zunächst eine Sentiment Analyse auf Basis von Twitter Daten und Plenarprotokollen des Bundestages durchgeführt. Die drei verwendeten Ansätze der Sentiment Analyse und die Datengrundlage sind in Kapitel zwei beschrieben. Anschließend wurde in Kapitel drei die Datenbeschaffung dargestellt und die zusammengestellten Datensätze beschrieben. In Kapitel vier ist zunächst erklärt, wie die drei Ansätze der Sentiment Analyse implementiert wurden, und schließlich werden die Ergebnisse des erfolgreichsten Ansatzes detailliert beschrieben. Im Laufe der Arbeit stellte sich heraus, dass der Ansatz auf Basis von Word Embeddings und maschinellem Lernen den einfachen wissensbasierten Sentiment Analysen überlegen war.

Es konnte gezeigt werden, dass die AfD sowohl auf Twitter als auch im Plenum, aggressiver kommuniziert als andere Parteien. Dabei konnten - neben den bereits erwarteten - weitere, besonders aufgeladene Themencluster identifiziert werden, wie die Ministerpräsidentenwahl in Thüringen und der Öffentlich-rechtliche Rundfunk.

Die Vermutung, dass Corona zu weniger offensivem Auftreten geführt hat, konnte teilweise nachgewiesen werden. Auf Twitter wurde der Anteil aggressiver Tweets aller Parteien im Lockdown geringer. Im Plenum konnte dieser Effekt nur für die AfD nachgewiesen werden.

# INHALTSVERZEICHNIS

---

<b>I THESIS</b>	
<b>1 EINLEITUNG</b>	<b>2</b>
<b>2 GRUNDLAGEN UND VERWANDTE ARBEITEN</b>	<b>3</b>
<b>2.1 Datengrundlage . . . . .</b>	<b>3</b>
<b>2.1.1 Analyse politischer Tweets . . . . .</b>	<b>3</b>
<b>2.1.2 Auswertung von Plenarprotokollen . . . . .</b>	<b>7</b>
<b>2.2 Sentiment Analyse . . . . .</b>	<b>8</b>
<b>2.2.1 Wissensbasiert . . . . .</b>	<b>9</b>
<b>2.2.2 Maschinelles Lernen . . . . .</b>	<b>13</b>
<b>3 DATENSATZ UND EXPLORATIVE DATENANALYSE</b>	<b>16</b>
<b>3.1 Twitter API und MongoDB . . . . .</b>	<b>16</b>
<b>3.1.1 Crawlen der Abgeordneten mit Twitter Account . . . . .</b>	<b>16</b>
<b>3.1.2 Laden der Timeline Daten und speichern in MongoDB . . . . .</b>	<b>17</b>
<b>3.1.3 Pflege des Datensatzes in MongoDB . . . . .</b>	<b>19</b>
<b>3.2 Plenarprotokolle . . . . .</b>	<b>19</b>
<b>3.2.1 Herunterladen aller Protokolle einer Legislaturperiode . . . . .</b>	<b>19</b>
<b>3.2.2 Auslesen von XML Dokumenten . . . . .</b>	<b>20</b>
<b>3.3 Explorative Datenanalyse der Tweets . . . . .</b>	<b>22</b>
<b>3.4 Verhalten im Parlament . . . . .</b>	<b>26</b>
<b>4 SENTIMENT ANALYSE</b>	<b>30</b>
<b>4.1 Trainieren und Labeln der Datensätze . . . . .</b>	<b>30</b>
<b>4.1.1 Einfache Textverarbeitung mit TextBlob . . . . .</b>	<b>30</b>
<b>4.1.2 Lexika für sieben Basis Emotionen . . . . .</b>	<b>31</b>
<b>4.1.3 Feature Extraction und Prediction . . . . .</b>	<b>33</b>
<b>4.1.4 Vergleich der Methoden anhand von Ergebnisübersichten</b>	<b>36</b>
<b>4.2 Ergebnisse der Sentiment Analyse . . . . .</b>	<b>42</b>
<b>4.2.1 Vorstellung der Hypothesen und der statistischen Tests</b>	<b>42</b>
<b>4.2.2 Twitter Sentiments . . . . .</b>	<b>45</b>
<b>4.2.3 Corona Pandemie . . . . .</b>	<b>59</b>
<b>4.2.4 Plenum Sentiments . . . . .</b>	<b>63</b>
<b>5 FAZIT UND AUSBLICK</b>	<b>68</b>
<b>II APPENDIX</b>	
<b>A WEITERE CODE LISTINGS</b>	<b>72</b>
<b>B ZUSÄTZLICHE GRAFIKEN</b>	<b>74</b>
<b>B.1 Nachstellen der SZ Studie . . . . .</b>	<b>74</b>
<b>B.2 Sentiment Analyse Ergebnisse . . . . .</b>	<b>77</b>
<b>B.3 Wordclouds . . . . .</b>	<b>80</b>
<b>B.4 Hypothesentests . . . . .</b>	<b>86</b>
Literatur	89

## ABBILDUNGSVERZEICHNIS

---

Abbildung 2.1	Screenshot des Pollytix MdB-Twitter Netzwerk am 10.06.2020	4
Abbildung 2.2	Netzwerkdarstellung der 25 am häufigsten geteilten Domains[67]	5
Abbildung 2.3	Eigene Grafik zu Zwischenrufen in den ersten sechs Monaten	7
Abbildung 2.4	SZ Darstellung vom Beifall für die Fraktion im Verhältnis zum Beifall für andere[31]	8
Abbildung 2.5	SZ Übersicht über verschiedene Aktivitäten im Bundestag und wie häufig sie eingesetzt werden[31]	8
Abbildung 2.6	Einordnung der Politiker in einer Polarität-Subjektivität-Grafik[16]	11
Abbildung 2.7	Polarität von @realDonaldTrump zu CNN und Fox News[16]	12
Abbildung 2.8	Angst in den Tweets der SPD im Vergleich zur AfD[53]	13
Abbildung 3.1	Grundsteine des Regulären Ausdrucks zur Kommentar-Analyse	20
Abbildung 3.2	Absolute Häufigkeiten von Tweets zwischen Jan 2017 und Juli 2020	23
Abbildung 3.3	Abgeordnete mit den meisten Tweets im Zeitraum 05.19 - 05.20	24
Abbildung 3.4	Wordclouds zur Europawahl - Zeitraum 20.-31.05.2019	25
Abbildung 3.5	Absolute und relative Darstellung von Beifall zwischen Fraktionen	26
Abbildung 3.6	Absolute und relative Darstellung von Lachen zwischen Fraktionen	27
Abbildung 3.7	Absolute und relative Darstellung von Lachen zwischen Fraktionen	28
Abbildung 3.8	Abgeordneten mit den meisten Zurufen	29
Abbildung 4.1	Emotionsmatrix aus Nullen und Einsen	32
Abbildung 4.2	Matrix aufsummierten Emotionswerten für jeden Tweet	32
Abbildung 4.3	Durch Tweetlänge relativierte Ergebnisse	33
Abbildung 4.4	Übersicht der mit TextBlob gelabelten Ergebnisse	38
Abbildung 4.5	Übersicht der mit Basic Emotions gelabelten Ergebnisse	40
Abbildung 4.6	Übersicht der mit GermEval-TUWien gelabelten Ergebnisse	41
Abbildung 4.7	Histogramme der relativen OFFENSE-Tweet Häufigkeit pro Woche	43
Abbildung 4.8	Übersicht der relativen Häufigkeit von OFFENSE-Tweets	46
Abbildung 4.9	Tweets zum Topic KemmerichThüringen	47
Abbildung 4.10	Tweets zum Topic Hanau	48
Abbildung 4.11	Hanau 19.02.2020 - Wordcloud 20.02.2020	49

Abbildung 4.12	Hanau 19.02.2020 - Wordcloud 21.02.2020 . . . . .	50
Abbildung 4.13	Tweets zum Topic Klima und Fridays for Future . . . . .	51
Abbildung 4.14	Tweets zum Topic Migration . . . . .	52
Abbildung 4.15	Tweets zu den Topics Links- und Rechtsextremismus .	54
Abbildung 4.16	Tweets zum Topic Öffentlich-Rechtliche . . . . .	56
Abbildung 4.17	Tweets zum Jahreswechsel 2019/2020 . . . . .	57
Abbildung 4.18	Tweets zum Zeitraum des Corona-Lockdowns . . . . .	59
Abbildung 4.19	Tweets zum Topic Corona . . . . .	60
Abbildung 4.20	Übersicht der absoluten OFFENSE und OTHER Werte im Plenum . . . . .	64
Abbildung 4.21	Ranking der TOPs mit den meisten OFFENSE-Zurufen	64
Abbildung B.1	Absolute/relative Darstellung von Zurufen . . . . .	74
Abbildung B.2	Absolute/relative Darstellung von Widerspruch . . . . .	74
Abbildung B.3	Absolute/relative Darstellung von Lachen im ersten halben Jahr . . . . .	74
Abbildung B.4	Häufigkeiten der Reaktionen im ersten halben Jahr . .	75
Abbildung B.5	Lachen als Mittel sich über das Gesagte lustig zu machen[31] . . . . .	75
Abbildung B.6	Abgeordneten mit den meisten Zurufen - eigene Darstellung . . . . .	76
Abbildung B.7	Abgeordneten mit den meisten Zurufen[31] . . . . .	76
Abbildung B.8	Absolute Häufigkeit von OFFENSE-Tweets . . . . .	77
Abbildung B.9	Zufällige Auswahl gelabelter Tweets von Union und AfD . . . . .	78
Abbildung B.10	Zufällige Auswahl gelabelter Tweets der Grünen und der Linken . . . . .	79
Abbildung B.11	Wordclouds der AfD Tweets nach Monaten unterteilt .	80
Abbildung B.12	Wordclouds der FDP Tweets nach Monaten unterteilt .	81
Abbildung B.13	Wordclouds der Grünen Tweets nach Monaten unterteilt	82
Abbildung B.14	Wordclouds der Linken Tweets nach Monaten unterteilt	83
Abbildung B.15	Wordclouds der Union Tweets nach Monaten unterteilt	84
Abbildung B.16	Wordclouds der SPD Tweets nach Monaten unterteilt .	85
Abbildung B.17	Histogramme der relativen OFFENSE-Zuruf Häufigkeit pro Woche . . . . .	86
Abbildung B.18	Histogramme der relativen OFFENSE-Tweet Häufigkeit pro Woche (24 Wochen) . . . . .	87
Abbildung B.19	Histogramme der relativen OFFENSE-Zuruf Häufigkeit pro Woche (24 Wochen) . . . . .	88

## TABELLENVERZEICHNIS

---

Tabelle 3.1	Mit ElementTree ausgelesene Daten aus XML Plenarprotokollen . . . . .	21
Tabelle 3.2	Abgeordnete im Bundestag und auf Twitter - Mai 2019 - Juli 2020 . . . . .	24
Tabelle 4.1	Ergebnisse einer Sentiment Analyse von Twitter Daten mit TextBlob . . . . .	31
Tabelle 4.2	Zusammenfassung der deutschen Wörterlisten[46] . . . . .	31
Tabelle 4.3	Evaluierung der Vorhersagen nach dem Vorgehen der TUWien . . . . .	36
Tabelle 4.4	Verteilungsparameter und Test auf Normalverteilung . . . . .	44
Tabelle 4.5	Wilcoxon-Mann-Whitney-Test der rel. OFFENSE-Tweet Häufigkeiten . . . . .	58
Tabelle 4.6	Wilcoxon-Rang-Test der rel. OFFENSE-Tweets in den neun Wochen vor und während dem Lockdown (LD) . . . . .	61
Tabelle 4.7	Wilcoxon-Rang-Test der rel. OFFENSE-Tweets in den neun Wochen nach und während dem Lockdown (LD) . . . . .	62
Tabelle 4.8	Wilcoxon-Rang-Test der rel. OFFENSE-Tweets in den 13 Wochen vor und nach dem Lockdown (LD) . . . . .	62
Tabelle 4.9	Mann-Whitney-U-Test der rel. OFFENSE-Zurufe zwischen AfD und jeder der anderen Parteien . . . . .	66
Tabelle 4.10	Mann-Whitney-U-Test der wöchentlichen relativen OFFENSE-Zurufe und OFFENSE-Tweets . . . . .	66
Tabelle 4.11	Wilcoxon-Rang-Test der relativen OFFENSE-Zurufe an 18 Sitzungstagen vor und während Corona . . . . .	67
Tabelle B.1	Verteilungsparameter und Test auf Normalverteilung - Plenum . . . . .	86
Tabelle B.2	Verteilung und Test auf Normalverteilung - Twitter (24 Wochen) . . . . .	87
Tabelle B.3	Verteilung und Test auf Normalverteilung - Plenum (24 Wochen) . . . . .	88

## LISTINGS

---

Listing 3.1	Twitter API - Verbindungsdaten aufsetzen . . . . .	17
Listing 3.2	Lokale MongoDB - Verbindungsdaten aufsetzen . . . . .	17
Listing 3.3	Laden von Tweets und speichern in MongoDB . . . . .	18
Listing A.1	Duplikate entfernen . . . . .	72
Listing A.2	Umformatieren des Felds created_at in datetime Format	72
Listing A.3	Entschachteln von Collection und Selektion von Feldern	72
Listing A.4	Feld 'user_party 'für jeden Tweet hinzufügen . . . . .	73
Listing A.5	Backup und übertragen . . . . .	73

## ACRONYME

---

- AfD Alternative für Deutschland
- API Application Programming Interface
- BLM Black Lives Matter
- CDU Christlich Demokratische Union
- CSU Christlich-Soziale Union
- FDP Freie Demokratische Partei
- GOP Grand Old Party
- JSON JavaScript Object Notation
- MdB Mitglied des Bundestags
- MDR Mitteldeutscher Rundfunk
- NRC National Research Council (Canada)
- OdeNet Open German WordNet
- ÖRR Öffentlich-rechtlicher Rundfunk
- POS Part-Of-Speech tagging
- PWN Princeton WordNet of English
- RBC Rank biserial correlation
- SPD Sozialdemokratische Partei Deutschlands
- SZ Süddeutsche Zeitung
- URL Uniform Resource Locator
- WDR Westdeutscher Rundfunk

Teil I  
THESIS

## EINLEITUNG

---

[...] Cumming District is a disgusting, rat and rodent infested mess.[...]

*@realDonaldTrump*

Den Wahlbezirk eines demokratischen Abgeordneten als widerliches, von Ratten und Nagern befallenes Chaos zu bezeichnen, war bloß einer von vielen abfälligen Tweets des Präsidenten der Vereinigten Staaten.<sup>[3][65]</sup> Er steht in krassem Gegensatz zu Politiker\*innen wie Angela Merkel, die keinen Twitter Account besitzt und bekannt ist für die Regierungsformel "Macht durch Bescheidenheit und Moderation". Gleichzeitig wird ihrer Politik der Erfolg der AfD zugeschrieben, die seit 2017 im deutschen Bundestag vertreten ist.<sup>[68]</sup>

Sieht man diese beiden Staatsoberhäupter als extreme Ausprägungen von sehr aggressiver Sprache auf der einen Seite, und zurückhaltend, moderierender Kommunikation auf der anderen Seite, so stellt sich die Frage, wie in der deutschen Politiklandschaft heute kommuniziert wird. Überwiegen Attacken und Beleidigungen wie man sie von Donald Trump kennt? Welche Parteien greifen vermehrt darauf zurück? Sind deutsche Politiker\*innen auf Twitter ungehemmter als im Bundestag, oder entlädt sich in den Debatten erst die volle Aggression? Ziel dieser Arbeit ist es, sich diesen Fragen durch die Analyse von Twitter Daten und Plenarprotokollen zu nähern. Dabei liegt der Fokus auf 15 Monaten zwischen Mai 2019 und Juli 2020, weshalb außerdem die Frage behandelt wird, in wieweit die Corona Pandemie eine Auswirkung auf die Sprache von deutschen Abgeordneten hatte.

Zunächst werden in Kapitel zwei die verwendeten Datenquellen und Methoden beschrieben. Anhand verwandter Arbeiten wird ein Einblick gegeben, welche Möglichkeiten sich heute bieten, Sprache mithilfe großer Datenmengen zu analysieren. In Kapitel drei wird erklärt, wie aus den beiden Datenquellen die verwendeten Datensätze erstellt wurden. Außerdem wird mit einer explorativen Datenanalyse ein erster Eindruck des Verhaltens von Bundestagsabgeordneten auf Twitter und im Parlament vermittelt. Schließlich wird in Kapitel vier die Sentiment Analyse beschrieben und die Ergebnisse ausführlich dargestellt. Am Ende werden im Fazit die zentralen Resultate der Arbeit noch einmal herausgestellt und ein Ausblick gegeben, welche weiteren Ansätze und Fragen sich hieraus ergeben.

## GRUNDLAGEN UND VERWANDTE ARBEITEN

Wenn man das Ziel hat, Kommunikation von Politiker\*innen zu analysieren, kommen viele Datenquellen und noch mehr Methoden in Frage. Für eine quantitative, automatische Analyse großer Datenmengen, bieten sich insbesondere existierende Schnittstellen und frei zugängliche Dokumente an. Diese Vorteile von Twitter Daten und Plenarprotokollen wurden bereits von anderen Autor\*innen ausgenutzt, und daher wird in diesem Kapitel auf bisherige Arbeiten und Analysen eingegangen. Daneben werden anhand von aktuellen Artikeln die beiden Kategorien von Sentiment Analyse erklärt, die in dieser Arbeit zur Anwendung kommen.

### 2.1 DATENGRUNDLAGE

#### 2.1.1 Analyse politischer Tweets

Twitter bietet verschiedene Möglichkeiten, um an Daten zu gelangen. So kann man Tweets mit bestimmten Stichworten herunterladen oder solche, die während eines konkreten Zeitraums abgesetzt wurden. Allerdings ist das Volumen der verfügbaren Tweets beschränkt, und nur mit einem entsprechend höherklassigem Paket<sup>1</sup> kann es ausgeweitet werden.

Ein alternativer Ansatz, der in dieser Arbeit verfolgt wurde, stellt der Download von Timelines dar. In diesem Fall können pro Twitter Nutzer\*in über 3200 Tweets heruntergeladen werden. Neben dem reinen Text liefert die API unter anderem Informationen zu Retweets, der Uhrzeit, der Location und der Nutzer\*in.

Neben diesen auf Tweets fokussierten Zugängen ist es mit einer weiteren API Anfrage<sup>2</sup> außerdem möglich, die Follower einer Nutzer\*in herunterzuladen. Auf dieser Basis können Netzwerke zwischen Abgeordneten, Fraktionen oder beispielsweise Informationsmedien hergeleitet werden. Die Beratungsagentur Pollytix bietet auf ihrer Plattform für die aktuelle Legislaturperiode eine interaktive Grafik<sup>3</sup>, welche die Vernetzung zwischen Abgeordneten über die Zeit hinweg darstellt.

Eine Analyse dieser Daten ergab, dass Bundestagsabgeordnete sich insbesondere in der eigenen Fraktion vernetzten und vor allem Spitzenpositionen zu Followern über Parteidgrenzen hinweg führten. Besonders auffällig ist die Abgrenzung der AfD. Nur wenige Parteimitglieder folgen anderen Abgeordneten wie Peter Altmaier (CDU), Christian Lindner (FDP) und Katrin

<sup>1</sup> Ein Upgrade von der Standard API bietet die Premium API oder die noch höherklassige Enterprise API. <https://developer.twitter.com/en/products/products-overview>

<sup>2</sup> <https://developer.twitter.com/en/docs/accounts-and-users/follow-search-get-users/api-reference/get-followers-list>

<sup>3</sup> MdB-Twitter-Netzwerk: <https://mdb.pollytix.de/>

Göring-Eckardt (Bündnis 90/Die Grünen).[51] Diese Politiker\*innen wurden in der Auswertung der Gruppe der "Sprachrohre" zugeteilt, was bedeutet, dass sie eine hohe Reichweite in andere Fraktionen haben, jedoch seltener anderen zurück folgen. Solche Sprachrohre existieren auf AfD Seite nicht, kaum eine Abgeordnete hat Follower aus anderen Fraktionen[51].

Verdeutlicht wird diese Abgrenzung zum Beispiel mit dem Account von Frank Pasemann in Abbildung 2.1. Er ist im Vergleich zu anderen Abgeordneten seiner Partei sehr zentral positioniert, da er verhältnismäßig vielen Abgeordneten folgt. Aus der Übersicht rechts unten im Bild geht jedoch hervor, dass kein anderer Abgeordneten außerhalb der AfD ihm folgt.

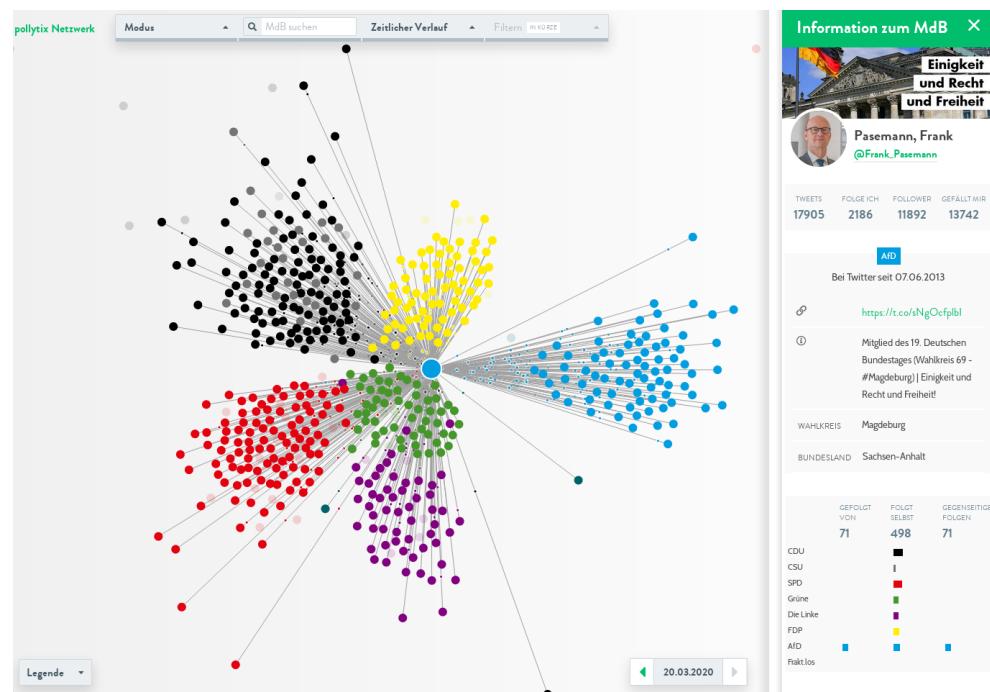


Abbildung 2.1: Screenshot des Pollytix MdB-Twitter Netzwerk am 10.06.2020

Eine weitere Auswertung auf Basis von Pollytix Daten geht auf die bevorzugten Informationsquellen von Abgeordneten ein. Zu diesem Zweck wurde beobachtet, welchen Medien-Accounts, Interessenvertretungen und Unternehmen die Abgeordneten auf Twitter folgen[45]. Dabei gibt es klare, teilweise erwartbare Unterschiede zwischen den Parteien. Eine linke Tageszeitung wie die Taz wird bevorzugt von Abgeordneten von Die Linke, dem Bündnis 90/Die Grünen und auch der SPD gefolgt. Kaum folgen diese Abgeordnete hingegen Medien des Axel Springer Verlags wie Bild und Welt, die wiederum bei der Union, der AfD und der FDP besonders häufig vorkamen. Trotz solcher klaren Unterschiede gibt es Dienste, die bei allen Parteien zu den meist-gefolgten Accounts gehören, dazu zählen die Tagesschau, Zeit Online und Spiegel Online.

Diese Ergebnisse weisen in eine ähnliche Richtung wie die Untersuchungen der Universität Hildesheim in ihrem Forschungsprojekt "Wahlkampf in (a)sozialen Netzwerken"[28]. Auf Basis von 2,9 Millionen Facebook Posts

wurde die These von Echokammern in der deutschen Online-Kommunikation untersucht. Der Begriff "Echokammern" beschreibt das aus den USA bekannte Phänomen, dass sich im Netz zunehmend homogene Gruppen bilden, in denen Kritik und Meinungspluralismus kaum noch zu finden sind. Dadurch tendieren die Mitglieder solcher Gruppen zu immer extremeren Positionen, und es kommt zu einer Polarisierung und Radikalisierung der Kommunikation im Internet.

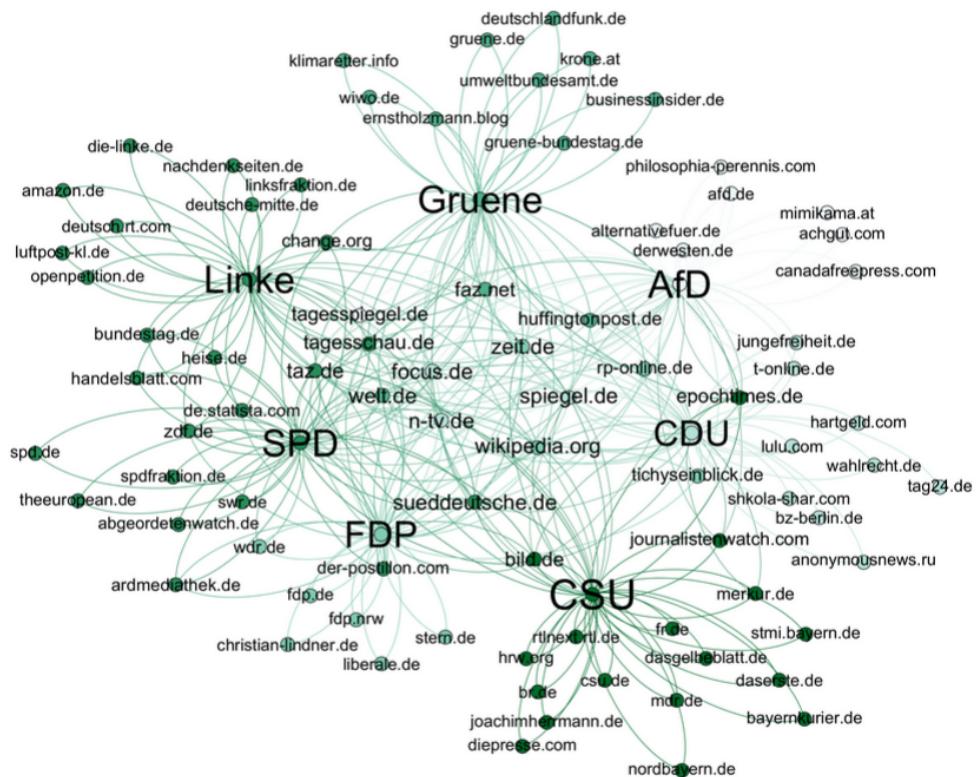


Abbildung 2.2: Netzwerkdarstellung der 25 am häufigsten geteilten Domains[67]

Die Untersuchung stellte fest, dass anders als in den USA die Gefahr von Echokammern in Deutschland relativ gering ist. Dies führten die Autoren unter anderem auf Mainstream-Medien zurück, die von allen Parteien gepostet und somit konsumiert werden[67].

Bei der Verbreitung journalistischer Medien lag 2017 die neurechte Zeitung „Junge Freiheit“ in der AfD an erster Stelle. Daneben werden vermeintlich „wahrhaftige Informationen“ über die offiziellen Twitterkonten der Partei sowie des Mitgliedermagazins „AfD Kompakt“ retweetet. Die Frage eines Rechercheteams des Tagesspiegel und Netzpolitik.org lautete, wie groß die Reichweite dieser Informationen tatsächlich ist, und wer diese retweetet. Dabei stießen sie auf rund ein Dutzend anonyme Unterstützungsaccounts deren größter sich „Balleryna“ nannte und zwischen April 2011 und 2017 gut 85.000 Tweets abgesetzt hatte. Die Inhalte waren meist AfD-Parteiwerbung, wobei nur drei Prozent der Follower Deutsch als Sprache angaben und inter-

essanterweise fast doppelt so viele Arabisch<sup>4</sup>. Diese Scheinriesen erzeugen ein Grundrauschen im Sinne der Partei, ohne dass sich die AfD offiziell dazu bekennt und treten dabei radikaler auf als die Partei selbst[20].

Im Zusammenhang mit der Europawahl 2019 wurde die Kommunikationsmethode der AfD auf Twitter noch einmal untersucht[49]. Dabei konnte nachgewiesen werden, dass neben anderen der größte Unterstützeraccount "Balleryna" von einem Mann aus Münster betrieben wurde, der für die Bundesgeschäftsstelle der AfD auf Honorarbasis tätig war.

Die Methode wurde in den folgenden Punkten zusammengefasst:

1. Anlegen zahlreicher Fake-Accounts mit beliebigen Namen.  
*Beispiel: Die Accounts rotesTshirt, blaueHose und grüneJacke werden erstellt.*
2. Hochzüchten dieser Accounts einerseits mit der Followback-Methode und andererseits durch das Betreiben der Accounts als Teil eines inoffiziellen rechten Unterstützer Netzwerkes. Durch die Aktivität folgen den Konten auch einige echte Accounts.  
*Beispiel: rotesTshirt und die anderen folgen möglichst vielen anderen Accounts, die dafür ebenfalls zurück-folgen. Dadurch baut sich mit der Zeit ein immer größeres Netzwerk auf.*
3. Weitergabe von hochgezüchteten Accounts unter anderem Namen, damit AfD-Vertreter oder AfD-nahe Kampagnen mit einem großen Followerstamm starten und von Anfang an größer aussehen.  
*Beispiel: Frauke Strolch braucht einen Twitter Account für ihre Kampagne und bekommt rotesTshirt, der jetzt Strolch2020 heißt. Es ist nicht ersichtlich, dass dieser Account mal anders hieß und alle Follower werden übernommen.*
4. Betreiben eines Netzwerkes künstlicher und koordinierter Relevanz-Zuweisung durch Retweets. Hierdurch wirkt die auf Twitter eher schwache Partei und ihre Vertreter stärker als sie tatsächlich sind.  
*Beispiel: Strolch2020 tweetet für ihre Kampagne und erreicht vom ersten Tag an eine hohe Reichweite auf Twitter. Die wenigen echten Menschen, die jetzt anfangen Frauke Strolch zu folgen, sehen, dass ihre Tweets tausendfach geteilt und geliked werden.*

Die bisher dargestellten Recherchen und Forschungsarbeiten bieten einen ersten Überblick über die Möglichkeiten der Auswertung von Tweets im politischen Umfeld. In dieser Arbeit wird der Fokus nicht auf den Netzwerken sondern auf den Emotionen und Inhalten liegen. Eine Quelle neben den sozialen Medien bietet hierfür der Bundestag selbst, daher wird im folgenden auf bisherige Arbeit mit Plenarprotokollen eingegangen. Am Ende des Kapitels wird schließlich erläutert, welche Möglichkeiten zur Auswertung die Sentiment Analyse bietet, und in wie weit diese bereits Anwendung bei politischen Tweets gefunden hat.

---

<sup>4</sup> Über die Hälfte hatten Englisch als Sprache angegeben, vor Spanisch, Portugiesisch und diversen anderen Sprachen.[50]

### 2.1.2 Auswertung von Plenarprotokollen

Im Vergleich zu Twitter Daten sind Plenarprotokolle kaum Gegenstand wissenschaftlicher Auswertungen, und noch seltener geschieht diese Auswertung automatisiert. Die Anregung für die Betrachtung in dieser Arbeit kam durch eine Reportage der Süddeutschen Zeitung, deren Autorinnen sich 2018 eingehend mit den bis dahin veröffentlichten Plenarprotokollen der aktuellen Legislaturperiode beschäftigten. Im Fokus stand das Verhalten der Fraktionen untereinander und insbesondere im Hinblick auf die AfD. Hierfür konzentrierten sie sich auf Kategorien wie Klatschen, Lachen und Reinrufen der Abgeordneten, da diese in den Plenarprotokollen explizit ausgewiesen sind. Die Beschreibung der Methoden ist teilweise sehr vage gehalten. Gerade über den ersten Teil - die Umwandlung von XML Dokumenten in Tabellen, erfährt man nur, dass Reguläre Ausdrücke verwendet wurden. Ob bestimmte Programme mit spezialisierten Paketen zum Einsatz kamen bleibt offen. Dafür wurden die fertigen Tabellen öffentlich zur Verfügung gestellt, zusammen mit dem verwendeten R-Code[11].

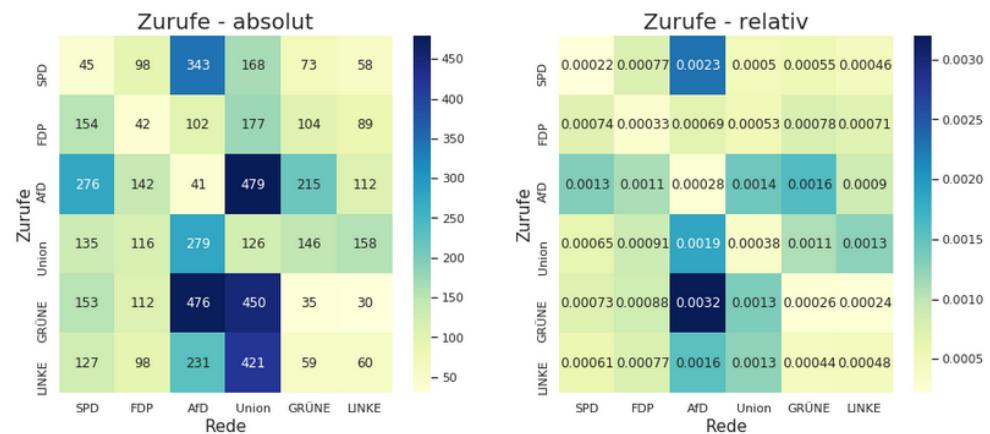


Abbildung 2.3: Eigene Grafik zu Zwischenrufen in den ersten sechs Monaten

Die Ergebnisse zeigen eine klare Abgrenzung der AfD durch die anderen Parteien. So wird nach der CDU bei Reden der AfD am häufigsten dazwischen gerufen und das bei weniger Redezeit. Gleichzeitig hat die Partei in ihren Reihen einige der Politiker, die selbst am meisten reinrufen. In Abbildung 2.3 wurde dieser Sachverhalt dargestellt. Im Artikel der SZ wird lediglich darauf hingewiesen, dass die AfD weniger Redezeit hat als beispielsweise die Union, allerdings wurden die Abbildungen nicht entsprechend relativiert. Dieser Umstand verzerrt die Grafiken nicht eklatant, jedoch sollte man ihn bei Grafik 2.4 und 2.5 im Hinterkopf haben. In Kapitel 3.4 wird im Detail auf die eigene Auswertung eingegangen.

Betrachtet man Klatschen als gängige Form der Zustimmung im Bundestag, so wird deutlich, dass die AfD so gut wie nie Beifall von anderen Fraktionen bekommt. Zwar ist es üblich, sich vor allem geschlossen selbst in der Fraktion zu beklatzen, jedoch spenden Teile auch regelmäßig Beifall für andere

Fraktionen wie aus Abbildung 2.4 hervorgeht.

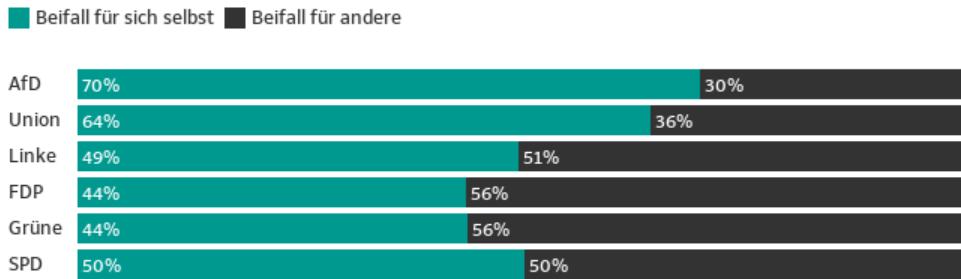


Abbildung 2.4: SZ Darstellung vom Beifall für die Fraktion im Verhältnis zum Beifall für andere[31]

Lachen wird vor allem als Form der Kritik eingesetzt, und hierbei wird deutlich, dass insbesondere Parteien aus dem linken Spektrum über die AfD lachen<sup>5</sup>. Am häufigsten tat dies die SPD mit 58 mal im betrachteten Zeitraum von einem Jahr. Die AfD dagegen setzte dieses Mittel vor allem gegenüber der CDU ein, was ebenfalls auf deren höhere Redezeit zurück gehe könnte.

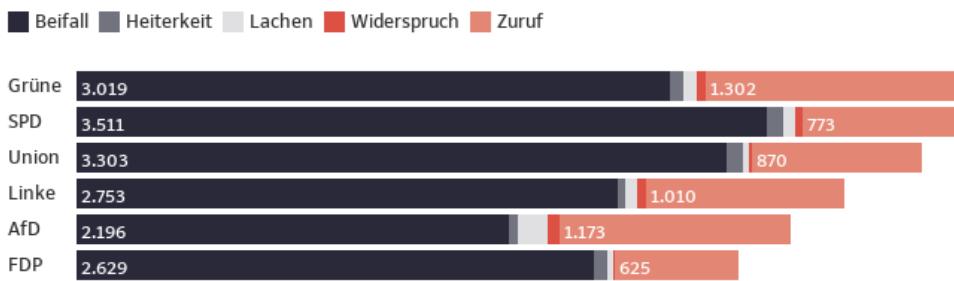


Abbildung 2.5: SZ Übersicht über verschiedene Aktivitäten im Bundestag und wie häufig sie eingesetzt werden[31]

Auffällig ist außerdem, dass die Grünen in Hinsicht auf die betrachteten Aktivitäten besonders aktiv im Bundestag sind (siehe Abbildung 2.5) und das, obwohl sie mit gerade einmal 67 Sitzen die kleinste Fraktion sind[31].

## 2.2 SENTIMENT ANALYSE

Das Forschungsgebiet der Sentiment Analyse hat in den letzten fünfzehn Jahren stark an Bedeutung gewonnen. Da ein Hauptaspekt in der Erkennung von Meinungen liegt, wurde die Sentiment Analyse ursprünglich auf Texte mit entsprechendem Schwerpunkt angewandt, wie zum Beispiel Reviews oder Zeitungsartikel. Seit fast zehn Jahren ist außerdem die Analyse von microblogging Texten weit verbreitet, was insbesondere mit dem Erfolg von Social Media Diensten zusammenhängt. Diese Kurznachrichten, die meistens

<sup>5</sup> Die entsprechende Grafik aus dem Artikel kann im Appendix in der Grafik B.5 eingesehen werden.

über das Internet verbreitet werden, eignen sich besonders gut um sozioökonomische Fragestellungen zu erforschen.[6]

Bei der Sentiment Analyse werden den Dokumenten im Datensatz Klassen zugewiesen, im einfachsten Fall sind diese positiv oder negativ. Neben dieser binären Einteilung gibt es auch multi-label Klassifikationen (positiv, negativ, neutral) oder ordinale (sehr positiv, positiv, neutral, negativ, sehr negativ). Eine weitere Möglichkeit stellt die Zuweisung von Emotionen dar, wie beispielsweise die sieben Basis Emotionen von Ekman (Freude, Angst, Wut, Überraschung, Ekel, Traurigkeit)[17]. Durch einige Aspekte unterscheiden sich microblogging Texte deutlich von beispielsweise Zeitungsartikeln. Hierzu gehört der geringe Umfang von ca. 200 Zeichen, die Verwendung von Emojis und Emoticons, sowie die Anreicherung durch Bilder, Videos, Hashtags oder Verweise auf andere Nutzer\*innen.[6]

Die vielen verschiedenen Ansätze der Sentiment Analyse lassen sich in zwei Arten unterteilen. Bei "Wissensbasierten Methoden" werden auf Basis von Lexika und Ontologien klare Regeln zur Zuweisung von Klassen aufgestellt. Diese können äußerst komplex sein, allerdings ist durch die modulare Zusammensetzung ein Transfer auf andere Systeme oder Sprachen relativ einfach, da nur Teile angepasst werden müssen.

Anders verhält es sich mit statistischen "Machine Learning Methoden", die auf Basis eines gelabelten Datensatzes die Regeln lernen. In diesem Fall kann ein trainiertes System nicht ohne weiteres auf einen Text zu einem anderen Thema oder auf einer anderen Sprache angewandt werden.[57]

Diese Unterscheidung wurde auch in diesem Kapitel gewählt, um die in dieser Arbeit zur Anwendung kommenden Methoden vorzustellen. Im folgenden werden zunächst die beiden lexikonbasierten Ansätze anhand zweier Studien dargestellt und anschließend auf einige gängige Methoden des maschinellen Lernens eingegangen. Letzteres orientiert sich an den Ergebnissen der GermanEval Tasks von 2018[72], bei der sich die Teilnehmer\*innen mit dem Thema "Identification of Offensive Language" beschäftigten.

### 2.2.1 Wissensbasiert

Im Laufe der letzten 15 Jahre sind verschiedene Lexika entstanden, die als Basis einer wissensbasierten Sentiment Analyse dienen können. Eines der ältesten, das Princeton WordNet of English (PWN)[19] ist noch heute die Grundlage für weitere Lexika, in denen Taxonomien<sup>6</sup> mit Informationen zu Polarität und Emotionen angereichert werden. Für die deutsche Sprache wird seit 2017 an der Hochschule Darmstadt das Open German WordNet (OdeNet) entwickelt. Eine erste Version basierte auf verschiedenen Quellen wie Open Thesaurus. Ausgeweitet wurde das Lexikon, das mittlerweile ca. 200,000 Einträge und 35,000 Synonym Gruppen zählt, durch folgende Methoden[29][30]:

---

<sup>6</sup> Teilgebiet der Linguistik, auf dem man durch Segmentierung und Klassifikation sprachlicher Einheiten den Aufbau eines Sprachsystems beschreiben will.[15]

- Automatisches "part-of-speech (POS) tagging".
- Verlinkung der gemeinsamen Synset IDs<sup>7</sup> durch maschinelle Übersetzung.
- Hyponym Beziehungen<sup>8</sup> wurden automatisch hinzugefügt.
- Einpflegen weiterer Definitionen und Zusammenhänge aus dem englischen PWN.

Es gibt außerdem verschiedene Lexika, die eine Klassifikation in Basis Emotionen ermöglichen[59]. Eine deutsche Version des NRC "Emotion Lexicon"[40], welches englische Wörter den sieben Basis Emotionen zuteilt, bietet das german-emotion-dictionary[46]. Wie die anderen Lexika ist auch dieses frei zugänglich. Wie genau auf Basis eines bestimmten Lexikons anschließend eine Klassifikation von Dokumenten abgeleitet wird, hängt von der Umsetzung ab. Manche Lexika wie WordNet werden in fertigen Python Paketen verwendet, und es reicht ein einfacher Funktionsaufruf. Andere Lexika liegen in txt Dokumenten vor und müssen zunächst eingelesen und angepasst werden, um anschließend Emotions-Scores ableiten zu können.

#### 2.2.1.1 *TextBlob*

Eine sehr einfache und mit geringem Aufwand verbundene Sentiment Analyse bietet das Python Paket TextBlob, das ein Teil der großen NLTK Library[43] ist. Es bietet neben vielen anderen Funktionen eine Einstufung der Polarität mit Werten zwischen -1.0 und 1.0. Im englischen gibt es außerdem die Einteilung der Subjektivität mit Werten zwischen 0.0 und 1.0, dabei ist 0.0 sehr objektiv und 1.0 sehr subjektiv<sup>9</sup>.

Gerade wenn Analysen von verschieden-sprachigen Texten durchgeführt werden sollen, ist der heterogene Entwicklungsstand bzw. die grundlegenden Unterschiede der Lexika ein Problem. In einer Auswertung der Tweets von Politikern und Staatsoberhäuptern aus der ganzen Welt, wurden aus diesem Grund zunächst alle Tweets ins Englisch übersetzt. Die hierfür verwendete API von Google Translate[22] hat jedoch ein relativ niedriges Request Limit von ca. 100KB pro Tag und Computer und ist entsprechend zeitaufwändig.

Für eine erste Darstellung wurden Polarität und Subjektivität von den Autoren in einer Grafik gegenübergestellt, die auch in Abbildung 2.6 zu sehen ist. Dabei sind die Subjektivitäts-Scores von Trump und Modi vergleichsweise

---

<sup>7</sup> Bei Synsets werden Synonyme zu einem Feld zusammengefasst. Sie lassen sich auch als Synonymringe umschreiben.[60]

<sup>8</sup> Hyponym ist ein untergeordneter Begriff (z. B. Vogel, Hund gegenüber Tier)[14]

<sup>9</sup> In der Dokumentation von TextBlob-de findet sich hingegen noch folgender Hinweis: "Warning: WORK IN PROGRESS: The German polarity lexicon contains only uninflected forms and there are no subjectivity scores yet."

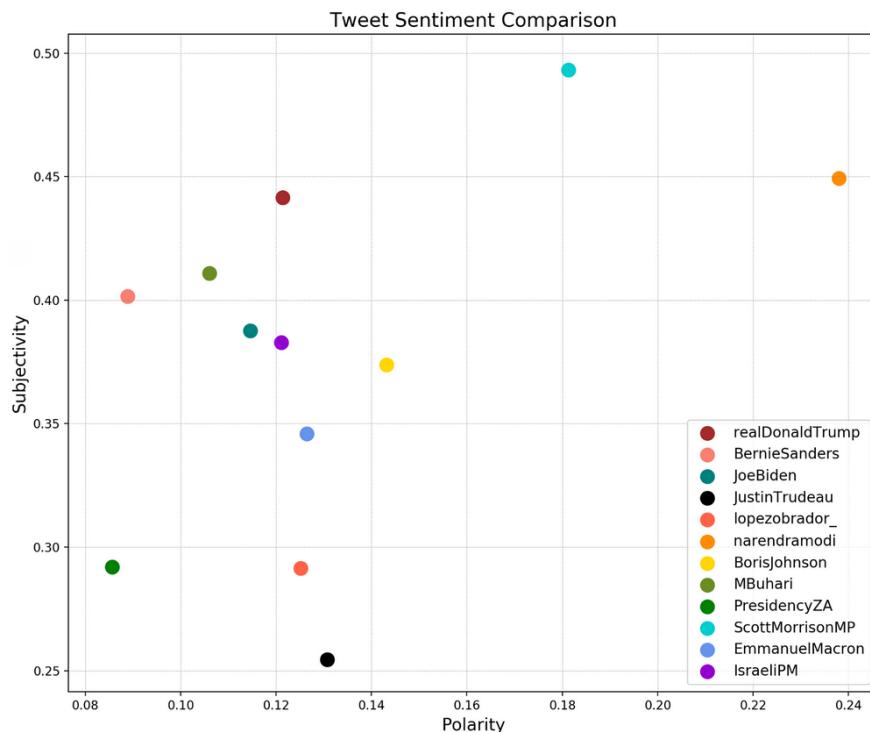


Abbildung 2.6: Einordnung der Politiker in einer Polarität-Subjektivität-Grafik[16]

hoch. Trudeau hingegen scheint in seiner Wortwahl relativ objektiv zu twittern. Aus den Polaritätswerten geht hervor, dass keiner der Politiker überwiegend negative Sprache verwendet. Am niedrigsten sind die Werte von Bernie Sanders, was ebenfalls nicht überrascht, da er überwiegend Versäumnisse der Politik anprangert. Diese Grafik zeigt zwar, wie einfach Ergebnisse einer Sentiment Analyse mit TextBlob dargestellt und interpretiert werden können, jedoch ist sie für wissenschaftliche Standards zu sehr vereinfacht. Das Mindeste wäre eine Angabe der Unsicherheit zu den jeweiligen Datenpunkten sowie die Darstellung der gesamten Achsenabschnitte.

Durch die Einschränkung auf bestimmte Themen und Schlüsselwörter können die sehr verdichteten Informationen im Detail dargestellt werden. So haben die Autoren für die Grafik in Abbildung 2.7 nur Tweets des Accounts @realDonaldTrump über CNN und Fox News auf einer Zeitlinie aufgetragen. Dabei sind die Polaritätswerte im Bezug auf das konservative, GOP-freundliche Fox News durchgehend neutral bis positiv. Tweets zu CNN scheinen dagegen überwiegend neutral bis negativ zu sein.[16]

TextBlob selbst bietet kaum Erklärungen, wie genau die Ergebnisse der Sentiment Analyse ermittelt werden. Es bietet sich lediglich die Möglichkeit den Code nachzuvollziehen, was teilweise recht komplex sein kann<sup>10</sup>. Eine gute Zusammenfassung der wichtigsten Aspekte hat Aaron Schumacher aus dem Code abgeleitet und bereit gestellt. Die bereits erwähnten TextBlob Werte Subjektivität und Polarität werden als Durchschnittswerte über alle bekannt-

<sup>10</sup> <https://github.com/sloria/TextBlob>

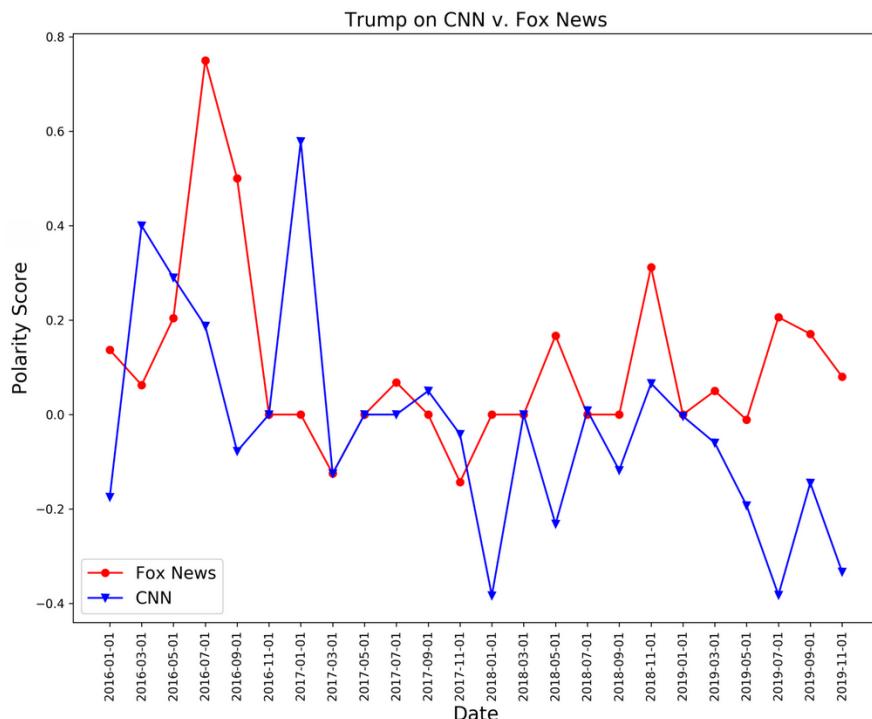


Abbildung 2.7: Polarität von @realDonaldTrump zu CNN und Fox News[16]

ten Wörter mit mindestens zwei Buchstaben ermittelt, die ein zu analysierendes Dokument enthält. "Bekannt" bedeutet, dass das zugrundeliegende Lexikon<sup>11</sup> mindestens einen Eintrag zu diesem Wort beinhaltet. Außerdem bietet TextBlob eine Möglichkeit mit Negation umzugehen, da bestimmte Wörter dafür sorgen, dass die Polarität umgekehrt wird.[5]

### 2.2.1.2 Basis Emotionen

Das deutsche Basis-Emotions-Lexikon besteht aus sieben .txt Dateien, eine für jede Emotion: Wut, Trauer, Angst, Freude, Ekel, Verachtung, Überraschung. Jede Datei enthält eine Liste der Wörter, die dieser Emotion zuzuschreiben sind, wobei ein Wort in verschiedenen Listen vertreten sein kann.[46] Das Format im englischen Wörterbuch unterscheidet sich hier von, da alle Wörter in einer Datei zusammengefasst sind und für jede Wort-Emotion Verbindung mit 0 oder 1 angezeigt wird, ob sie zusammengehören.[40]

Eine Arbeit, die mit dieser Methode der wissensbasierten Sentiment Analyse gute Ergebnisse erzielt hat, wendete diese auf Tweets von Bundestagsabgeordneten an. Dabei konnte zum Beispiel festgestellt werden, dass Tweets von AfD Mitgliedern durchgehend höhere Werte in der Dimension Angst zugewiesen wurden als bei Angehörigen der SPD (siehe Abbildung 2.8).

<sup>11</sup> Im Englischen kann dieses XML eingesehen werden: <https://github.com/sloria/TextBlob/blob/eb08c120d364e908646731d60b4e4c6c1712ff63/textblob/en/en-sentiment.xml>

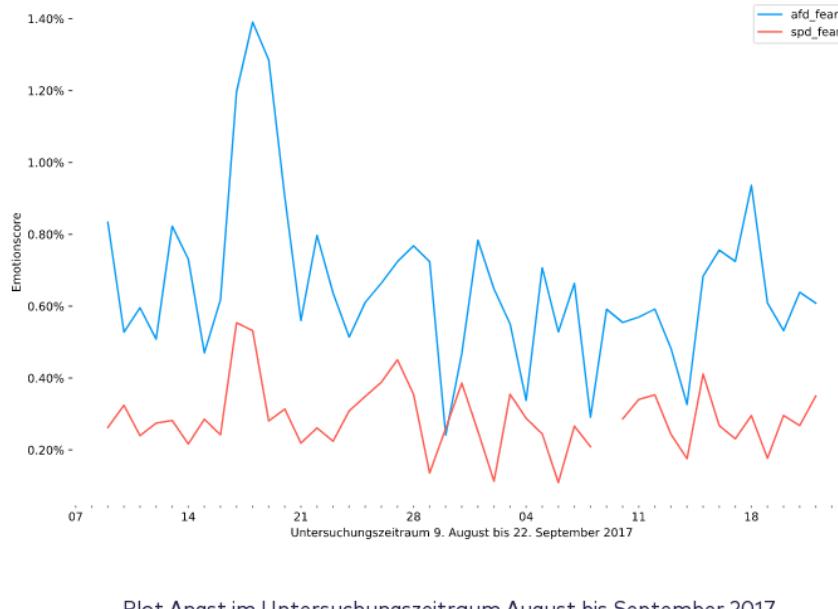


Abbildung 2.8: Angst in den Tweets der SPD im Vergleich zur AfD[53]

Bei der einfachen Implementierung dieser Methode wird jedem Wort ein Vektor zugewiesen und wenn dieses Wort beispielsweise in den Lexika Wut und Ekel vorkommt, würde ein zugehöriger Vektor zunächst so aussehen: [1, 0, 0, 0, 1, 0, 0]. Diese Werte werden allerdings noch relativiert, da weder die Tweetlänge noch die Anzahl an Tweets die Ergebnisse verzerrn sollen. Ein Tweet mit fünf Wörtern, von denen zwei in Wut.txt und eins in Ekel.txt vorkommt, würde beispielsweise so aussehen: [0.4, 0, 0, 0, 0.2, 0, 0].[52][53] Diese Methode ist deutlich einfacher als die in TextBlob hinterlegten Funktionen. Es gibt keine Möglichkeit, auf Negationen oder Intensivierungen einzugehen und auch alle weiteren Informationen, die man aus dem Satzbau entnehmen könnte, gehen verloren.[40]

## 2.2.2 Maschinelles Lernen

Für die Methoden aus der Kategorie "maschinelles Lernen" ist eine Grundvoraussetzung, dass die Datensätze, anhand derer die Regeln gelernt werden, gelabelt sind. Eine Möglichkeit diese sehr zeitaufwändige Arbeit zu umgehen, besteht darin, einen thematisch sehr ähnlichen Datensatz zu verwenden, dem bereits die Label von Interesse zugewiesen wurden. In dieser Arbeit wurde daher auf die Tweets von GermEval 2018 zurückgegriffen. Dieser Datensatz mit 8541 Tweets wurde minutiös zusammengestellt und gelabelt, um möglichst jede Art von Bias zu umgehen. So wurden die Daten aus den Timelines von ca. 100 Usern heruntergeladen, was ein breiteres Vokabular versprach, als Twitter nach bestimmten Stichworten zu durchsuchen oder Streaming Daten zu sammeln, in denen "trending" Tweets überrepräsentiert sind. Da bestimmte Themen trotzdem fast immer negativ konnotiert

waren (Flüchtlinge, Merkel, Maas), wurde der Datensatz zusätzlich mit diesbezüglich neutralen Tweets angereichert und auf eine ausgewogene Repräsentanz des gesamten politischen Spektrums geachtet.

Bei der Vergabe von Labeln wurde anhand von 300 Tweets getestet, ob die drei Personen, die Label verteilt, auch die gleichen Kategorien zuwiesen. Aussortiert wurden zunächst Tweets ohne erkennbaren Sinn oder solche, die lediglich die offensive Äußerung einer anderen Person wiederholten. Mit einem Cohens Kappa von 0,66 bei 240 gelabelten Tweets ist diese Übereinstimmung relativ gut. Für diese Arbeit sind insbesondere die Label aus Task 1 von Interesse. Hier wurde zwischen den Klassen "OFFENSE" (2890 Tweets) und "OTHER" (5651 Tweets) unterschieden. Die Unterscheidung aus Task 2 in "ABUSE", "INSULT" und "PROFANITY" wäre zu detailliert.[72]

Von den 20 verschiedenen Teams, die ihre Ergebnisse einreichten, wurden verschiedene Ansätze gewählt und kombiniert. Wie in Tabelle 2.2.2 zu sehen ist, geben diese eine gute Übersicht über die aktuellen Methoden in der Sentiment Analyse. Für diese Arbeit wurde das Vorgehen der TU Wien[41] im Detail betrachtet, die bei der Klassifizierung besonders gut abgeschnitten hat. In diesem Kapitel wird nur kurz auf den Ansatz eingegangen. Später wird in Kapitel 4 genauer beschrieben, wie in dieser Arbeit konkret vorgegangen wurde.

VORBEREITUNG	WÖRTERBUCH	WORT VEKTOREN	KLASSIFIZIERER
Tokenization <sup>a</sup>	Kein aufgabenspez. Lexikon	Vortrainierte Word Embeddings <sup>b</sup>	SVMs
POS-Tagging <sup>c</sup>	Öffentlich zugängliches Lexikon	An eigenen Tweets trainierte Vektoren	Logistic regression
Lemmatization und stemming <sup>d</sup>	Neues Lexikon erstellt	Mehrsprachige Word Embeddings	Entscheidungsbäume
Nur Parsing <sup>e</sup>	Übersetztes englisches "Schimpfwörterbuch" Deutsches "Schimpfwörterbuch" Polaritäts Lexikon <sup>f</sup>	Lexikonerweiterung durch Embeddings	Naive Bayes
			Neuronale Netze: CNN, LSTM, GRU

<sup>a</sup> TweetTokenizer in nltk (Bird et al., 2009), SoMaJo social media tokenizer (Proisl and Uhrig, 2016), twokenize (Owoputi et al., 2013), extension of the tokenizer of Baziotis et al. (2017), tokenizer in spaCy

<sup>b</sup> word2vec, fasttext

<sup>c</sup> Stand-alone tagger abgeleitet von einem komplexeren Tool wie spaCy oder TextBlob

<sup>d</sup> spaCy, TreeTagger (Schmid, 1995) und ParZu., stemming

<sup>e</sup> ParZu parser (Sennrich et al., 2013), mate-tools parser(Björkelund et al., 2010)

<sup>f</sup> PolArt (Klenner et al., 2009), PolarityClues (Waltinger, 2010) and SentiWS (Remus et al., 2010)

Besonders interessant ist, dass die Gruppe der TU Wien in ihrem Ansatz auf neuronale Klassifikationsmethoden verzichtete und sehr gute Ergebnis-

se erzielte. Mit einem F1-Score von 76,77 schnitten sie bei Task 1 von allen Teilnehmern am besten ab. Nach einer ersten Bearbeitung der Tweets, bei der Sonderzeichen entfernt wurden, sind aus den vereinfachten, kleingeschriebenen **Tokens n-Gramme** erstellt worden. Aus diesen Gruppen von Buchstaben bzw. Wörtern wurden per **TF-IDF** nur diese behalten, die selten genug waren, um Informationen zu tragen und häufig genug, um auch auf andere Texte angewandt werden zu können.

Für die anschließende Feature-Extraction wurde ein vor-trainiertes **Word2Vec Model** verwendet. Außerdem trennten die Autoren alle Tokens für die im verwendeten Model keine **Embeddings** hinterlegt waren. So konnten zum Beispiel Tokens wie "Nichtdeutsch" ebenfalls Vektoren zugeordnet bekommen. Weitere Features wurden auf Basis der wichtigsten Tokens und Buchstaben n-Gramme in der jeweiligen Klasse "OTHER" oder "OFFENSE" erstellt. Zum einen wurde der Abstand eines "wichtigen Tokens" zu den anderen im Tweet enthaltenen Tokens als Feature berechnet. Da für Buchstaben n-Gramme keine Embeddings existieren, wurde hierfür lediglich eine boolesche Variable berechnet, ob der Tweet eine dieser wichtigen Buchstaben Gruppen enthält.

Die so erstellten Features wurden anschließend in einer ersten Basis Klassifikation mit drei verschiedenen Methoden verwendet. Diese waren ein **maximum entropy model (LogisticRegression)**, ein **Random Forest Ensemble** mit Splits auf Basis des **Information Gain** und ein Random Forest mit Splits auf Basis der **Gini-Impurity**. Nach mehreren Durchgängen und **10 x Cross-Validations** ergaben sich auf diese Weise für jeden Tweet Predictions und Meta-Features. Diese gingen anschließend in die eigentliche Klassifizierung ein, in der mit einem **maximum entropy model (LogisticRegression)** die finalen Vorhersagen getroffen wurden.

## DATENSATZ UND EXPLORATIVE DATENANALYSE

---

Die für diese Arbeit verwendeten Datensätze wurden auf Basis allgemein verfügbarer Quellen erstellt. Diese sind zum einen die von Twitter bereit gestellte API und zum anderen die auf der Bundestag Homepage veröffentlichten Plenarprotokolle in XML Format<sup>1</sup>. Im Folgenden wird zunächst erklärt, welche Schritte notwendig waren, um die beiden verwendeten Datensätze zu erstellen.<sup>2</sup> Anschließend werden die Ergebnisse einer explorativen Datenanalyse präsentiert, um einen ersten Einblick in die verwendeten Daten zu ermöglichen.

### 3.1 TWITTER API UND MONGODB

Um die Tweets aller Bundestagsabgeordneten mit einem Twitter Account herunterzuladen, musste zunächst festgestellt werden, wie die jeweiligen Nutzernamen (screen\_name) der Abgeordneten lauten. Erst anschließend konnten die Daten heruntergeladen und in eine Datenbank eingepflegt werden.

#### 3.1.1 *Crawlen der Abgeordneten mit Twitter Account*

In einem ersten Schritt wurden Anfang April 2020 von den parteieigenen Fraktionsseiten die screen\_names der Politiker\*innen mit einem Twitter Account gesammelt. Für jede Fraktion kam zu diesem Zweck ein eigener Crawler zum Einsatz, da jede Partei ihre Homepage anders aufgebaut hat<sup>3</sup>. Die generierten Listen wurden anschließend mit regulären Ausdrücken bearbeitet, um URLs und Zeilenumbrüche zu entfernen.<sup>4</sup>

Da im Laufe der ersten Monate insbesondere bei der Liste der AfD Abgeordneten Fehler auffielen, wurde Anfang Juni ein manueller Abgleich zur Qualitätssicherung gemacht. Dabei wurde jeder Abgeordnete von der parteieigenen Fraktionsseite zunächst in der zuvor erstellten Liste gesucht. Wenn dieser Abgleich negativ ausfiel, wurde der Name bei Twitter eingegeben und versucht ein Profil zu finden. Dieses Vorgehen führte bei der AfD zu einer knappen Verdreifachung der Anzahl von screen\_names, und auch bei

---

<sup>1</sup> <https://www.bundestag.de/services/opendata>  
<https://developer.twitter.com/en>

<sup>2</sup> Der Code für den Download der Daten (Plenarprotokolle und Twitter) ist auf GitHub hinterlegt: [https://github.com/LisaStolz/kommunikation\\_bundestag/tree/master/05\\_Data](https://github.com/LisaStolz/kommunikation_bundestag/tree/master/05_Data)

<sup>3</sup> Als Basis wurde die folgende Anleitung zur Anwendung von Scrapy in Jupyter Notebooks verwendet: <https://www.jitsejan.com/using-scrapy-in-jupyter-notebook.html>

<sup>4</sup> Der Code für die Datensatzerstellung und Auswertung der Twitter Daten ist auf GitHub abgelegt: [https://github.com/LisaStolz/kommunikation\\_bundestag/tree/master/06\\_Analyse](https://github.com/LisaStolz/kommunikation_bundestag/tree/master/06_Analyse)

den anderen Parteien konnten zwischen zwei und 14 weitere Namen nachgepflegt werden.

### 3.1.2 Laden der Timeline Daten und speichern in MongoDB

Für jede Partei wurde ein eigenes Jupyter Notebook (Python3) erstellt, da ohnehin für jede Partei eine eigene Liste der screen\_names existiert, und somit der Download parallelisiert werden konnte. Im Folgenden ist exemplarisch der Code aus dem Notebook zum Download der Tweets von Unionsabgeordneten (CDU, CSU) abgebildet.

Zunächst wird die Verbindung zu Twitter aufgebaut. Die notwendigen Zugangsdaten erhält man mit einem Developer Account, in welchem man eine neue App generiert<sup>5</sup>. Im untenstehenden Listing wird die API mit dem Python Paket Tweepy aufgerufen, wobei die Zugangsdaten mit Platzhaltern versehen wurden.

```
import os
import tweepy as tw

consumer_key= 'Lisas key'
consumer_secret='Lisas secret'
access_token_key='Lisas token_key'
access_token_secret='Lisas token_secret'

auth = tw.OAuthHandler(consumer_key, consumer_secret)
auth.set_access_token(access_token_key, access_token_secret)
api = tw.API(auth, wait_on_rate_limit=True)
```

Listing 3.1: Twitter API - Verbindungsdaten aufsetzen

Anschließend wird die Verbindung zur lokalen MongoDB vorbereitet, indem die Namen der Datenbank und der Collection übergeben werden. In der Collection "Twitter\_mdp\_extend", welche ein Teil der Datenbank Twitter ist, wird im nächsten Schritt jeder Tweet als ein Dokument gespeichert.

```
import pymongo

client = pymongo.MongoClient("mongodb://127.0.0.1:27017/")
db = client['Twitter']
All_Tweets_collection = db['Twitter_mdp_extend']
```

Listing 3.2: Lokale MongoDB - Verbindungsdaten aufsetzen

Für den Download der Tweets wird zu Beginn die JSON Liste mit den screen\_names der Abgeordneten geladen. Anschließend wird nacheinander jeder Name an die API übergeben. Hierbei ist zu beachten, dass die Option

---

<sup>5</sup> Twitter bietet unter folgendem Link eine schrittweise Anleitung: <https://developer.twitter.com/en/docs/basics/getting-started>

tweet\_mode als "extended" angegeben wird, da andernfalls die Tweets abgeschnitten werden. Des weiteren können pro Seite nicht mehr als 200 Tweets geladen werden, und die Anzahl der Seiten scheint auf 17 begrenzt zu sein. Wenn die Grenze der zu ladenden Tweets eines Abgeordneten erreicht wurde<sup>6</sup>, dann wird jeder Tweet als eigenes Dokument in die zuvor definierte Collection geschrieben.

```
import json

with open('Namen_Union.json') as json_file:
    Union = json.load(json_file)

for Abgeordneter in Union:
    i = 1
    user = Abgeordneter
    all_tweets = []
    while i <= 100 :
        tweets_of_page = api.user_timeline(screen_name = user, tweet_
            mode = "extended", count = 200, page = i, include_rts =
            True)
        all_tweets = all_tweets + tweets_of_page
        i=i+1
        if len(tweets_of_page) == 0:
            break
    for tweet in all_tweets:
        All_Tweets_collection.insert_one(tweet.json)
```

Listing 3.3: Laden von Tweets und speichern in MongoDB

Das bisher beschriebene Vorgehen wurde über fünf Monate hinweg zu verschiedenen Zeitpunkten wiederholt, um auch alle aktuellen Tweets in den Datensatz einzupflegen. Die verwendete Funktion `api.user_timeline` bietet zwar theoretisch eine Option "since", um nicht immer alle Tweets zu laden, allerdings ist in diesem Fall das Iterieren durch Seiten nicht mehr möglich. Das würde bedeuten, dass bei Abgeordneten, die sehr viel tweeten, möglicherweise manche ausgelassen werden. Aus diesem Grund werden immer alle Tweets geladen und es kommt somit zu Duplikaten in der Datenbank. Im Rahmen des regelmäßigen Updates mit neuen Tweets, werden diese Duplikate entfernt und weitere Anpassungen an der Datenbank vorgenommen, um die anschließende Analyse zu vereinfachen. Diese regelmäßigen "Anpassungen" werden im Folgenden beschrieben.<sup>7</sup>

---

<sup>6</sup> Entweder weil es nicht mehr Tweets zu diesem User gibt, oder weil keine weiteren Seiten geladen werden dürfen.

<sup>7</sup> Es wurde entschieden, nicht vor jedem Download die Datenbank zu leeren, da dann die älteren Tweets verloren gehen würden. Bei Politikern die sehr viel Tweeten, wären das Tweets aus dem Jahr 2018 und Anfang 2019. Dieser Zeitraum wurde am Ende zwar nicht im Detail betrachtet, jedoch sollte diese Option offen gehalten werden.

### 3.1.3 Pflege des Datensatzes in MongoDB

Nachdem die aktuellen Tweets geladen wurden, und der Datensatz in der Collection Twitter\_mdp\_extend somit aktuell ist, werden die folgenden Schritte durchgeführt, die im Detail in Appendix A eingesehen werden können:

#### DUPLIKATE ENTFERNEN

In MongoDB werden anhand des Feldes "id", welches von Twitter vergeben wird, Duplikate erkannt und entfernt.

#### UMFORMATIEREN DES FELDS CREATED\_AT IN DATETIME FORMAT

In MongoDB wird das Feld "created\_at" in das datetime Format gebracht und der Wert in einem neuen Feld gespeichert. Die Collection wird als "Twitter\_mdp\_extend\_datetime" gespeichert.

#### ENTSCHACHTELN VON COLLECTION UND SELEKTION VON FELDERN

In MongoDB werden insbesondere die Felder mit Informationen zum User entschachtelt, um diese für Datenbankzugriffe leichter zugänglich zu machen. Außerdem werden nur die Felder selektiert, die relevante Informationen tragen.

#### FELD "USER\_PARTY" FÜR JEDEN TWEET HINZUFÜGEN

In MongoDB wird jedem User ein Feld mit der Parteizugehörigkeit zugewiesen. Zu diesem Zweck werden die user\_screen\_names abgeglichen mit den Namen in einer separaten Collection, in welcher die jeweilige Partei hinterlegt ist.

#### BACKUP UND ÜBERTRAGEN

Am Ende der Datenbanküberarbeitung wird nicht in MongoDB sondern in der Konsole ein neues Backup angestoßen. Dieses dient zur Datensicherung und zur Datenübertragung, um die Daten auf einen Desktop Computer einzuspielen.

## 3.2 PLENARPROTOKOLLE

Neben Twitter wurden Daten aus Plenarprotokollen analysiert, um festzustellen, in wie weit sich die Kommunikation im Bundestag von der in den sozialen Medien unterscheidet. In diesem Kapitel wird beschrieben, wie zunächst die Protokolle für die aktuelle Legislaturperiode geladen wurden, und anschließend wird die Aufbereitung der Daten für die Analyse erklärt.

### 3.2.1 Herunterladen aller Protokolle einer Legislaturperiode

Auf der Webseite des Bundestages können für jede Sitzung im Plenum die Protokolle in PDF oder XML Form heruntergeladen werden.<sup>8</sup> Der dynamische Aufbau der Webseite hätte den Einsatz eines Crawlers deutlich er-

---

<sup>8</sup> <https://www.bundestag.de/services/opendata>

schwert. Da jedoch die Links zu den Protokollen beim Laden jeder dynamischen Seite im html Code gespeichert werden (auch wenn sie in der grafischen Darstellung nicht mehr sichtbar sind), können, nach dem durchklicken jeder Slide, über die Webdeveloper Tools (z.B. in Google Chrome oder Firefox) alle Links aus dem HTML Code extrahiert werden und in eine Text Datei gespeichert werden.

Zunächst wurden per Konsole die Links aus dem txt Dokument gelesen um sie vom restlichen html Code zu trennen. Anschließend musste jedem Link noch ein "<https://www.bundestag.de>" vorangestellt werden, um funktionierende Links zu erhalten. Mit dem Programm Wget<sup>9</sup> konnten schließlich alle 171 Protokolle aus der Liste von Links heruntergeladen werden.

### 3.2.2 Auslesen von XML Dokumenten

Um mit den Informationen aus den 171 Protokollen arbeiten zu können, wurde zunächst jedes mit dem Python Paket ElementTree einzeln ausgelesen. Das Ziel war ein Datensatz in tabellarischer Form, in welchem jede Zeile für einen Redeabschnitt stehen sollte. Jede Rede im Bundestag hat eine **Rede\_ID** und die Redner\*in wird mit **Vor- und Nachnamen** sowie der **Fraktion** angegeben. Außerdem ist die Plenarsitzung nach **Tagesordnungspunkten** unterteilt, die wiederum zwei **Beschreibungen** der zu behandelnden Themen haben können.

```
# Grundbausteine
typen = '(?:Heiterkeit und Beifall|Beifall|Lachen|Heiterkeit|Widerspruch|(Weitere )?Zurufe?|Gegenrufe?)'
parteien = '(?:SPD|FDP|AfD|CDU|CSU|BÜNDNIS_90/DIE_GRÜNEN|DIE LINKE|Bundesminister)'
akteure = '\s*(?:sowie|und)?[,|,|\s]*(?:beim?|vo[nm])?\s*(?:de[rsmn])?\s*(?:Abg\.)?\s*(?:de[rs]|vo[nm])?'
namen = '(?:[a-zA-ZÄÖäö-öö-f \.\,\-\+]+)' # • ist ein weiches trennzeichen, wird z.B. bei Alexander Graf Lambsdorff der
texte = '(?:[a-zA-ZÄÖäö-öö-f \.\,\!\,\,\+]+)'

# Blöcke zum verketten in einer großen Pattern
re_block={}
for BLOCK in ['A']:
    # Mehr als Block A nicht notwendig, weil Kommentare an "--" getrennt werden
    bl={}
    for AKT in [1,2,3,4,5,6]:
        #für jeden Akteur
        bl[AKT] = {}
        inst = BLOCK+str(AKT)
        # helper blocks, werden in anderen blocks verschachtelt
        #bl[AKT][“partei_mdb”] = “(?P<partei_mdb_“inst+”“+parteien+)”
        bl[AKT][“partei”] = “(?P<partei_“inst+”“+parteien+)”
        bl[AKT][“text”] = “(?:\s*)(?P<text_“inst+”“+texte+)”
        bl[AKT][“mdb”] = “(?P<mdb_“inst+”“+namen+)?(,|\s*)(?:\[(?P<partei_mdb_“inst+”“+parteien+)\])?”
        #blocks zur nutzung in patterns
        bl[AKT][“typ”] = “(?P<typ_“inst+”“+typen+)”
        bl[AKT][“akteur”] = “(?:\n(?P<akteur_“inst+”“_p+”“+akteure+)\s*“+bl[AKT][“partei”]+”\\n\n(?P<akteur_“inst+”“_m+”“+akteure+)\s*“+bl[AKT][“mdb”]+”(?:“+bl[AKT][‘text’]+”)?”\n”
    re_block[BLOCK] = bl
```

Abbildung 3.1: Grundsteine des Regulären Ausdrucks zur Kommentar-Analyse

Ebenfalls genau dokumentiert werden alle anderen Vorkommnisse im Plenum, die während einer Rede statt finden. Ein typischer **Kommentar** ist beispielsweise "Beifall bei Abgeordneten der CDU/CSU und der FDP". Allerdings gibt es auch eine Vielzahl von Variationen, wie zum Beispiel "Widerspruch bei der LINKEN – Matthias W. Birkwald [DIE LINKE]: Es gibt kein Ministerium

<sup>9</sup> <https://www.gnu.org/software/wget/manual/wget.html>

für die Opposition, Herr Kollege!".

Man kann die Informationen in den Kommentaren auf folgende Gruppen herunterbrechen: **Aktion**, **Akteur**, **Partei** und **Text**, wobei diese nicht als eigene Tags im Dokument gekennzeichnet sind, sondern mit Regulären Ausdrücken ausgewertet werden mussten.

NAME	BESCHREIBUNG
Datum	In jedem Plenarprotokoll ist am Anfang das Attribut "sitzung-datum" angegeben.
TOP	Jeder Tagesordnungspunkt kann verschiedene Reden enthalten.
Beschreibung1	Informationen zum Thema des aktuellen TOP, gelesen aus dem Attributwert "T_NaS"
Beschreibung2	Informationen zum Thema des aktuellen TOP, gelesen aus dem Attributwert "T_fett"
Rede_ID	Zusammensetzung der ID1809709800: ID+aktuelle Wahlperiode(18) + Sitzungsnummer(097) + laufende Nummer der verknüpften Rede (098) + Reserve für etwaige Korrekturen(00)
Titel	Falls vorhanden Titel der Redner*in.
Vorname	Vorname der Redner*in
Nachname	Nachname der Redner*in
Fraktion	Fraktion der Redner*in
Rede_Text	Der eigentliche Text der Rede, unterteilt in Abschnitte von denen jeder eine Zeile in der Tabelle befüllt.
Kommentar	Beschreibung aller weiteren Vorkommnisse - ausgelesen mit RegEx Funktion.
<Partei>_Akteur1	Alternativen: "ganze", "teile", <Name>, Bsp.: SPD_Akteur1
<Partei>_Aktion1	Alternativen: "Lachen", "Beifall", "Heiterkeit", "Widerspruch", "Zuruf", Bsp: SPD_Aktion1
<Partei>_Text1	Falls vorhanden der zugerufene Text. Bsp.:SPD_Text1
<Partei>_Akteur2	Falls für eine Partei zwei verschiedene Akteure im Kommentar stehen.
<Partei>_Aktion2	Falls eine Partei mit zwei Aktionen im Kommentar steht.
<Partei>_Text2	Falls eine Partei mit zwei Zurufen in einem Kommentar steht.

Tabelle 3.1: Mit ElementTree ausgelesene Daten aus XML Plenarprotokollen

Komplex wird die Strukturierung dadurch, dass Kommentare mehrere Aktionen gleichzeitig beschreiben können und sich die Beschreibung in Nuancen unterscheidet. So enthält der Kommentar

"Annalena Baerbock [BÜNDNIS 90/DIE GRÜNEN]: Das stimmt doch gar nicht! – Oliver Krischer [BÜNDNIS 90/DIE GRÜNEN]: Woher wissen Sie das denn?"

zwei mal die Aktion "Zuruf", zwei mal die Partei "BÜNDNIS 90/DIE GRÜNEN" und zwei verschiedene Zurufe von zwei Akteur\*innen (Annalena Baerbock und Oliver Krischer). Dagegen wäre in dem Kommentar "*Beifall bei der SPD sowie bei Abgeordneten des BÜNDNISSES 90/DIE GRÜNEN*" die Aktion zwei mal "Beifall", einmal von der Partei SPD, einmal vom BÜNDNIS 90/DIE GRÜNEN und die Akteur\*innen wären einmal die "ganze" Partei (SPD) und einmal nur vereinzelte Abgeordnete (BÜNDNIS 90/DIE GRÜNEN). Zusätzlich wird das Auslesen erschwert durch die Angleichung von Parteinamen ("des BÜNDNISSES 90/DIE GRÜNEN").

In der Abbildung 3.1 sind die Grundbausteine des Regulären Ausdrucks abgebildet. Diese wurden anschließend verkettet und die ausgelesenen Gruppen den entsprechenden Spalten in der Tabelle zugeordnet. Um auf duplizierte Zeilen verzichten zu können, wurde entschieden für jede Partei eine eigene Spalte pro Aktion, Akteur und Text zu erstellen. Mit dem Ziel, auch Kommentare mit zwei Aktionen der selben Partei abbilden zu können, gibt es jede dieser Spalten zwei mal. In der Tabelle 3.1 wird ein Überblick mit einer kurzen Beschreibung der Spalten gegeben.<sup>10</sup>

### 3.3 EXPLORATIVE DATENANALYSE DER TWEETS

Um die Ergebnisse dieser Arbeit besser einordnen zu können, werden in diesem Kapitel einige grundlegende und beschreibende Statistiken präsentiert. Der betrachtete Zeitraum wird zu diesem Zweck eingeschränkt auf fünfzehn Monate, von Mai 2019 bis inklusive Juli 2020, um möglichst aktuelle und repräsentative Werte zu erhalten. Abgeordnete, die zwar einen Account haben, jedoch in dieser Zeit nicht getwittert haben, werden nicht mitgezählt. Tweets von Accounts, die zu Beginn der Recherche existierten und in dieser Zeit gelöscht wurden, sind im Datensatz weiterhin enthalten. Ein Beispiel hierfür ist der User Johannes Kahrs (SPD). Dieser war lange sehr aktiv auf Twitter und lösche seinen Account, nachdem er am 05.05.2020 von allen Ämtern zurückgetreten war.

Wie in Abbildung 3.2 zu erkennen ist, wurde in jeder Partei über die letzten drei Jahre zunehmend mehr getwittert. Insbesondere bei der AfD ist dieser Anstieg darauf zurückzuführen, dass viele Abgeordnete zu Beginn der 19. Legislaturperiode noch keinen Twitter Account hatten. Doch auch bei der FDP, die nicht im 18. deutschen Bundestag vertreten war, stiegen die Aktivitäten auf Twitter ab 2018 deutlich an. Ein besonders starker Anstieg ist zum Zeitpunkt der Bundestagswahl 2017 zu erkennen und ebenfalls bei den Wahlen in Europa und Thüringen. Interessant ist hierbei, dass die AfD bei der Europawahl kaum merklich mehr getwittert hat und hingegen klare Ausschläge bei der Wahl in Thüringen zeigt. Auf die Wahl des Ministerpräsidenten Anfang Februar 2020, die eine Regierungskrise in Thüringen nach

---

<sup>10</sup> Der Code für die Datensatzerstellung und Auswertung der Plenarprotokolle ist auf GitHub abgelegt: [https://github.com/LisaStolz/kommunikation\\_bundestag/tree/master/06\\_Analyse/Plenum](https://github.com/LisaStolz/kommunikation_bundestag/tree/master/06_Analyse/Plenum)

sich zog, wird auch in Kapitel 4 eingegangen, wenn die Ergebnisse der Sentiment Analyse beschrieben werden.

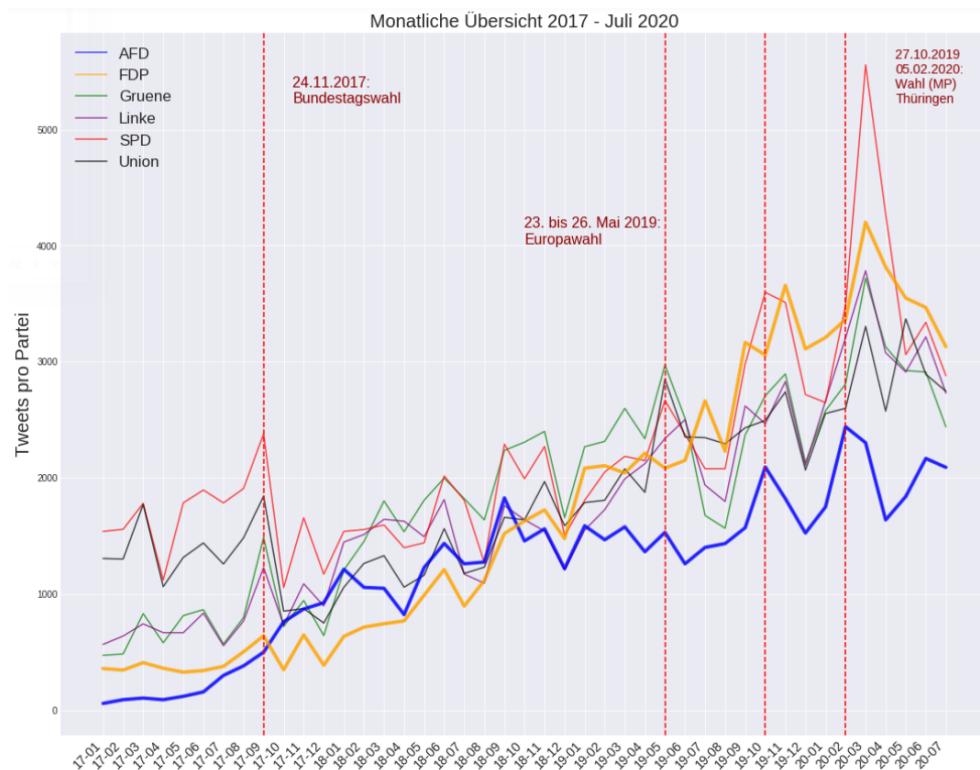


Abbildung 3.2: Absolute Häufigkeiten von Tweets zwischen Jan 2017 und Juli 2020

Verkürzt erklärt ging es in Thüringen um die Wahl von Thomas Kemmerich (FDP) zum Ministerpräsidenten mit Stimmen der AfD. Es ist zu erkennen, dass die FDP ab Mitte 2019 immer aktiver auf Twitter wurde, und zu der Zeit, als die Wahl in Thüringen im Oktober 2019 statt fand, gehörte sie zu den am meisten twitternden Parteien. Es ist unwahrscheinlich, dass es sich hier eine direkte Kausalität handelt - schließlich sind die im Bundestag twitternden Politiker\*innen nicht die selben, die auf Landesebene abstimmen. Aller höchstens könnte die vermehrte Aktivität als eine Art Aufbruchsstimmung innerhalb der gesamten Partei verstanden werden, die sich auch auf Landesebene vermuten lässt. Der wirklich große Ausschlag war in den Tweets der Bundestagsabgeordneten erst nach der eigentlichen Wahl zum Ministerpräsidenten zu beobachten. Zu diesem Zeitpunkt schaltete sich auch Berlin ein, mit dem Ziel die Wahl rückgängig zu machen. Auffällig war außerdem, dass die AfD die einzige Partei war, die eben nicht nach der Wahl besonders viel twitterte, sondern mit dem Datum der Wahl von Thomas Kemmerich einen vorläufigen Höchststand erreicht hatte.

Union und SPD waren 2017 noch am stärksten auf Twitter vertreten, allerdings hat sich diese Aufteilung mittlerweile relativiert. Im Verhältnis zu der Anzahl an Sitzen, die diese beiden Parteien im Bundestag inne haben, besit-

PARTEI	TWEETS	MDPS	TWITTER	ANTEIL	TWEETS PRO USER
AFD	26.875	89	71	79,78	379
FDP	46.856	80	75	93,75	625
Gruene	39.349	67	60	89,55	656
Linke	40.191	69	57	82,61	705
SPD	47.256	152	110	72,37	430
Union	39.621	246	131	53,25	302

Tabelle 3.2: Abgeordnete im Bundestag und auf Twitter - Mai 2019 - Juli 2020

zen vor allem bei der Union nur wenige Abgeordnete einen Twitter Account (53 %). Sehr stark vertreten sind hingegen FDP und Grüne, bei denen ca. 90% der Abgeordneten einen eigenen Account haben, und in den betrachteten 15 Monaten wurden durchschnittlich über 600 Tweets pro User abgesetzt.

Aus der Tabelle 3.2 geht des weiteren hervor, dass bei der Partei die Linke zwar nur gut 80% der Abgeordneten auf Twitter vertreten sind, diese setzen jedoch mit Abstand am meisten Tweets pro Nutzer ab (705). In Abbildung 3.3 kann man außerdem sehen, dass die drei Abgeordneten der Linken mit den meisten Tweets alle ähnlich aktiv sind. Anders als bei den anderen Parteien gibt es keine Ausschläge bis weit über 4000 Tweets, jedoch bleibt auch keiner unter 3000.

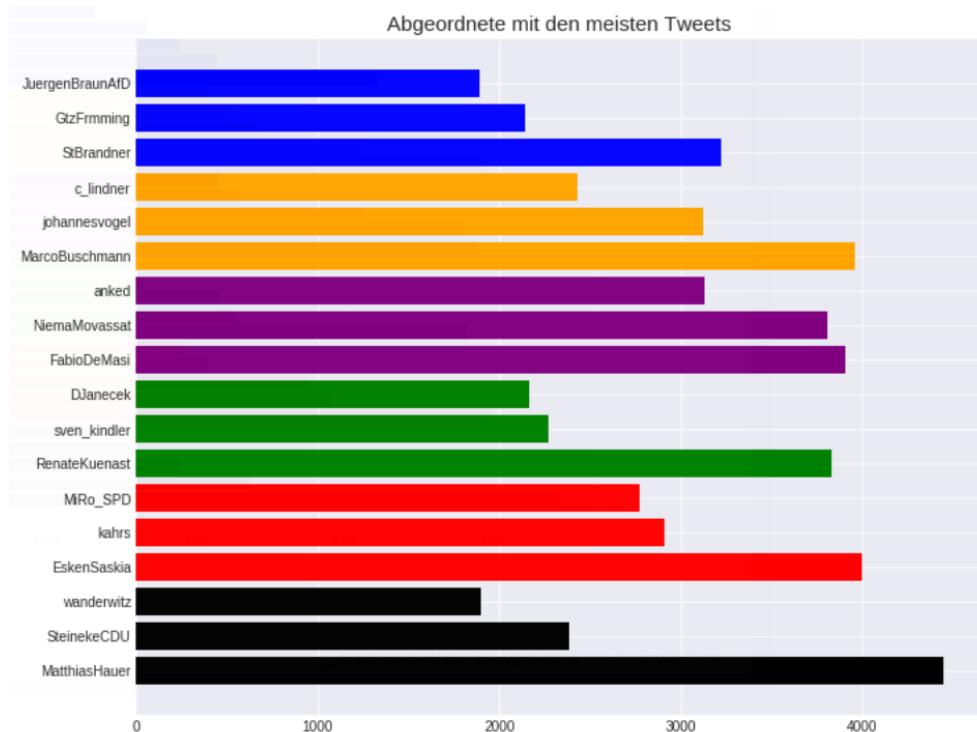


Abbildung 3.3: Abgeordnete mit den meisten Tweets im Zeitraum 05.19 - 05.20

Besonders viele Tweets gehen nicht notwendigerweise mit entsprechenden Ämtern einher, wie bereits in Kapitel 2.1.1 gezeigt wurde. Saskia Esken und Christian Lindner bilden hier Ausnahmen, in den anderen Parteien ist es nicht üblich, dass Parteivorsitzende oder Minister die meisten Tweets absetzen. Außerdem ist es auch möglich, dass die Kommunikation auf Twitter zu einem großen Teil ohne wichtige Inhalt auskommt. Besonders auffällig ist dies bei dem aus dem Parlament ausgeschiedenen Johannes Kahrs. Von den 2908 Tweets die er im beobachteten Zeitraum absetzte, waren über 800 Grüße. Die meisten folgten dem Muster: "fröhlicher gruss aus der sonnigen freien und hansestadt". Das direkte Gegenteil stellt sein Partekollege Karl Lauterbach dar, in dessen Tweets sich eine Vielzahl an wissenschaftlichen Inhalten zu den verschiedenen aktuellen Themen findet, und auch er kam auf 2086 Tweets im selben Zeitraum. Neben diesen Extremen, abwechslungsreiche, informative Tweets auf der einen und banale Wiederholung auf der anderen Seite, gibt es natürlich auch viele andere Arten von Inhalten. Im Kapitel 4 wird es insbesondere um solche gehen, die negative Emotionen übermitteln.



Abbildung 3.4: Wordclouds zur Europawahl - Zeitraum 20.-31.05.2019

Wie in Abbildung 3.2 bereits zu erkennen war, führen bestimmte Ereignisse zu vermehrter Aktivität auf Twitter. Eine einfache Art, um in der Menge von Tweets aus einem bestimmten Zeitraum einige Schlagwörter zu finden, sind Wordclouds. In Abbildung 3.4 wurde für jede Partei eine Wolke für den Zeitraum 20.05 bis 31.05.2019 erstellt. Besonders häufig kamen natürlich Begriffe wie "Europa" oder "Europawahl2019" vor. Sehr auffällig sind jedoch auch die Begriffe "rezomusik", "Rezo" und "Klimaschutz". Diese stehen alle im Zusammenhang mit dem am 18.05.2019 erschienenen Video "Die Zerstörung der CDU"<sup>11</sup> von Rezo. Da in diesem Video vorrangig auf die mangelhafte Politik der CDU im Bezug auf Klimaschutz eingegangen wurde, ist es nicht überraschend, dass diese Begriffe bei der Union einen prominenten Platz einnehmen. Die Bundestagsabgeordneten der SPD twitterten dagegen besonders viel über die Grundrente, da sie zur selben Zeit ein entsprechendes Finanzierungskonzept vorgelegt hatten.

<sup>11</sup> <https://www.youtube.com/watch?v=4Y1lZQsyuS0>

Auch mit der Einschränkung des Zeitraums auf 15 Monate kann bei der Vielzahl von Themen in dieser Arbeit nicht jedes im Detail dargestellt werden. Nach dieser ersten Auswahl wird im Kapitel 4 auf weitere eingegangen und gezeigt, wie sich die Sprache der Abgeordneten je nach Ereignis unterscheidet.

### 3.4 VERHALTEN IM PARLAMENT

Mit den Plenarprotokollen in XML Form kann eine Vielzahl von Fragestellungen untersucht werden. In diesem Kapitel geht es vorrangig um die gleichen Schwerpunkte, die auch von den SZ Autorinnen gesetzt wurden. Das bedeutet, dass der eigentliche Text einer Rede oder eines Zurufs noch nicht betrachtet wird. Es geht vorerst um die Reaktionen von Fraktionen während einer Rede, welche aus den Kommentaren herausgelesen wurden (siehe Kapitel 3.2). Der Zeitraum ist mit 2,5 Jahren in etwa fünf mal länger als in der SZ Studie. Bei einer Eingrenzung auf das selbe halbe Jahr konnten die SZ Ergebnisse relativ gut reproduziert werden.

Wie bereits in Kapitel 2.1.2 beschrieben wurde, ist Beifall das gängige Mittel, im Plenum Zustimmung zu signalisieren. Am häufigsten klatscht eine Partei immer dann, wenn die eigene Fraktion spricht. Besonders deutlich zu sehen ist dieser Zusammenhang in Abbildung 3.5, da in der Heatmap die Diagonale besonders dunkel hervortritt. Es ist nicht überraschend, dass in absoluten Zahlen die größten Fraktionen am meisten klatschen, da diese auch häufiger sprechen. Es wurde versucht, den Faktor der längeren Redezeit herauszufiltern, indem die absolute Häufigkeit mit der Partei x während den Reden von Fraktion y klatscht, durch die Anzahl an Wörtern von Fraktion y geteilt wurde. Da die Redezeit pro Rede nicht im Protokoll angegeben ist, wurde diese Methode als Näherung verwendet.

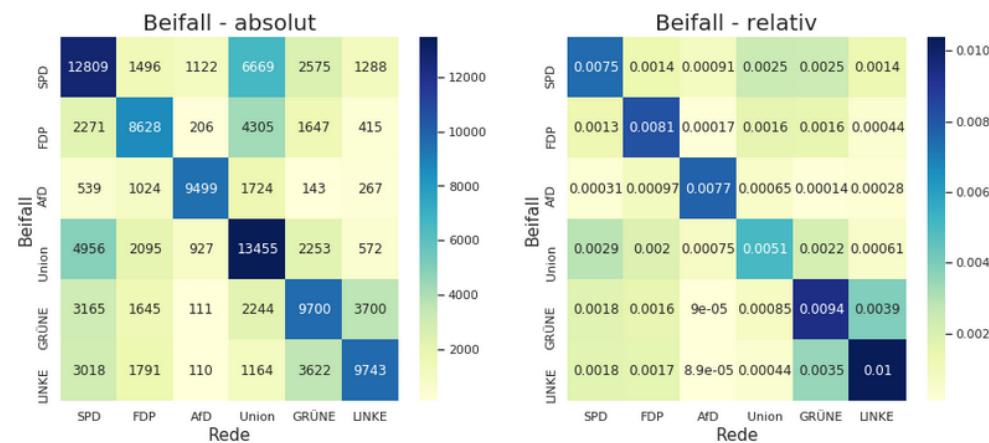


Abbildung 3.5: Absolute und relative Darstellung von Beifall zwischen Fraktionen

Betrachtet man nun die relativen Werte der Diagonale, so fällt auf, dass im Verhältnis zur Wortzahl die kleineren Fraktionen mehr klatschen - insbesondere Die Linke und das Bündnis 90/Die Grünen. Diese beiden spenden sich auch relativ häufig gegenseitig Beifall, ebenso wie die Koalitionspartner Union und SPD. Kaum Beifall anderer Parteien gibt es während Reden der AfD. Wenn tatsächlich einmal zum Beispiel die SPD klatscht, so meistens nur mit dem letzten Satz und somit bei der Verabschiedung des AfD Redners.

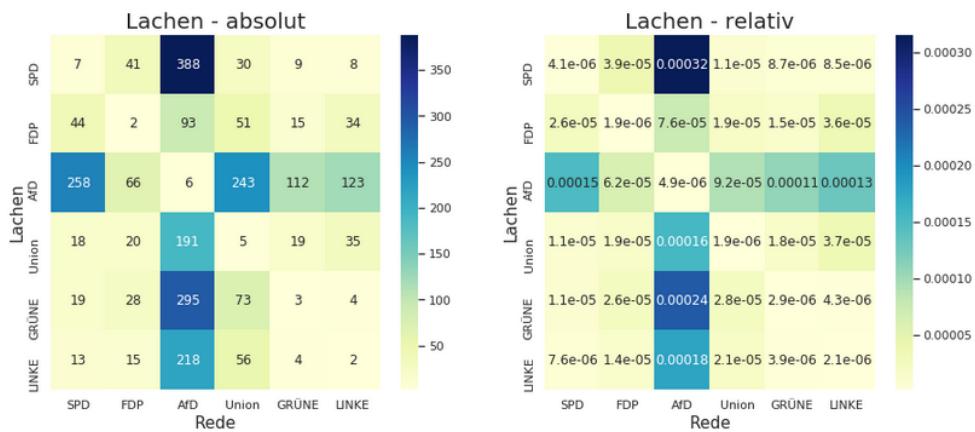


Abbildung 3.6: Absolute und relative Darstellung von Lachen zwischen Fraktionen

Die Abgrenzung der AfD wird besonders deutlich, wenn man sich die Heatmap einer weiteren Reaktion anschaut. So wie Beifall mit Zustimmung verbunden ist, zeigt Lachen Ablehnung gegenüber dem Gesagten. Es zeichnet sich deutlich ein Kreuz ab, mit einem Balken vertikal entlang der Reaktionen auf Reden der AfD und horizontal, wenn die AfD mit Lachen auf Reden der anderen Fraktionen reagiert. Am häufigsten setzt insgesamt die SPD dieses Mittel gegen die AfD ein.

Auch bei den weiteren Reaktionen ist deutlich erkennbar, dass die SPD am meisten Widerspruch (Appendix B.2) und Zurufe (Appendix B.1) gegen die AfD zu verzeichnen hat, noch vor dem Bündnis 90/Die Grünen. Auffällig bei allen drei Formen des Widerspruchs ist das relativ helle Quadrat zwischen FDP und AfD. Das steht nicht notwendigerweise für eine Annäherung zwischen den Parteien, jedoch scheint die FDP - im Verhältnis zur den anderen Parteien - relativ wenig Widerstand gegen die Aussagen der AfD zu leisten. Innerhalb des ersten halben Jahres war der Unterschied noch etwas weniger ausgeprägt (Appendix B.3), jedoch ist hier kein klarer Trend zu erkennen.

Über alle Reaktionsarten hinweg kann festgestellt werden, dass die Koalitionspartner in absoluten Zahlen am aktivsten sind. Die Redezeit wurde an dieser Stelle nicht mit eingerechnet, zur leichteren Interpretierbarkeit der Abbildung 3.7. Beifall ist eindeutig die häufigste Reaktion, wobei auch Zurufe in allen Fraktionen nicht selten sind. Heiterkeit und Widerspruch treten dagegen nur in Ausnahmen auf und Lachen ist zwar nicht häufig, wird jedoch verhältnismäßig oft von der AfD eingesetzt.

Die hier dargestellte Grafik eignet sich außerdem zum direkten Vergleich mit der Abbildung 2.5 aus der SZ. Dabei fällt auf, dass die AfD und das Bündnis 90/Die Grünen weniger aktiv sind als noch im ersten Halbjahr und die FDP etwas mehr Zurufe verzeichnet. Dieser Umstand gehört jedoch bereits zu den auffälligeren Unterschieden zwischen dem ersten halben Jahr und dem längeren Betrachtungszeitraum. Des weiteren ergaben sich keine nennenswerten Unterschiede bei den Ergebnissen der SZ und der eigenen Auswertung. Das war aufgrund der komplexen und eigenständigen Datensatzerstellung nicht selbstverständlich.<sup>12</sup>

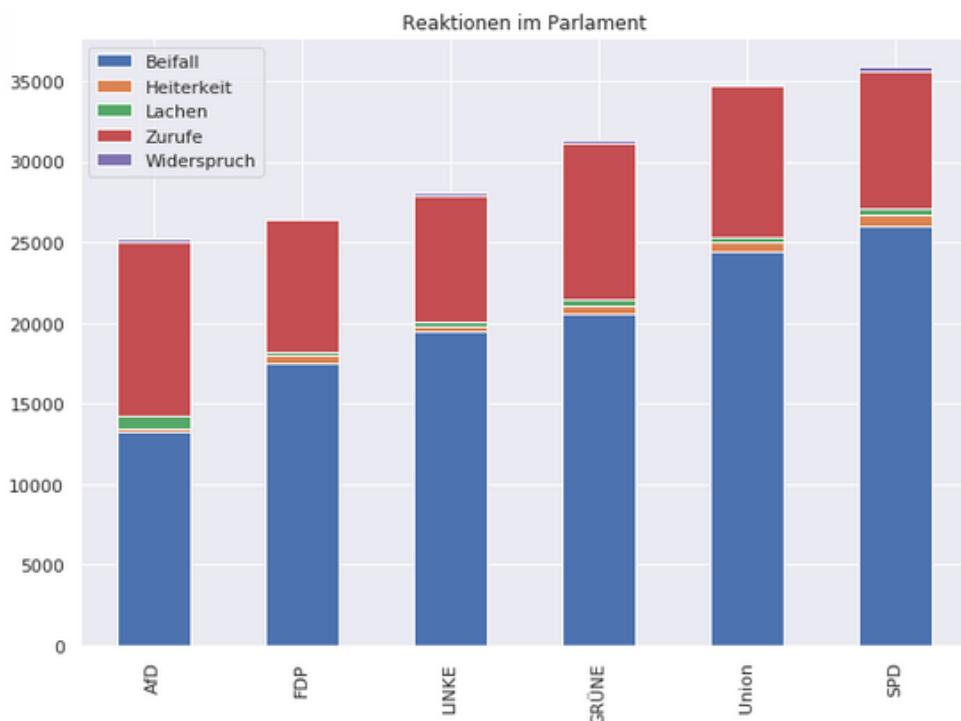


Abbildung 3.7: Absolute und relative Darstellung von Lachen zwischen Fraktionen

Während nach dem ersten halben Jahr der Abgeordnete Alexander Gauland (AfD) noch der Abgeordnete mit den meisten Zurufen im Parlament war, so hat dieses Engagement in den Monaten darauf nachgelassen. An der Spitze steht mit rund 2000 Zurufen nach 171 Sitzungen der Abgeordnete Matthias Birkwald (Die Linke), gefolgt von Michael Grosse-Brömer (CDU/CSU) mit ca. 1500 Zurufen, sowie Steffi Lemke (Bündnis 90/Die Grünen) und Ulli Nissen (SPD) mit jeweils ca. 1300 Zurufen. Jeder dieser Politiker\*innen gehörte auch im ersten halben Jahr bereits zu den Abgeordneten mit den meisten Zurufen.<sup>13</sup>

Während es bei den meisten Parteien eine klare Abgrenzung zwischen den

<sup>12</sup> Zum Vergleich mit Abbildung 2.5 ist Abbildung B.4 im Appendix aufgeführt. Sowie Abbildung B.5 zum Vergleich mit der Abbildung B.3

<sup>13</sup> In Abbildung 3.8 sind die häufigste Zurufer aus der bisherigen Legislaturperiode aufgeführt. Im Appendix B.6 und B.7 können zum Vergleich die Ergebnisse aus dem ersten halben Jahr eingesehen werden, sowie die Darstellung der SZ.

“Viel-Zurufern” und dem Rest gibt, so ist dies bei der AfD nicht der Fall. Hier rufen viele Abgeordnete relativ häufig rein, jedoch sticht keiner besonders hervor. Stephan Brandner, Jürgen Braun und Alexander Gauland haben alle drei jeweils ca 1000 Zurufe zu verzeichnen.

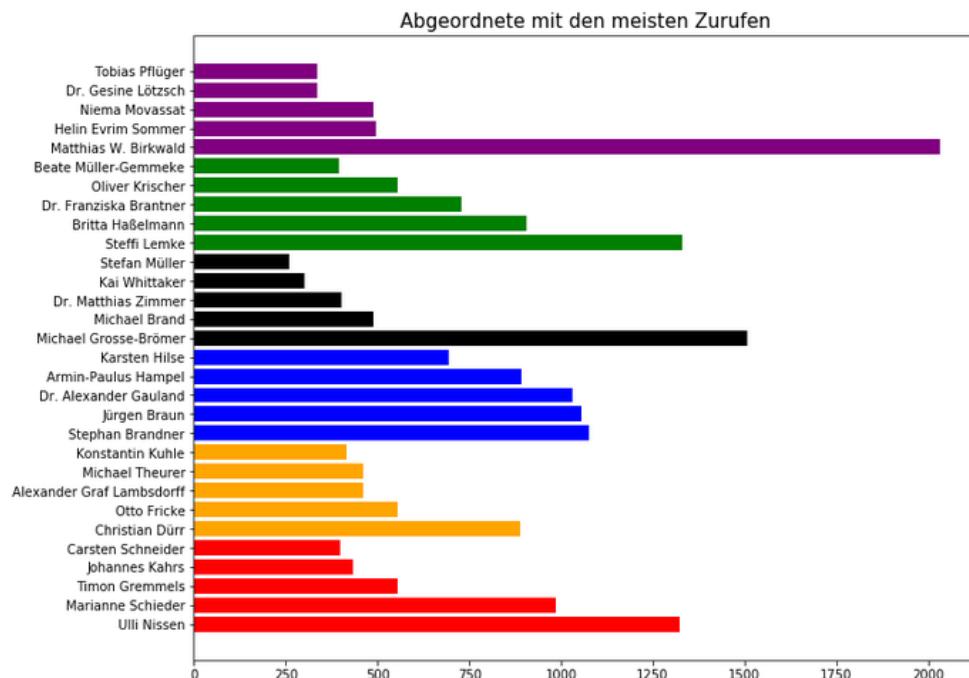


Abbildung 3.8: Abgeordneten mit den meisten Zurufen

Vergleicht man Zurufe im Plenum und Aktivität bei Twitter, so stellt man fest, dass es nicht notwendigerweise die selben Abgeordneten sind, die in beiden hervorstechen. Innerhalb der eigenen Partei gehören Niema Movassat (Die Linke), Johannes Kahrs (SPD), Stephan Brandner (AfD) und Jürgen Braun (AfD) jeweils sowohl zu den aktivsten Twitter-Nutzern als auch zu den Abgeordneten mit den meisten Zurufen. An dieser Stelle muss jedoch nochmal darauf hingewiesen werden, dass die reine Menge an Tweets noch nichts über die Reichweite aussagt. Wie in den Kapiteln 2.1.1 und 3.3 bereits erklärt wurde, sind es nicht unbedingt die allgemein bekannten Politiker\*innen, die besonders viel tweeten oder dazwischen rufen, und auch die Qualität der Inhalte unterscheidet sich stark zwischen den Abgeordneten.

# 4

## SENTIMENT ANALYSE

---

Nachdem in Kapitel 2.2 die hier verwendeten Methoden bereits kurz vorgestellt wurden, geht es in diesem Kapitel um die Anwendung auf die verwendeten Datensätze. Zunächst wird kurz übergreifend auf die drei Arten von Labeln eingegangen und anschließend in Unterkapiteln beschrieben, in welchen Schritten diese den Daten zugeordnet wurden.<sup>1</sup>

### 4.1 TRAINIEREN UND LABELN DER DATENSÄTZE

Die in diesem Kapitel beschriebenen Methoden haben die folgenden Dimensionen bzw. Label:

TEXTBLOB positive, neutral, negative

BASIC EMO Ekel, Freude, Furcht, Trauer, Überraschung, Verachtung, Wut

MACHINE LEARNING OFFENSE, OTHER

Insbesondere die Methode der Basis Emotionen unterscheidet sich sehr stark von den anderen beiden. Einem Tweet wird nicht genau eine der sechs Emotionen zugewiesen, sondern ein sechs-dimensionaler Vektor. Jede Dimension steht für eine Emotion, und die Zahl ist umso größer desto stärker diese ausgeprägt ist. Die Zuteilung der Label positiv, neutral oder negativ bzw. OFFENSE oder OTHER ist dagegen relativ ähnlich interpretierbar. In den meisten Fällen sollten dieselben Tweets, die als OFFENSE gelabelt wurden, auch als negativ interpretiert werden. Es gibt zwar theoretisch einen Unterschied zwischen "offensiven" bzw. beleidigenden Tweets und negativen, jedoch ist diese Grenze nicht immer eindeutig. Gerade wenn maschinelles Lernen eingesetzt wird, ist die Frage nach den korrekten Labeln entscheidend und manchmal auch von Menschen nicht eindeutig zu beantworten.

#### 4.1.1 Einfache Textverarbeitung mit TextBlob

Es wurden 244.471 Tweets und 54.117 Kommentare mit TextBlob analysiert. Das grundlegende Vorgehen war für beide Datensätze gleich. Säubern der Texte, Berechnen der Polarität mit dem Paket TextBlob und anschließend die Vergabe der Label positive, neutral oder negative auf Basis der Polarität. Wenn auf diese Art jedem Tweet ein Label zugeordnet wurde, kann man sich durch eine Pivot Tabelle einen ersten Überblick verschaffen. Für die gelabelten Tweets ist eine entsprechende Übersicht in Tabelle 4.1 abgebildet.

---

<sup>1</sup> Die Methoden sind Teil der Auswertung und auf GitHub abgelegt: [https://github.com/LisaStolz/kommunikation\\_bundestag/tree/master/06\\_Analyse](https://github.com/LisaStolz/kommunikation_bundestag/tree/master/06_Analyse)

PARTEI	NEGATIVE	NEUTRAL	POSITIVE
AFD	5927	13170	7778
FDP	7410	23321	16125
Gruene	5610	19511	14228
Linke	8448	19081	12662
SPD	5125	23480	18651
Union	4899	19397	15325

Tabelle 4.1: Ergebnisse einer Sentiment Analyse von Twitter Daten mit TextBlob

Wie in Kapitel 2.2 bereits erklärt wurde, ist Auswertung mit TextBlob sehr einfach umsetzbar, allerdings mit dem Nachteil, dass sich die Zusammensetzung des Polaritäts Scores nicht komplett nachvollziehen lässt. Das Gegen teil ist bei der Umsetzung der Einteilung in Basis Emotionen der Fall. Hier gibt es kein eigenes Paket in Python, und im folgenden Kapitel wird erklärt, mit welchen Schritten in dieser Arbeit die Emotions-Vektoren berechnet wurden.

#### 4.1.2 Lexika für sieben Basis Emotionen

Ausgangspunkt sind sieben Textdateien, jeweils nach einer Emotion benannt, die Wortlisten enthalten. In einer solchen Liste stehen untereinander Wörter, die der jeweiligen Dimension zugerechnet werden. In Tabelle 4.2 sind einige Basisinformationen zu diesen sieben Listen angegeben.

EMOTION	SUM	ANFANG DER LISTE
Wut	336	Aggression, Aggressivität, Amok, Anfall,...
Verachtung	2.138	Aasgeier, Aberwitz, Abgeschmacktheit, Abklatsch,...
Ekel	271	Aberration, Abfall, Abgeneigtheit, Abgeschmacktheit,...
Freude	555	Abschluss, Adventsfreude, Akklamation, Amusement,...
Angst	399	Abgrund, Abhauen, Abhängigkeit, Abreibung,...
Traurigkeit	657	Abbrechen, Abgeschlagenheit, Abgrund, Abschied,...
Überraschung	376	Achtung, Achtung!, Aha-Erlebnis, Ahaerlebnis,...

Tabelle 4.2: Zusammenfassung der deutschen Wörterlisten[46]

Ein Faktor, der sofort auffällt ist die Anzahl von Wörtern pro Liste (Spalte SUM). Diese kann mit einem Minimum von 271 und einem Maximum von 2.138 sehr unterschiedlich sein. Später in diesem Kapitel wird noch auf die beiden Arten eingegangen, die Ergebnisse ins Verhältnis zu setzen zu Tweetlänge und Anzahl von Tweets pro Partei. Es wurde auch erwogen, die Länge der Liste mit einzubeziehen, dies wurde jedoch verworfen. Es kommt viel

mehr auf die "Qualität" der Wörter in einer Liste an, als auf die reine Anzahl. In den Ergebnissen ist beispielsweise zu sehen, dass der Wert für Verachtung nicht automatisch dreimal so hoch ist wie die Werte anderer Dimensionen. Statt eine weitere Normalisierung der Ergebnisse vorzunehmen, sollte lediglich bei der Interpretation im Hinterkopf behalten werden, dass zum Beispiel Ekel und Wut nur verhältnismäßig wenig Wörter zum Abgleich bieten.

Für die Umsetzung in Python wurde die Arbeit von Rafferty als Vorlage genutzt.<sup>[25]</sup> Er hatte die englischen Harry Potter Bücher analysiert und seinen Python Code auf GitHub veröffentlicht.<sup>2</sup> Sowohl der zu analysierende Text, als auch die zum Abgleich genutzten Wörterlisten werden zunächst bearbeitet. Hierfür wurde der deutsche SnowballStemmer verwendet um die Wörter besser vergleichbar zu machen. Neben dieser Reduzierung auf eine Basisform und kleingeschriebene Wörter, kann die Analyse der Basis Emotionen in drei Schritte unterteilt werden:

#### 1.) EMOTIOMSMATRIX ERSTELLEN :

Jedes Wort aus einer der sieben Wortlisten entspricht einer Zeile und jede Liste einer Spalte. (siehe Abbildung 4.1) Wenn ein Wort in einer Liste vorkommt, ist der entsprechende Wert in dieser Spalte eins und andernfalls Null. Wörter können in mehreren Wortlisten vorkommen, und in dieser Zeile gibt es entsprechend mehr als eine eins.

	Ekel	Freude	Furcht	Trauer	Ueberraschung	Verachtung	Wut
aalglatt	0	0	0	0	0	1	0
aasgel	0	0	0	0	0	1	0
abbrech	0	0	0	1	0	0	0

Abbildung 4.1: Emotionsmatrix aus Nullen und Einsen

#### 2.) EMOTIOMSMATRIX ANWENDEN :

Jeder Tweet entspricht einer Zeile, die Spalten sind wie in der zuvor erstellten Emotionsmatrix die sieben Emotionen.(siehe Abbildung 4.2) Wenn ein Wort aus dem Tweet in der Matrix vorkommt, werden die entsprechenden Spalten um eins erhöht.

	full_text_processed	Ekel	Freude	Furcht	Trauer	Ueberraschung	Verachtung	Wut
0	fordern wir schon lange endlich bewegen sich auch die altparteien atdwirkt	0	1	0	0	0	0	0
1	von wegen einthemenpartei atd hier eine kleine auswahl allein von demwas ich so angestoßen habehinzukommen noch 88 weitere mdb-kollegen zwei dutzend arbeitskreisdie karten gibt's bei den fraktionsveranstaltungenzbb bigadwirkt berlin bundestag brandner	0	0	0	0	0	0	0
2	leipzig mutter 37 stirbt nach attacke auf sich und ihr baby	0	1	1	0	0	0	1

Abbildung 4.2: Matrix aufsummierten Emotionswerten für jeden Tweet

#### 3.) ERGEBNISSE INS VERHÄLTNIS SETZEN ZU TWEETLÄNGE UND -HÄUFIGKEIT

Da in längeren Tweets potenziell mehr Wörter aus der Emotionsmatrix stehen - der Tweet jedoch deshalb nicht automatisch entsprechend

<sup>2</sup> [https://github.com/raffg/harry\\_potter\\_nlp](https://github.com/raffg/harry_potter_nlp)

emotionaler sein muss - wird der Vektor jedes Tweets durch den eigenen Wortcount geteilt. (siehe Abbildung 4.3) Je nach Darstellung kann es außerdem sinnvoll sein, das gleiche Vorgehen mit der Gesamtzahl an Tweets pro Partei zu wiederholen.

	full_text_processed	Ekel	Freude	Furcht	Trauer	Ueberraschung	Verachtung	Wut
0	fordern wir schon lange endlich bewegen sich a...	0.0	0.090909	0.000000	0.0	0.0	0.0	0.000000
1	von wegen einthemenpartei afd hier eine kleine...	0.0	0.000000	0.000000	0.0	0.0	0.0	0.000000
2	leipzig mutter 37 stirbt nach attacke auf sich...	0.0	0.090909	0.090909	0.0	0.0	0.0	0.090909

Abbildung 4.3: Durch Tweetlänge relativierte Ergebnisse

#### 4.1.3 Feature Extraction und Prediction

Die Klassifizierung mit einem lernenden Verfahren verspricht die besten Ergebnisse, ist jedoch auch entsprechend komplex und schwerer nachzuvollziehen. Im Gegensatz zu den bisher präsentierten lexikonbasierten Verfahren, werden so viele Faktoren mit einbezogen, dass eine bildliche oder tabellarische Darstellung nicht mehr möglich ist. Im Folgenden wird versucht zu erklären, wie die in Kapitel 2.2 bereits kurz beschrieben Schritte im Code der TUWien umgesetzt wurden.[41] Anschließend wird gezeigt, wie gut diese Methode auf Basis der Daten von GermEval abgeschnitten hat, und welche Verbesserungen unternommen wurden.

##### 4.1.3.1 Training und Vorhersage

Sowohl Trainings- als auch Testdatensatz durchlaufen jede Stufe der Feature Extraction. Für diese Arbeit wurden Trainingsdaten und Testdaten von GermEval zusammengefügt und als Trainingsdatensatz verwendet (8541 Tweets). Außerdem wurden 1802 Tweets selbst gelabelt und 802 davon zufällig für den Test ausgewählt. Nach einer kurzen Bearbeitung (Sonderzeichen entfernen, nur Kleinbuchstaben) durchlaufen diese Daten die folgenden Schritte in der Feature Extraction:

###### TNGR - TOKEN N-GRAMME :

Mit der Funktion "token\_vect" werden n-Gramme mit 1-3 Wörtern erstellt. Bei dem hier verwendeten Trainingsdatensatz von 8541 Tweets führt dies zu 31082 n-Grammen. In einer Matrix kann man sich jedes n-Gramm als Spalte und jeden Tweet als Zeile vorstellen:

X\_TNGR\_test: (802, 31082)

X\_TNGR\_train: (8541, 31082)

###### CNGR - CHARACTER N-GRAMME :

Analog zu TNGR werden mit der Funktion "char\_vect" n-Gramme mit

3-7 Buchstaben erstellt.

X\_CNGR\_test: (802, 286641)

X\_CNGR\_train: (8541, 286641)

#### EMB - WORD EMBEDINGS :

Es wird das vortrainierte Word2Vec Model von Josef Ruppenhofer verwendet.<sup>3</sup> Dieses wurde auf Basis von deutschen Tweets aus den Jahren 2013-2017 trainiert, hat 100 Dimensionen und eine window size von 5. Das heißt, dass während des Trainings zwei Begriffe vor, und zwei nach dem betrachteten Wort mit einbezogen wurden - in einem "Fenster" finden sich demnach fünf Wörter. Jeder Token bzw. jedes Wort in diesem Word2Vec Model ist in einen 100-dimensionalen Raum eingebettet. In diesem Raum kann es anderen Wörtern mit ähnlicher Bedeutung sehr nah sein. Wörter, die auf bestimmten Dimensionen genau das Gegenteil bedeuten (z.B. männlich - weiblich), wären auf diesen "Achsen" entsprechend weit entfernt.<sup>4</sup>

Für die Anwendung auf die im ersten Schritt erstellten Tokens bedeutet dies, dass für jeden Tweet die Werte der in ihm enthaltenen Tokens im Word2Vec Model ermittelt werden. Um dem gesamten Tweet ein Embedding zuzuweisen, werden die Werte mit der Anzahl an Tokens normalisiert, sodass der gesamte Tweet nun ebenfalls in dem 100-dimensionalen Raum verortet ist.

Wenn ein Token des Tweets nicht im Model zu finden ist, wird der Token in Präfix und Suffix aufgeteilt und das Model darauf geprüft.

X\_EMB\_test: (802, 100)

X\_EMB\_train: (8541, 100)

#### TIMP - IMPORTANT TOKEN :

In diesem Schritt werden die k wichtigsten Token innerhalb der jeweiligen Kategorie (OFFENSE, OTHER) identifiziert. Ob ein Token "wichtig" ist, entscheidet der TFIDF Score. Anschließend wird dieser Token im Word2Vec gesucht und mittels der Kosinus-Ähnlichkeit mit den anderen Token im Tweet verglichen. Diese entspricht dem Kosinus des Winkels zwischen den beiden Vektoren und gibt somit an, ob diese annähernd in die gleiche Richtung zeigen.<sup>[33]</sup> Dadurch erhält man für jeden wichtigen Token in einem Tweet eine minimale und eine maximale Ähnlichkeit. Bei k = 1250 wichtigen Tokens \* 2 Kategorien (OTHER, OFFENSE) \* 2 Kosinus-Ähnlichkeiten (min, max), ergibt das 5000 Features pro Tweet.

X\_TIMP\_task1\_test: (802, 5000)

X\_TIMP\_task1\_train: (8541, 5000)

---

<sup>3</sup> [https://www.cl.uni-heidelberg.de/english/research/downloads/resource\\_pages/GermanTwitterEmbeddings/GermanTwitterEmbeddings\\_data.shtml](https://www.cl.uni-heidelberg.de/english/research/downloads/resource_pages/GermanTwitterEmbeddings/GermanTwitterEmbeddings_data.shtml)

<sup>4</sup> Eine sehr gute Erklärung zur bildlichen Vorstellung von Word2Vec Modellen und Begriffen wie window size, findet sich hier: <https://medium.com/@jayeshbahire/introduction-to-word-vectors-ea1d4e4b84bf>

**CIMP - IMPORTANT CHARACTER :**

Für die wichtigen Buchstaben Kombinationen ist das Vorgehen sehr ähnlich zu dem unter TIMP beschriebenen Schritten. Allerdings sind keine entsprechenden Ausdrücke im Word2Vec Model zu finden, und daher wird statt einer Einbettung in einen Vektorraum auf eine boolesche Variable zurückgegriffen. Diese gibt an, ob eine wichtige Buchstabenkombination in einem Tweet enthalten ist oder nicht. Bei  $k = 3200 * 2$  Kategorien (OTHER, OFFENSE), ergibt das 6400 Feature pro Tweet.

X\_CIMP\_task1\_test: (802, 6400)  
X\_CIMP\_task1\_train: (8541, 6400)

Im Anschluss an die Feature Extraction folgen die drei "Basis Klassifikationen". Dabei durchläuft jede der zuvor bestimmten fünf Feature Gruppen, jede der drei folgenden Methoden:

- **MaxEnt model**(Logistische Regression)
- **Random Forest Ensemble** (ExtraTreesClassifier - Information Gain Splits)
- **Random Forest Ensemble** (ExtraTreesClassifier - Gini-Impurity Splits)

Für den ExtraTreesClassifier wurden 100 Schätzer verwendet und daraus resultieren  $5 * 3$  verschiedene "Basis Klassifikationen". Jeder dieser 15 Klassifikator wurde auf 90% der Trainingsdaten trainiert und eine Vorhersage für die übrigen 10% gemacht. Dieser Prozess wurde zehn mal in Form eines Kreuzvalidierungsverfahrens wiederholt um für den ganzen Datensatz Vorhersagen zu erhalten. Um die Ergebnisse zu erhärten wurde der Vorgang zehn mal mit verschiedenen random seeds wiederholt. Bei 15 Klassifikatoren für jeden Tweet und jede Kategorie ergibt sich folgende Form der Meta Klassifikatoren:

X\_META\_task1\_train: (8541, 30)  
X\_META\_task1\_mdp: (802, 30)

Abschließend wird auf Basis der Meta Features des Trainingsdatensatzes, sowie der bekannten wahren Label für jeden Tweet, das **maximum entropy model (LogisticRegression)** gefittet. Mit diesem Model werden für die Testdaten die finalen Vorhersagen getroffen.

#### *4.1.3.2 Evaluierung und Anpassungen des Trainingsdatensatzes*

Zu Beginn der Klassifizierung wurde nur der Trainingsdatensatz von GermEval verwendet, um das Model zu trainieren und Vorhersagen zu treffen. Erst später wurden Trainings- und Testdaten zusammengefasst und auf dieser Basis Label für die Tweets zwischen Mai 2019 und Juli 2020 noch einmal vergeben. Besonders interessant waren die Tweets, die unterschiedlich gelabelt wurden, insbesondere weil mehr Trainingsdaten nicht automatisch zu besseren Ergebnissen führten.

Aus diesem Grund wurden 700 Tweets aus dem Zeitraum Januar und Februar 2020, die sich in ihren Labels unterschieden in eine csv Datei geladen, um

diese manuell zu labeln. In dieser Auswahl war der Anteil der mit OFFENSE gelabelten Tweets bei ca 50%. Um ein ähnliches Verhältnis von OFFENSE-Tweets zu OTHER-Tweets zu behalten wie im GermEval Datensatz (30%), wurden weitere Tweets hinzugefügt (1000 \* OTHER, 100 \* OFFENSE). Die zusätzlichen Tweets entsprachen "einfachen" bzw. "eindeutigen" Kategorien, da sie in beiden Durchgängen gleich gelabelt wurden. Aus diesem Grund wurden auch 100 weitere OFFENSE-Tweets mit aufgenommen, um nicht nur uneindeutige Trainingsdaten hinzuzufügen.

Durch die gelabelten Tweets aus dem eigenen Datensatz ist auch eine Evaluierung der Ergebnisse möglich geworden. Dabei wurde zum einen überprüft, wie gut die Vorhersage mit dem ergänzten Datensatz ist und zum anderen getestet, ob diese besser ist als nur den kombinierten GermEval Trainings- und Testdatensatz zu verwenden.

Von den 1802 selbst gelabelten Tweets wurden 802 zufällig ausgewählt und als Testdatensatz deklariert. Der erste Trainingsdatensatz war der kombinierte GermEval Datensatz und der zweite Trainingsdatensatz enthielt zusätzlich die 1000 selbst gelabelten Tweets. In Tabelle 4.3 ist zu sehen, dass der um 1000 Tweets ergänzte Datensatz zu besseren Ergebnissen führt.

EVALUIERUNG	TRAINING 1	TRAINING 2
Accuracy:	0.746883	0.807980
Precision_OFFENSE:	0.606061	0.693617
Precision_OTHER:	0.793046	0.855379
Recall_OFFENSE:	0.489796	0.665306
Recall_OTHER:	0.859964	0.870736
F1 score_OFFENSE:	0.541761	0.679167
F1 score_OTHER:	0.825151	0.862989

Tabelle 4.3: Evaluierung der Vorhersagen nach dem Vorgehen der TUWien

Mit 80% richtig gelabelten Tweets, ist die Accuracy verhältnismäßig gut. Durch die Unterscheidung der Evaluierung in OFFENSE und OTHER, ist zu erkennen, dass die Vorhersagen der seltener vertretenen Kategorie OFFENSE schlechter ausfallen. Precision, Recall und der F1 Score sind alle schlechter für die OFFENSE Label. Jedoch haben gerade hier die zusätzlichen Trainingsdaten zu besseren Ergebnissen geführt. So stieg beispielsweise der F1 Score der Kategorie OFFENSE von 0.54 auf 0.68.

#### 4.1.4 Vergleich der Methoden anhand von Ergebnisübersichten

Die in diesem Kapitel vorgestellten Methoden unterscheiden sich wie bereits erwähnt auf verschiedene Weise. Während sich die Qualität der lexikonbasierten Verfahren nur schwer kontrollieren lässt, hat das maschinelle Lernverfahren der TUWien nachweislich gute Ergebnisse erzielt. Entscheidend

für die Interpretation sind außerdem die sehr unterschiedlichen Label und Dimensionen. Auf diese soll in diesem Abschnitt eingegangen werden, indem für jedes Verfahren die Ergebnisse über den betrachteten Zeitraum von 15 Monaten betrachtet werden. Am Ende dieses Kapitels wird auf Basis dieser ersten Übersichten erklärt, wie im folgenden Kapitel die Ergebnisse im Detail dargestellt werden und welche Schwerpunkte dabei gesetzt werden.

In Abbildung 4.4 sind die Ergebnisse der Methode TextBlob dargestellt. Wie auch bei den beiden anderen Ansätzen, entspricht jeder Graf einer Kategorie und jede Linie einer Partei. Die Farbe wurden zur leichteren Lesbarkeit analog der bekannten Parteifarben vergeben.

Die x-Achse bildet die Kalenderwochen ab und die y-Achse die absoluten Werte, wie häufig in der jeweiligen Woche positive/negative/neutrale Tweets von einer bestimmten Partei abgesetzt wurden. Die Darstellung von absoluten Zahlen ist in diesem Fall aussagekräftiger als die von relativen, da mit den drei abgebildeten Kategorien alle Tweets abgedeckt sind. Würde nur eine Kategorie gezeigt werden, könnten steigende Zahlen auch mit allgemein mehr Tweets in der Partei zusammenhängen und relative Werte wären potenziell die bessere Wahl. Allerdings lässt sich in diesem Fall keine Aussage mehr über die gesamte Zahl an Tweets treffen, und die Effekte sind schwerer zu interpretieren.

Wichtig ist jedoch der Hinweis, dass in der Abbildung 4.4 die Achsenabschnitte nicht gleich gewählt wurden. Im betrachteten Zeitraum gab es deutlich weniger negative Tweets als positive und neutrale. Damit die dargestellten Kurven nicht am unteren Rand des Grafens verschwinden, wurde die y-Achse jedoch nicht auf den Abschnitt 0 bis 1000 beschränkt sondern auf 0 bis 250.

Wie auch in Tabelle 3.2 bereits ersichtlich war, fällt auf, dass die AfD insgesamt weniger tweetet als andere Parteien. Das liegt nicht daran, dass weniger AfD Mitglieder\*innen einen Account haben, sondern daran, dass pro User\*in weniger geschrieben wird. Mit 379 Tweets pro User\*in war es im betrachteten Zeitraum fast halb soviel wie bei Abgeordneten der Linken (705). In Abbildung 4.4, wie auch in vielen folgenden Darstellungen, wurde die blaue Linie der AfD Tweets hervorgehoben. Es wird deutlich, dass die AfD zwar weniger tweetet als andere Parteien, jedoch ähnlich häufig negativ ge-labelte Tweets zugeordnet bekommt.

Auf drei weitere Auffälligkeiten soll an dieser Stelle eingegangen werden. Die Delle zum Jahreswechsel begründet sich nicht daraus, dass zu dieser ruhigen Zeit weniger getweetet wurde. Tatsächlich wird in der Detailbetrachtung noch auf diesen Zeitraum eingegangen, da sowohl die Ausstrahlung eines umstrittenen Kinderliedes durch den WDR, als auch Ausschreitungen in Leipzig in der Silvesternacht zu mehr Aktivität auf Twitter geführt haben. Die Delle begründet sich aus der Einteilung der Kalenderwochen. Die KW52 2019 hat in dieser Darstellung nur drei Tage und die erste KW 2020 ist die KW00 mit vier Tagen. Beide Wochen umfassen demnach weniger Tage und

folglich auch weniger Tweets als andere.

Bei den positiven und neutralen Tweets fällt gerade während der Zeit des Corona Lockdowns eine erhöhte Aktivität bei der SPD ins Auge. Allerdings liegt das nicht (nur) daran, dass der bereits erwähnte Karl Lauterbach in dieser Zeit besonders viele Tweets über medizinische Studien veröffentlichte. Aus den Wordclouds im Appendix B.3 aus dieser Zeit fällt auf, dass die SPD die einzige Partei ist, bei der nicht "corona" und "coronakrise" die Tweets beherrschten. Die ebenfalls bereits in Kapitel 3.3 erwähnten Gruß-Tweets von Johannes Kahrs lassen sich alle 806 März und April 2020 zuordnen. Da er im Mai versuchte Wehrbeauftragter zu werden, liegt die Vermutung nahe, dass er in dieser Zeit das Ziel hatte mehr Öffentlichkeit für seine Person zu schaffen. Schließlich legte er am 05.05.2020 sein Amt als Bundestagsabgeordneter nieder, das er seit 1998 inne hatte und löschte auch seinen Twitter Account.[75]

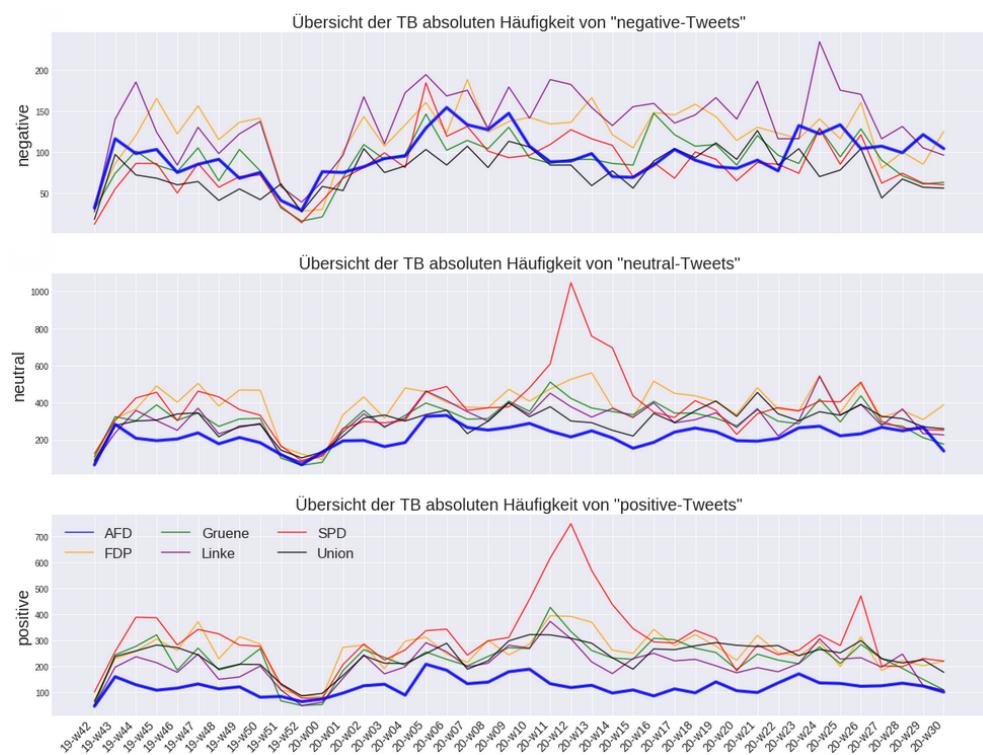


Abbildung 4.4: Übersicht der mit TextBlob gelabelten Ergebnisse

Eine letzte Auffälligkeit ist die Spitze an negativen Tweets der Partei Die Linke in der Woche 24. Dies hängt mit gleich zwei Ereignissen zusammen, die besonders im linken Spektrum für Entrüstung sorgten. Zum einen wurde am 25.05.2020 der Amerikaner George Floyd durch einen Polizisten ermordet, was zum Auslöser landesweiter Proteste wurde. Im Zuge dessen rief Trump per Twitter dazu auf, die Antifa in den USA als Terrororganisation einstufen zu lassen.[42] Dies nahmen viele Politiker\*innen und Twitternutzer\*innen zum Anlass sich selbst als eben solche "Antifaschisten" zu bezeichnen und sich gegen Rassismus auszusprechen.

Das zweite Ereignis im Juni 2020 war die Insolvenz von Wirecard, nachdem der Vorstand zugeben musste, dass Bankguthaben auf asiatischen Treuhandkonten in Höhe von mehr als 1,9 Milliarden Euro nicht existierten. Der Fall war besonders aufgeladen, weil bereits 2016 auf Unstimmigkeiten in der Buchhaltung von Wirecard hingewiesen wurde und die BaFin daraufhin ein Untersuchungsverfahren gegen die anonyme Gruppe Zatarra einleitete.[76] Gerade über die Rolle der BaFin und der Wirtschaftsprüfung von EY wurde in den Tagen darauf viel geschrieben.

Die zweite Übersicht, die in diesem Kapitel betrachtet wird, ist in Abbildung 4.5 dargestellt. Es handelt sich um die Ergebnisse der Methode Basis Emotionen und zeigt demnach die sieben beschriebenen Dimensionen jeweils mit einer Grafik. Die einzigen nicht negativ konnotierten Emotionen sind Freude und Überraschung. Dies ist besonders auffällig weil die hervorgehobene Linie der AfD in genau diesen Grafiken durchgehend unter den anderen Parteien bleibt.

Die y-Achse wurde wie schon bei der zuvor beschriebenen Methode nicht normalisiert und man erkennt, dass gerade "Ekel" nicht besonders oft in den Tweets erkannt wurde - was sich auch auf die geringe Anzahl von Wörtern in dieser Liste zurückführen lässt. Des Weiteren sind die Ergebnisse nach Anwendung der Emotionsmatrix zwar mit der jeweiligen Wortanzahl des Tweets normalisiert, jedoch nicht mit allen Tweets einer Partei. Dies folgt der gleichen Logik wie im Falle der TextBlob Ergebnisse - da alle Kategorien und somit alle Tweets in der Abbildung zu sehen sind, ist es für die Interpretierbarkeit besser, die absoluten Werte anzuzeigen. Die x-Achse ist in Monate unterteilt und nicht wie zuvor in Wochen, um die Lesbarkeit der kleineren Grafen zu erhalten.

Die zuvor beschriebenen Events lassen sich auch in diesen Ergebnissen ablesen. In der Dimension "Freude" ist deutlich der Zacken der SPD, im März 2020 erkennbar. Bei den Tweets von Johannes Kahrs ist es nicht überraschend, dass die Vektoren in dieser Dimension besonders hohe Zahlen erreichten. Die Kategorien "Wut" und "Verachtung" sind bei der Linken besonders ausgeprägt und in beiden lässt sich auch der Knick bzw. Anstieg im Juni 2020 erkennen. Die bereits beschriebenen Events (Wirecard und BLM Proteste in den USA) sind jedoch nicht die größten Ausschläge in den Basis Emotionen.

In allen negativen Dimensionen lassen sich zwei Höcker erkennen. Ein etwas kleinerer im Oktober/November 2019 und ein größerer Ausschlag im Februar 2020. Erneut kann man anhand der Wordclouds vermuten welche Themen in dieser Zeit die Tweets der Politiker dominiert haben.

Im Oktober und November waren es potenziell verschiedene Events. Bei den Grünen beherrschte nach dem Skandal um die Ausländer Maut und Intransparenz bei der Aufarbeitung, Andreas Scheuer die Tweets (siehe Abbildung B.13).[23]. Die Linke konzentrierte sich auf die Militäroffensive Erdogans im Norden Syriens (siehe Abbildung B.14).[63][48] Zwar nicht so dominant wie andere Themen, jedoch in jeder Partei vertreten war das Wort "halle", das

sich auf einen Anschlag bezieht, der am 09.10.2019 auf eine Synagoge in Halle verübt werden sollte. Nachdem der Täter mit seinem eigentlichen Plan an der Tür der Synagoge gescheitert war, erschoss er zwei Menschen.[8]

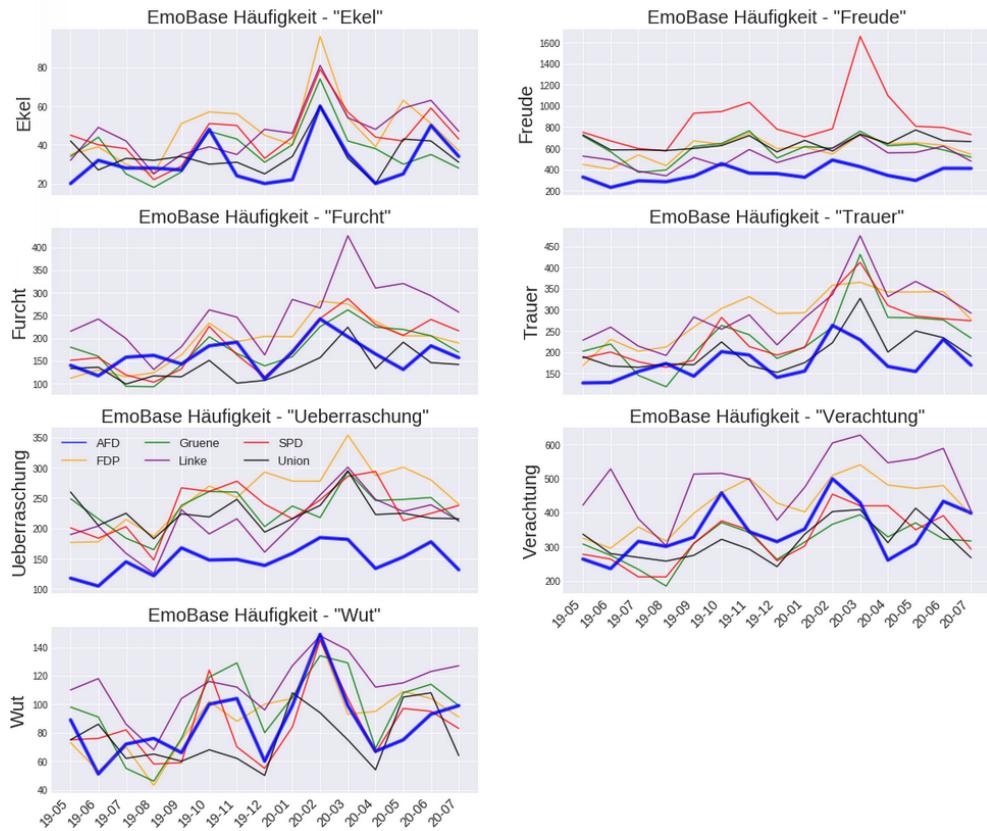


Abbildung 4.5: Übersicht der mit Basic Emotions gelabelten Ergebnisse

Das Thema das im Oktober 2019 noch nicht in allen Wordclouds vorhanden war, jedoch im Februar 2020 die Tweets der Politiker\*innen beherrschte, war die Wahl in Thüringen.[58][62] Nachdem im Oktober die Landtagswahl stattgefunden hatte, kam es im Februar bei der Wahl des Ministerpräsidenten zur Regierungskrise. Im Februar 2020 wurde außerdem der Anschlag in Hanau verübt bei dem zehn Menschen starben.[27] In Halle wie in Hanau hatten die Täter ein von Verschwörungstheorien geprägtes Weltbild. Beide Themen werden bei der Detailanalyse in den Kapiteln 4.2.2.1 und 4.2.2.2, genauer untersucht und dargestellt, da sie einen Einblick erlauben, welche Themen, in welchen Parteien, wie viel Aufmerksamkeit bekommen.

Die Ergebnisse der dritten und letzten Methode werden an dieser Stelle nur sehr kurz dargestellt, um sie mit den ersten beiden zu vergleichen. Da im Laufe der Arbeit deutlich wurde, dass der Ansatz des Machine Learning die verlässlichsten Ergebnisse liefert, wird dieser Ansatz im folgenden Kapitel für die detaillierte Analyse und die Überprüfung der zentralen Hypothesen dieser Arbeit herangezogen. In den Abbildungen B.9 und B.10 ist eine zu-

fällige Auswahl an Tweets mit den entsprechenden Labeln zu sehen. Aus ihnen wird ersichtlich, dass je nach Tweet jede Methode manchmal schlecht abschneidet. Über eine Vielzahl an Tweets hinweg fällt jedoch auf, dass die grobe Unterscheidung in OTHER und OFFENSE robuster zu sein scheint.

In Abbildung 4.6 gelten die gleichen Hinweise wie zuvor. Es handelt sich um die absolute Anzahl von Tweets pro Woche und pro Partei, da die beiden Kategorien (OTHER und OFFENSE) dargestellt wurden. Die x-Achse bildet die Wochen im betrachteten Zeitraum ab und es wurde nicht der selbe Bereich der y-Achse für beide Grafen gewählt. Beides dient einer besseren Lesbarkeit, sollte jedoch bei der Interpretation im Hinterkopf behalten werden. Die Beobachtungen aus den ersten beiden Abbildungen finden sich auch in dieser. Sowohl die Spitze an OTHER Tweets der SPD (Johannes Kahrs), als auch das erhöhte Aufkommen negativer Tweets im Februar (MP Wahl in Thüringen und Hanau). Die etwas kleinere Spitze an negativen Tweets der Linken in der Woche 24 ist ebenfalls zu erkennen (Anti Rassismus Demonstrationen und Wirecard). Besonders deutlich ist außerdem die Tendenz, dass die AfD über die Zeit hinweg immer die meisten OFFENSE Tweets veröffentlicht und das bei den wenigsten Tweets die als OTHER gelabelt wurden.

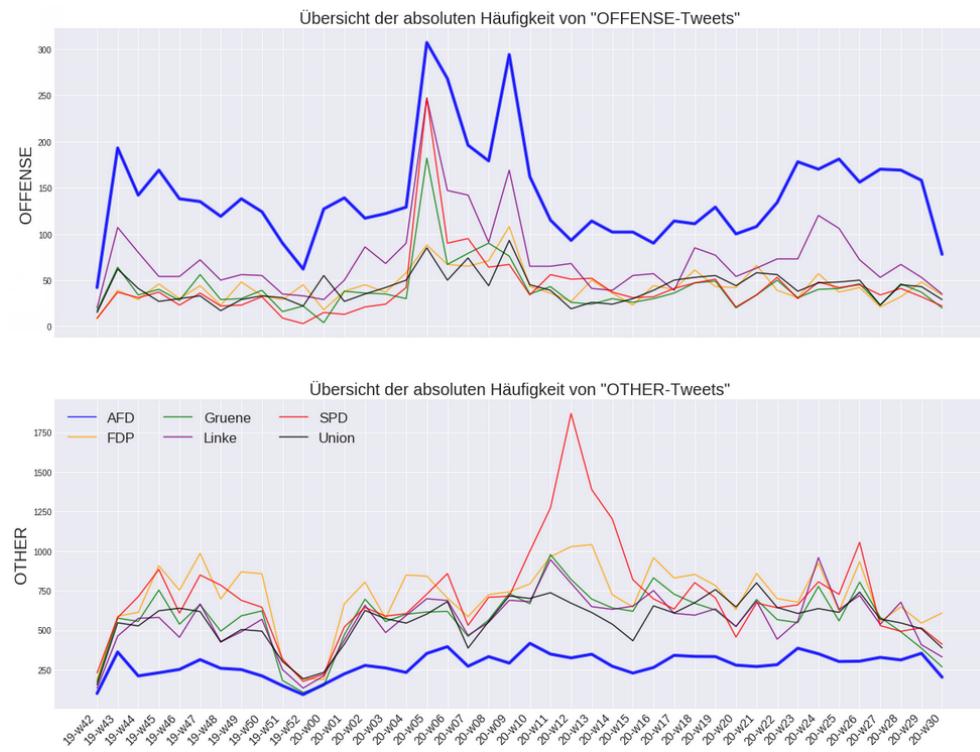


Abbildung 4.6: Übersicht der mit GermEval-TUWien gelabelten Ergebnisse

Die Gegenüberstellung der Ergebnisse aus drei verschiedenen Methoden hat gezeigt, dass trotz der sehr unterschiedlichen Herangehensweisen, die aggregierten Resultate in ähnliche Richtungen weisen. Auch wenn die Lexikonbasierten Verfahren mehr Label bzw. Dimensionen aufweisen, sie lassen sich

relativ gut auf die Label OFFENSE und OTHER übertragen. Da eine grobe Unterteilung in nur zwei Klassen für die zu überprüfenden Hypothesen ausreicht und weniger fehleranfällig zu sein scheint, werden im folgenden Kapitel nur noch die Ergebnisse des maschinellen Lernens verwendet.

## 4.2 ERGEBNISSE DER SENTIMENT ANALYSE

In diesem Kapitel werden die zentralen Ergebnisse der Sentiment Analyse von Twitter- und Plenardaten dargestellt. Dies umfasst zum einen die qualitative Beschreibung anhand von Grafiken und die Fokussierung auf bestimmte Themencluster, sowie Zeitabschnitte. Zum anderen werden zu Beginn die Hypothesen formuliert, welche im Lauf des Kapitels durch statistische Tests beantwortet werden.

### 4.2.1 Vorstellung der Hypothesen und der statistischen Tests

Die folgenden Hypothesen wurden in der Art formuliert, wie es bei statistischen Tests üblich ist. Die Aussagen entsprechen der Nullhypothese, die es zu widerlegen gilt. Bei den Tests der OFFENSE Häufigkeiten ist von den relativen Häufigkeiten auszugehen, die mit der Gesamtzahl von Tweets im selben Zeitraum normiert wurde.

#### HYPOTHESE H01 :

Der Anteil von OFFENSE-Tweets ist bei Mitgliedern der AfD genauso groß oder kleiner als bei Mitgliedern jeder anderen Partei.

#### HYPOTHESE H02 :

Der Anteil von OFFENSE-Tweets vor dem Corona Lockdown ist genauso groß oder kleiner als während des Lockdowns.<sup>5</sup>

#### HYPOTHESE H03 :

Der Anteil von OFFENSE-Tweets nach dem Corona Lockdown ist genauso groß oder kleiner als während des Lockdowns.

#### HYPOTHESE H04 :

Der Anteil von OFFENSE-Tweets vor dem Corona Lockdown ist genauso groß oder kleiner als nach dem Lockdown.

#### HYPOTHESE H05 :

Die Mitglieder der AfD rufen im Parlament zu einem genauso großen oder kleineren Anteil OFFENSE-Zurufe hinein, wie die Mitglieder jeder anderen Partei.

---

<sup>5</sup> Da der Lockdown nicht als eine klar eingegrenzte Zeitspanne gesehen werden kann, wird er in dieser Arbeit vom 13.03 bis zum 06.05. definiert. Es geht bei diesem Test insbesondere um die Zeit der Unsicherheit, nachdem klar wurde, dass es sich um eine ernstzunehmende Pandemie handelt, bis zu den ersten Lockerungen. Deshalb wurde als Start der Zeitpunkt der Schulschließungen gewählt und als Ende die Sitzung in der das dritte Maßnahmenpaket beschlossen wurde.

**HYPOTHESE H06 :**

Die Mitglieder jeder Partei rufen im Parlament zu einem genauso großen oder größeren Anteil OFFENSE-Zurufe hinein, im Vergleich dazu wie groß ihr Anteil an OFFENSE-Tweets ist.

**HYPOTHESE H07 :**

Der Anteil von OFFENSE-Zurufen vor Corona ist genauso groß oder kleiner als währenddessen.<sup>6</sup>

Um festzustellen welche Testverfahren in Frage kommen, wurden zunächst die Verteilungen der Daten betrachtet. Dabei gab es die Möglichkeit, die Häufigkeiten pro Monat, Woche oder Tag zu betrachten. Um Ausreißer zu vermeiden und gleichzeitig die Stichprobengröße nicht zu klein werden zu lassen, wurde entschieden die Daten auf Wochenbasis zu aggregieren. Das bedeutet, dass für jede der sechs Parteien 67 Beobachtungen vorliegen. Eine Beobachtung entspricht der relativen Häufigkeit von OFFENSE Tweets, einer konkreten Partei, in einer Woche. Als erste Indikation der Verteilung dieser Daten sind in Abbildung 4.7 die Histogramme dargestellt. Abgesehen von der AfD und der Linken, zeigen alle eine sehr deutlich rechtsschiefe Verteilung mit einem Mittelwert zwischen fünf und sieben Prozentpunkten.

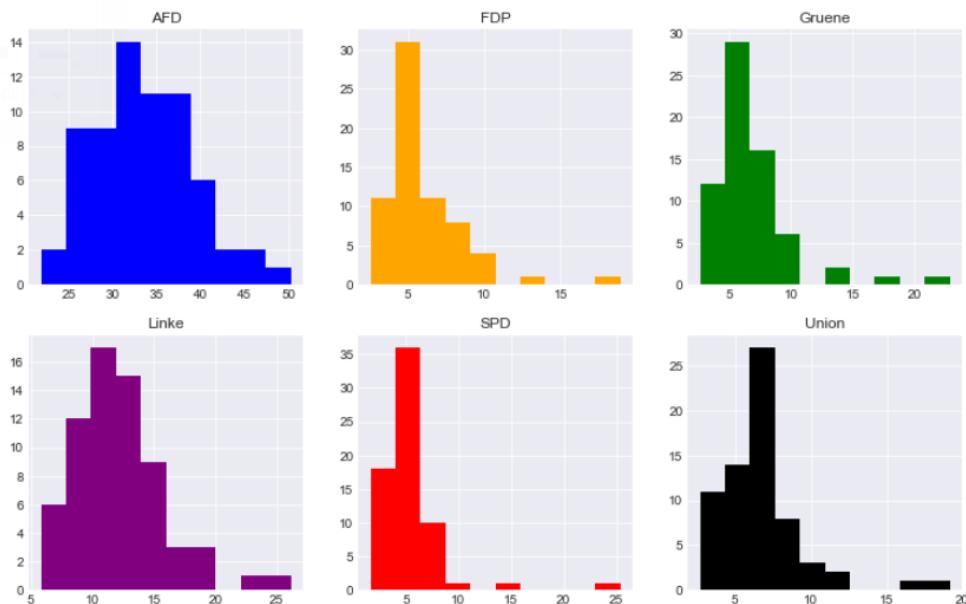


Abbildung 4.7: Histogramme der relativen OFFENSE-Tweet Häufigkeit pro Woche

Da für die Auswahl der Testmethode entscheidend ist, ob die Stichproben normalverteilt sind, wird diese Eigenschaft mit dem Shapiro-Wilk Test überprüft. Hierbei wird die Teststatistik  $W$  berechnet und mit dem kritischen Wert abgeglichen oder alternativ anhand des  $p$ -Werts entschieden, ob die

<sup>6</sup> Um eine größere Stichprobengröße zu erhalten, wurde für die Plenardaten der gesamte Zeitraum ab den Schulschließungen und nicht nur der Lockdown selbst betrachtet.

Nullhypothese abgelehnt werden kann<sup>7</sup>. Dabei entspricht  $W = \frac{b^2}{(n-1)s^2}$ , was bedeutet, dass zwei geschätzte Varianzen gegenübergestellt werden. Im Zähler wird die Varianz einer tatsächlichen Normalverteilung der in der Stichprobe geschätzten Varianz gegenübergestellt. Bei  $W = 1$  wäre die Stichprobe demnach sehr wahrscheinlich normalverteilt. Der zugehörige p-Wert gibt die Wahrscheinlichkeit an, dass es sich bei der beobachteten Stichprobe um eine Normalverteilung handelt. Aus Tabelle 4.4 geht hervor, dass nur für die Verteilung der AfD-Stichprobe die Nullhypothese nicht abgelehnt werden konnte. Die OFFENSE-Tweet Häufigkeiten aller anderen Parteien sind demnach sehr wahrscheinlich nicht normalverteilt.[55]

	AFD	FDP	GRÜNE	LINKE	SPD	UNION
Mean	$\bar{X}: 33.491$	$\bar{X}: 6.006$	$\bar{X}: 6.698$	$\bar{X}: 12.091$	$\bar{X}: 5.525$	$\bar{X}: 6.765$
Std.	$S: 5.833$	$S: 2.546$	$S: 3.263$	$S: 3.78$	$S: 3.174$	$S: 2.715$
Shapiro Wilk Test	W: 0.988 p: 0.745 Gaussian	W: 0.803 p: 0.000 NOT	W: 0.755 p: 0.000 Gaussian	W: 0.922 p: 0.000 NOT	W: 0.631 p: 0.000 Gaussian	W: 0.834 p: 0.000 NOT

Tabelle 4.4: Verteilungsparameter und Test auf Normalverteilung

Da die Voraussetzung der Normalverteilung nicht erfüllt werden konnte, werden die zuvor aufgestellten Hypothesen mit nichtparametrischen Methoden überprüft. Für die Hypothesen H<sub>01</sub>, H<sub>05</sub> und H<sub>06</sub> bedeutet dies, dass ein **Mann-Whitney-U-Test** durchgeführt wird. Dessen Voraussetzungen sind weniger streng und werden als erfüllt betrachtet, da lediglich die Form und Streuung der verschiedenen Stichproben gleich sein sollten.

Bei einem Vergleich der Parteien untereinander, bzw. der Gegenüberstellung von Parlament und Twitter, wird davon ausgegangen, dass es sich um unverbundene Stichproben handelt. Entscheidend ist hierbei der Wert  $U_1 = n_1 * n_2 + \frac{n_1 * (n_1 + 1)}{2} - R_1$  bzw.  $U_2$ . Eins und zwei stehen hierbei für die zwei Stichprobenkategorien, beispielsweise Frauen und Männer oder in dieser Arbeit AfD und SPD.  $R_1$  steht für die Rangsumme der Gruppe 1. Diese berechnet man, indem zunächst alle beobachteten Werte der Reihe nach geordnet werden und anschließend jedem Wert aufsteigend ein Rang zugewiesen wird. Summiert man nun diese Rangzahlen einer Gruppe zusammen, so ergibt dies die Rangsumme  $R_1$ .

Wenn  $U_1$  und analog  $U_2$  berechnet wurden, wird der kleinere der beiden Werte mit dem kritischen Wert verglichen - ist er niedriger, wird die Nullhypothese zurückgewiesen.[73]

In den Hypothesen H<sub>02</sub>-H<sub>04</sub> werden die Tweets der selben Partei vor, nach und während des Lockdowns verglichen. Für diese verbundenen bzw.

<sup>7</sup> Dieser Wert ist aus einer Tabelle abzulesen und ist umso höher je mehr Beobachtungen vorliegen. Bei einem Signifikanzniveau von 5% und bei 50 Beobachtungen läge dieser Wert bereits bei 0,947.

paarten Stichproben wird ein **Wilcoxon-Vorzeichen-Rang-Test** durchgeführt. Berechnet und mit dem kritischen Wert verglichen wird hierbei die Teststatistik  $W = \min(W_+, W_-)$ . Dabei steht  $W_+ = \sum_{i=1}^n \mathbb{I}(x_{i,1} - x_{i,2} > 0)R_i$  für die positive Rangsumme. Das bedeutet, dass in einem ersten Schritt Beobachtungen der beiden Stichproben nebeneinander gestellt und voneinander abgezogen werden. Den absoluten Werten dieses Ergebnisses werden aufsteigend Ränge zugewiesen, das heißt die größte Differenz erhält den höchsten Rang. Die positive Rangsumme ( $W_+$ ) wird schließlich gebildet, indem für alle Differenzen mit positivem Vorzeichen die jeweiligen Ränge addiert werden. Analog wird für  $W_-$  mit den Differenzen mit negativem Vorzeichen verfahren. Der kritische Wert  $W_{krit}$  liegt beispielsweise für den einseitigen Test und ein Signifikanzniveau von 5% bei 466. Wenn die kleinere der beiden Rangsummen unter diesem Wert liegt, wird die Nullhypothese zurückgewiesen, dass es keinen Unterschied zwischen den beiden Stichproben gibt.[74]

#### 4.2.2 Twitter Sentiments

Betrachtet man die Entwicklung der Häufigkeit von Tweets über die Zeit, passen die Hoch- und Tiefpunkte häufig zu den Zeitpunkten bestimmter Events. Einige dieser Ereignisse aus dem Betrachtungszeitraum Mai 2019 bis Juli 2020, wurden im vorangegangenen Kapitel bereits angesprochen. In Abbildung 4.8 sind im Gegensatz zur zuvor beschriebenen Grafik 4.6 die relativen Häufigkeiten der OFFENSE-Tweets abgebildet. Diese wurden mit der Gesamtzahl an Tweets in der jeweiligen Woche normiert. In dieser Darstellung hebt sich die Linie der AfD Tweets deutlich von den anderen Parteien ab, was zu erwarten war, da die AfD bei weniger Tweets insgesamt, die meisten mit dem Label OFFENSE zu verzeichnen hatte.

Die Ereignisse sind anhand der Linie der relativen Häufigkeiten deutlich erkennbar und wurden an den entsprechenden Stellen in der Grafik vermerkt. Besonders starke Ausschläge zeigen sich um die Jahreswende sowie im Februar und Anfang März. Ein deutlicher Einbruch folgte Mitte März. Um beurteilen zu können, ob Politiker\*innen tatsächlich über die Ereignisse aus den jeweiligen Zeiträumen getwittert haben, wird im Folgenden auf einzelne Themencluster eingegangen. Das bedeutet, dass nur Tweets mit bestimmten Stichworten betrachtet werden. Die Cluster sind zum einen zeitlich begrenzte Themen wie der Anschlag in Hanau oder die Ministerpräsidenten Wahl in Thüringen. In diesen Fällen lassen sich über den begrenzten Zeitraum hinaus kaum Tweets zu diesem Topic beobachten.

Zum anderen werden Cluster für Themen gebildet, die regelmäßig diskutiert werden. Hierzu gehören Links- und Rechtsextremismus, Migration und Flüchtlinge, Klimaschutz und die Öffentlich Rechtlichen. Diese Auswahl wurde anhand von Auffälligkeiten bei Betrachtung der Grafen und Tweets getätigt. Da ein besonderes Augenmerk auf OFFENSE-Tweets lag, und diese besonders häufig von der AfD geprägt sind, folgen auch die Themencluster den "Lieblingsthemen" dieser Partei.

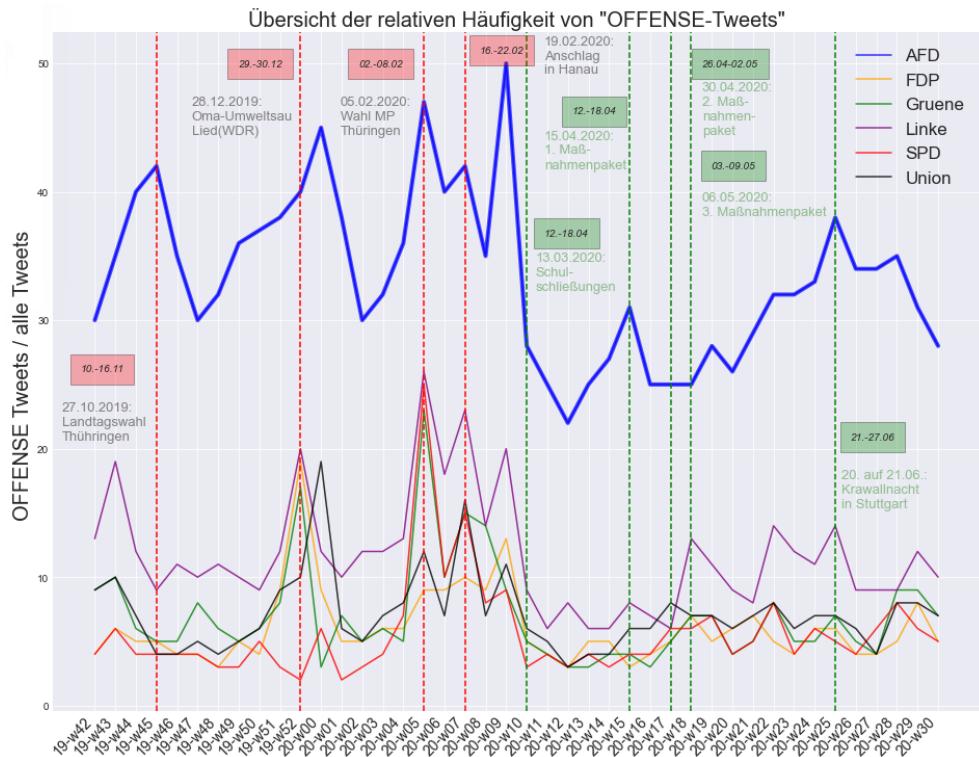


Abbildung 4.8: Übersicht der relativen Häufigkeit von OFFENSE-Tweets

In einem eigenen Kapitel wird schließlich auf das Thema Corona eingegangen. Dieses Cluster unterscheidet sich von den anderen in sofern, dass es sich nicht um ein plötzliches Ereignis mit anschließendem Echo auf Twitter handelt. Vielmehr kam es seit Jahresbeginn langsam auf und wurde erst Mitte März zu einem großen Thema. Gleichzeitig wurden die OFFENSE-Tweets parteiübergreifend weniger.

Die in diesem Abschnitt dargestellte Abbildung 4.8 sollte bei der Betrachtung der folgenden Cluster dazu dienen, das aktuelle Topic im Gesamtkontext zu sehen. Das ist notwendig, da die Ausschnitte der x-Achse (Zeit) und y-Achse (absolute Anzahl der Tweets) jeweils auf den relevanten Bereich eingeschränkt werden, um die Lesbarkeit zu verbessern.

#### 4.2.2.1 Ministerpräsidentenwahl in Thüringen

Die Tweets in diesem Cluster wurden ausgewählt, weil der folgende Reguläre Ausdruck im bereinigten Text einen oder mehrere Treffer ergab:

(.\*Kemmerich.\*|.\*Thüringen.\*|.\*Thueringen.\*)(?i)

Natürlich könnten diese Begriffe auch in Tweets zu anderen Themen als der Landtagswahl in Thüringen vorkommen. Jedoch sind diese zu vernachlässigen, da sie kaum ins Gewicht fallen. Dies wird in der hier dargestellten Abbildung 4.9 deutlich. Zwischen der Landtagswahl und der Wahl des Ministerpräsidenten gab es kaum Tweets zu dem Thema, und auch nach der Wahl von Bodo Ramelow zum Ministerpräsidenten am 04.03.2020 wurde

kaum eines der Stichworte erwähnt.

Vor der Landtagswahl am 27.10., sind bei FDP und AfD bereits einige Tweets zu erkennen, während die anderen Parteien kaum dazu twitterten. Mit Hinblick auf die verhältnismäßig geringe Anzahl an Tweets kann angemerkt werden, dass es sich in dieser Arbeit um Bundestagsabgeordnete handelt. Es ist sehr wahrscheinlich, dass die Landtagsabgeordneten in Thüringen deutlich aktiver auf Twitter waren. Auffällig ist jedoch, dass die FDP in der Woche der Wahl ca. doppelt so viele Tweets absetzte wie der Durchschnitt der anderen Parteien. Das lag insbesondere daran, dass sie ihr Ergebnis aus 2014 verdoppelt hatten und mit 5,0% knapp in den Landtag eingezogen waren.[34]

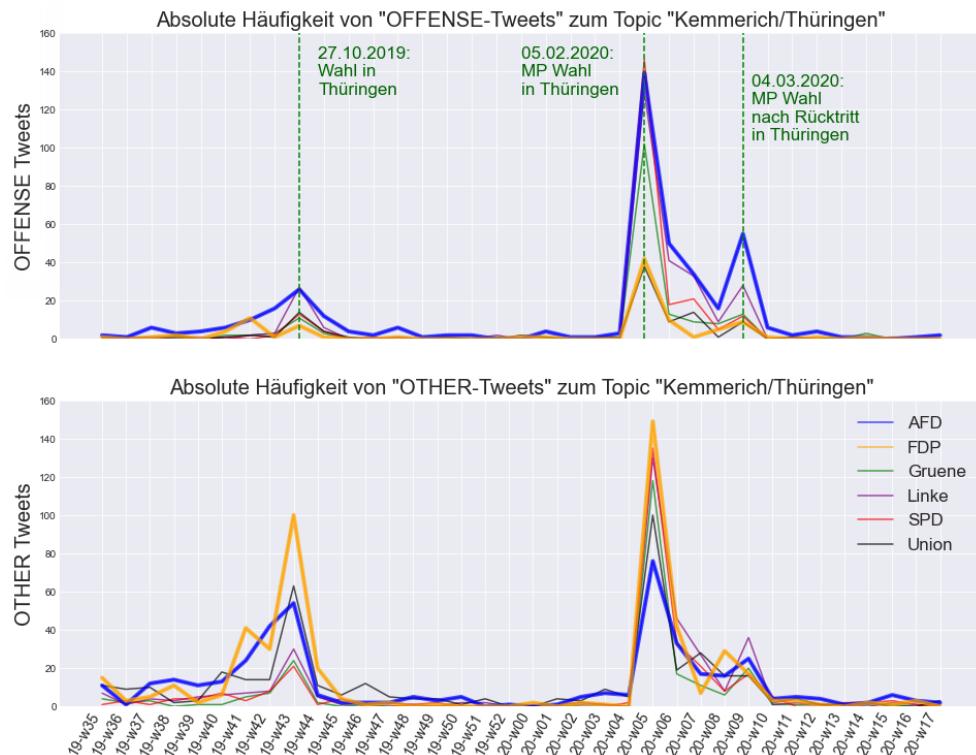


Abbildung 4.9: Tweets zum Topic KemmerichThüringen

In der Woche der Wahl des Ministerpräsidenten wurde hingegen von allen Parteien sehr viel getweetet, und Unterschiede waren vorrangig in den Emotionen zu erkennen. Die FDP hatte die meisten OTHER-Tweets (ca 150) zu verzeichnen, und dagegen wurden gerade mal 40 als OFFENSE gelabelt. Das waren die wenigsten unter allen Parteien. Bei der AfD dominierten hingegen die OFFENSE-Tweets, was sich zum einen auf abfällige und hämische Bemerkungen über linke Parteien am 05.02. zurückführen lässt. Zum anderen war die Empörung an den Tagen nach der Wahl groß, als Kemmerich zurücktrat.[62][32]

Einen kleineren Ausschlag verzeichnete das Topic schließlich am 04.03., als Bodo Ramelow zum Ministerpräsidenten gewählt wurde. Damit endete die Regierungskrise in Thüringen.[62] In den OFFENSE-Tweets der AfD konn-

ten in diesem Zeitraum besonders viele Ausdrücke gefunden werden, die dem AfD-typischen Narrativ gegen die Linke folgen. "Mauermörderpartei" und "SED-Nachfolgepartei" sind hier die Klassiker. Neu ist hingegen die Behauptung, dass die Linken Reiche erschießen lassen wolle. Diese Überspitzung eines Vorfalls auf einem Strategietreffen der Linken ist besonders perfide, weil sie nicht nur von der AfD undifferenziert dargestellt wird. Tatsächlich handelte es sich hierbei um den Beitrag eines Parteimitglieds, das der Linke-Chef Bernd Rixinger mit einem Witz versuchte zu entschärfen, anstatt entschieden zu widersprechen. Obwohl auch viele Linken Politiker sein Verhalten in der Situation verurteilten, und er selbst sich später auf Twitter davon distanzierte, folgten selbst seriöse Medien und CDU Politiker der überspitzten Version.[1][35]

Wenn die weiteren Themencluster präsentiert werden, lohnt es sich im Hinterkopf zu behalten, wie die Skala in diesem Topic "KemmerichThüringen" war. Es wird deutlich werden, dass die Bundestagspolitiker\*innen bei kaum einem anderen Thema mehr twitterten.

#### 4.2.2.2 Anschlag in Hanau

Die Tweets in diesem Cluster wurden ausgewählt, weil der folgende Reguläre Ausdruck im bereinigten Text einen oder mehrere Treffer ergab:

(.\*Hanau.\*|.\*Amoklauf.\*|.\*Rassis.\*|.\*Attentat.\*)(?i)

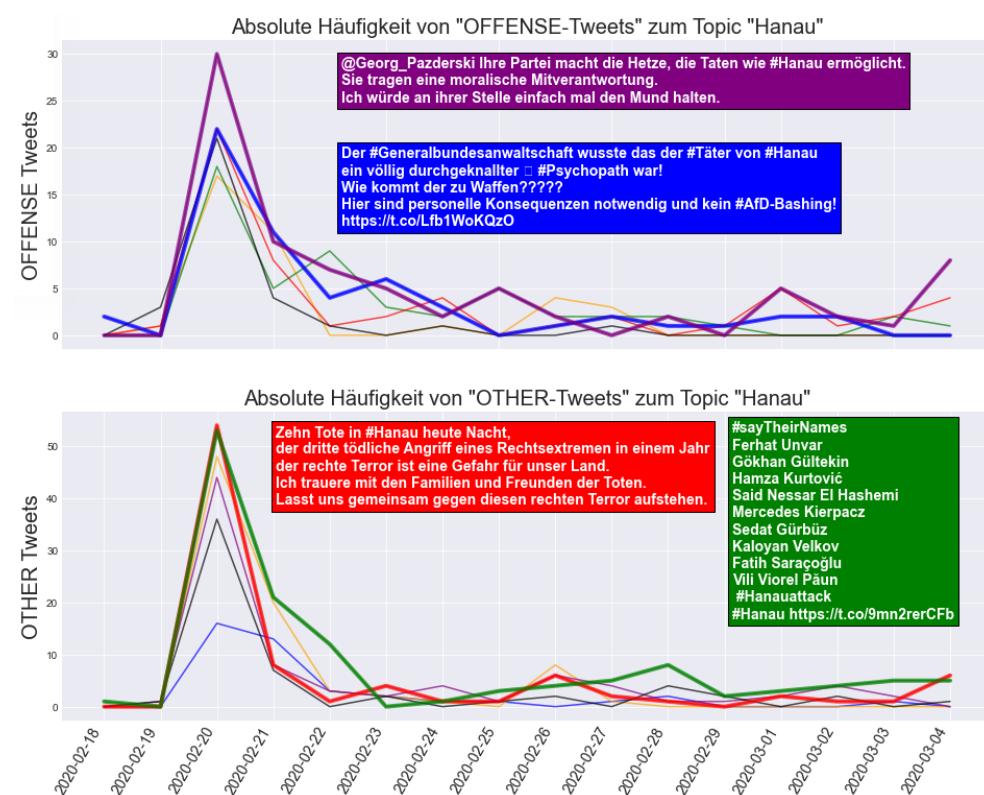


Abbildung 4.10: Tweets zum Topic Hanau

Der Attentäter von Hanau tötete in der Nacht vom 19. auf den 20.02.2020 neun Menschen und anschließend seine Mutter und sich selbst. Die Motive folgten einer rassistischen, von Vernichtungsfantasien geprägten Weltanschauung.[27] Bei den Reaktionen von Politiker\*innen auf eine solche Tat geht es nicht um ein pro oder contra. Selbst eine rechte Partei äußert sich über ein solches Ereignis nicht wohlwollend. Trotzdem lassen sich Muster erkennen, worauf in den ersten zwei Tagen nach dem Anschlag, die Schwerpunkte in der Kommunikation gelegt werden. Exemplarisch wurde hierfür in Abbildung 4.10 jeweils ein Tweet der Linken, der AfD, der SPD und der Grünen eingefügt. Diese Beispiele wurden mithilfe der Wordclouds in Abbildung 4.11 und 4.12 ausgewählt und werden in der folgenden Beschreibung Erwähnung finden.

Am Tag nach dem Attentat, twitterten insbesondere Politiker\*innen der Linken und der AfD OFFENSE-Tweets. Zwar übertrafen Erstere die AfD in absoluten Zahlen, betrachtet man jedoch die normalisierten Werte, so fällt auf, dass die AfD mit 69% OFFENSE-Tweets, einen mehr als doppelt so hohen Anteil hatte, als jede andere Partei. Die Grünen (17%) und die SPD (20%) lagen deutlich unter diesem Wert - insbesondere weil sie die meisten OTHER-Tweets zu verzeichnen hatten.

Der Fokus jeder Partei, lag am ersten Tag nach dem Attentat auf dem Mitgefühl für die Angehörigen und die Verletzten. Auffällig sind in Abbildung 4.11 darüber hinaus die Begriffe "Land" und "Terror" bei der SPD. Wie in dem Beispiels-Tweet in Abbildung 4.10 dargestellt, lässt sich dies darauf zurückführen, dass Politiker\*innen der SPD versuchten gegen rechten Terror zu mobilisieren. Es wurde betont, dass dieser eine Gefahr für Deutschland darstellt, gegen die man Stellung beziehen muss.



Abbildung 4.11: Hanau 19.02.2020 - Wordcloud 20.02.2020

Eine weitere Auffälligkeit ist die Verwendung des Begriffs Rassismus. Dieser kommt insbesondere bei linken Parteien vor und besonders selten bei der AfD. Beschäftigt man sich mit Sprache und Alltagsrassismus, so fällt bei Betrachtung der einzelnen Tweets ins Auge, dass Bundestagsabgeordneten auf Twitter fast nie den Fehler begehen, die Tat als "fremdenfeindlich", zu bezeichnen. Vielmehr wird von linken Politiker\*innen darauf hingewie-

sen, dass es eben keine Fremden waren, sondern Nachbarn, Freunde und Verwandte. Dieser aufgeklärten Sicht folgt auch "#sayTheirNames". Dieser Hashtag steht für eine respektvolle Berichterstattung bei der die Opfer als Individuen im Vordergrund stehen und nicht implizit die Weltsicht des Täters übernommen wird. Letzteres wäre der Fall, wenn man von Migranten oder Fremden schreiben würde.<sup>[4]</sup> Die klare Benennung der Tat als "Rassismus" durch linken Parteien (Abbildung 4.11), lässt vermuten, dass diese Abgeordnete entsprechend aufgeklärt sind, was die Bedeutung von Sprache und Wortwahl bei diesem Thema betrifft.

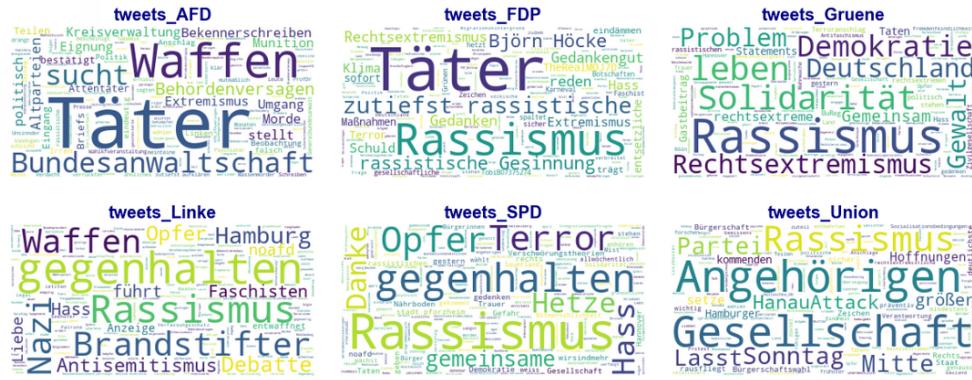


Abbildung 4.12: Hanau 19.02.2020 - Wordcloud 21.02.2020

Am zweiten Tag nach der Tat wurde von jeder Partei bereits weniger zu diesem Topic getweetet. Bei Betrachtung der Wordcloud in Abbildung 4.12 lassen sich jedoch ebenfalls interessante Tendenzen erkennen. Während man die Sprache von SPD und Grünen zu einem größeren Teil als konstruktiv und respektvoll bezeichnen könnte, so findet man bei der Linken und AfD andere Tendenzen. Insbesondere Politiker\*innen aus dem linken Spektrum sehen die AfD mitverantwortlich für derartige Taten und die Linke bringt diese Meinung besonders deutlich in OFFENSE-Tweets zum Ausdruck, wie das Beispiel in Abbildung 4.10 zeigt. In der Wordcloud finden sich entsprechend Begriffe wie "Nazi", "Faschisten", "Brandstifter" und "noafd". Dagegen sind bei den Grünen und der SPD die Wörter "Solidarität" und "gemeinsam" verhältnismäßig häufig verwendet worden.

Auffällig ist außerdem die Konzentration der AfD auf die Begriffe "Täter", "Waffen" und "Bundesanwaltschaft". Das Beispiel in Abbildung 4.10 zeigt, in welchem Zusammenhang diese Wörter stehen. Es wurde versucht, von der Kritik an der eigenen Partei abzulenken, indem den aktuellen Institutionen Versagen vorgeworfen wurde.

#### 4.2.2.3 Klimaschutz

Die Tweets in diesem Cluster wurden ausgewählt, weil der folgende Reguläre Ausdruck im bereinigten Text einen oder mehrere Treffer ergab:

(.\*Klima.\*|.\*Greta.\*|.\*Friday.\*)(?i)

Bei der Darstellung des Topics Klima wird - wie bereits im vorangehenden Unterkapitel - deutlich, dass es Unterschiede in der Sprache gibt, mit der Parteien sich zu zentralen Themen äußern. Klima und Umwelt sind seit ihrer Gründung das Thema der Grünen, und entsprechend wenig überraschend sind die Tweet-Häufigkeiten zu diesem Topic. Es sind in Abbildung 4.13 klare Spitzen zu den globalen Klimastreiks zu erkennen, und auch über das restliche Jahr vergeht keine Woche, in der nicht wenigstens zehn Tweets zu dem Thema abgesetzt werden. Die meisten Tweets in einer Woche wurden zum Globalen Klimastreik am 20.09.2020 versendet, dieser fand in 150 Staaten und tausenden Städten auf der ganzen Welt statt.[24] Deutlich wird außerdem, dass fast kein Tweet der Grünen zum Topic Klima das Label OFFENSE trägt.

Die AfD positioniert sich hingegen klar gegen die Politik der Grünen, und auf der Parteiseite findet sich folgendes Statement:

**"Die Aussagen des Weltklimarats, dass Klimaänderungen vorwiegend menschengemacht seien, sind wissenschaftlich nicht gesichert."**[18]

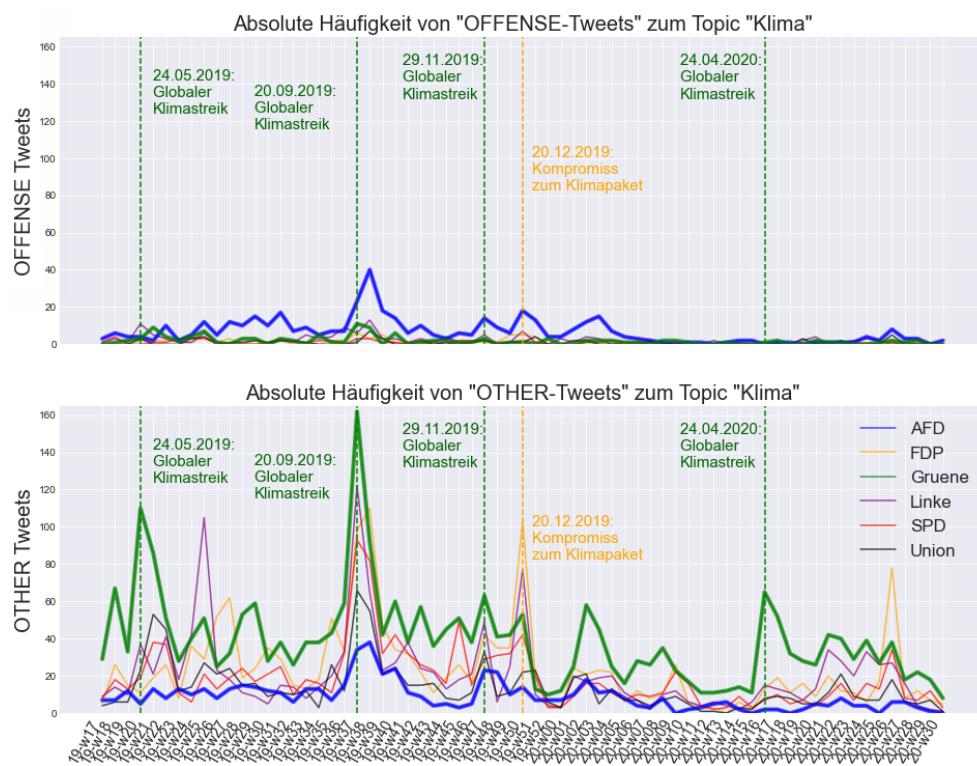


Abbildung 4.13: Tweets zum Topic Klima und Fridays for Future

Obwohl die AfD insgesamt zu diesem Topic relativ wenig tweetet, verzeichnet die Partei die meisten OFFENSE-Tweets. Beliebte Hashtags sind #Klimawahn, #Klimasekte, #Klimavoodoo und #Klimahysterie. Ein Beispiel für Whataboutism[44] ist #LangstreckenLuisa, der sich auf die Aktivistin Luisa Neubauer bezieht, das deutsche Gesicht der Fridays for Future Bewegung. Von dem Grundproblem, dass Fliegen und allgemein CO<sub>2</sub> schädlich für die

Umwelt sind, soll durch die scheinbare Doppelmoral der Aktivisten und Grünenpolitiker abgelenkt werden.[56]

Neben diesen beiden Parteien hat die FDP in der Woche 20.12.2019 zu diesem Topic einmal auffällig viel getweetet. Zu diesem Zeitpunkt stimmte der Bundesrat dem Kompromiss zum Klimapaket zu.[64] Die Reaktionen waren weitgehend neutral formuliert und folgten der Argumentation, dass Innovation statt Verzicht der richtige Weg seien.

#### 4.2.2.4 *Migration und Flüchtlinge*

Die Tweets in diesem Cluster wurden ausgewählt, weil der folgende Reguläre Ausdruck im bereinigten Text einen oder mehrere Treffer ergab:

(.\*Migration.\*|.\*Migrant.\*|.\*Flücht.\*|.\*Asyl.\*|.\*Zuwander.\*)(?i)

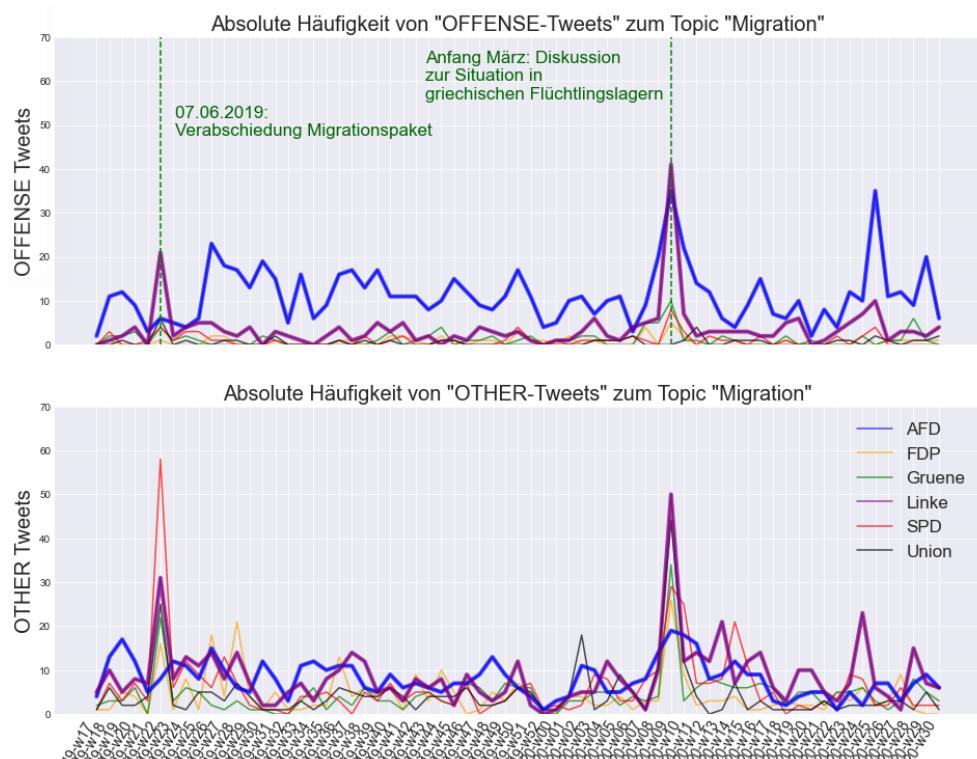


Abbildung 4.14: Tweets zum Topic Migration

Das in Abbildung 4.14 dargestellte Topic hat wenige eindeutige OFFENSE Spitzen und ist vielmehr davon geprägt, dass die AfD konstant 10 bis 20 OFFENSE-Tweets pro Woche dazu veröffentlicht. Die Präferenz der AfD zu diesem Thema wurde unter anderem von der Süddeutschen Zeitung in dem bereits in Kapitel 2.1.2 zitierten Artikel dargestellt. In verlinkten Videos ist zu sehen, wie innerhalb von kürzester Zeit auf das Thema Migration gewechselt wird, unabhängig vom ursprünglichen Kern der Rede.[12]

Darüber hinaus konnte das gleiche Team in einem anderen Artikel zeigen, dass sich die Wortwahl im Bundestag seit der Gründung der AfD im Jahr 2013 verändert hat. Dies ist natürlich zu einem großen Teil normal, da sich

Schwerpunkte ändern. Interessant sind jedoch Verschiebungen wie die bewusste Bevorzugung des Wortes Migrant gegenüber Flüchtling. Letzteres kann Empathie und Hilfsbereitschaft auslösen, während "Migrant" das Schutzbedürfnisse nicht automatisch transportiert. Dabei werden die Worte häufig bewusst falsch eingesetzt, sodass zum Beispiel von "syrischen Migranten" die Rede ist, obwohl es sich offensichtlich um Flüchtlinge handelt. Dieses Beispiel zeigt, dass der Zusammenhang in dem bestimmte Worte fallen, zunehmend zu einer anderen Wahrnehmung führen kann, was wiederum den Diskurs verschiebt.[10]

Zwei Spitzen können insbesondere in den OTHER-Tweets in Abbildung 4.14 erkannt werden. Das Migrationspaket im Juni 2019 sorgte insbesondere bei der SPD zu einem erhöhten Tweet-Aufkommen. Die sieben Gesetze im Paket wurden von den beiden Koalitionspartnern gegen Widerstände von Links und Rechts durchgesetzt. Unter anderem ging es um erleichterte Abschiebungen, jedoch auch einen vereinfachten Zugang zum Arbeitsmarkt bei Mangelberufen und eine Duldung gut integrierter Asylbewerber, die vor dem 01.08.2018 in Deutschland ankamen.[39] Politiker\*innen der Linken tweeteten unter dem Hashtag #HauAbGesetz besonders viele OFFENSE-Tweets. Dagegen ist es überraschend, dass ausgerechnet bei der AfD in dieser Zeit eine klare Delle in den OFFENSE-Tweets erkennbar ist.

Die zweite Spitz im März 2020 ist hingegen in OFFENSE- und OTHER-Tweets zu erkennen. Hierbei handelt es sich um die Empörung über die humanitäre Lage im griechischen Flüchtlingslager Moria, insbesondere im Hinblick auf die sich anbahrende Pandemie.[37] Für besonderen Unmut hatte das Thema der Aufnahme von Kindern gesorgt. Dabei folgten die Fronnen und Argumente den bekannten Parteilinien. AfD Abgeordnete schreiben in ihren Tweets von einem Einknick gegenüber Erdogan und bedienen rassistisch Ressentiments. Grüne und Linke twittern unter dem Hashtag #WirHabenPlatz und beklagen, dass Innenminister Horst Seehofer vor der AfD einknickt und Bürokratie über Humanität stellt. Tatsächlich verweigerte dieser in den folgenden Monaten mehreren Bundesländern die Aufnahme von Flüchtlingskindern mit dem Hinweis auf geltende EU Vereinbarungen. Bis Mitte Juli waren gerade einmal 47 von ihnen in Deutschland angekommen.[61]

#### 4.2.2.5 Extremismus

Die Tweets in diesem Cluster wurden ausgewählt, weil der folgende Reguläre Ausdruck im bereinigten Text einen oder mehrere Treffer ergab:

(.\*Linksextrem.\*)(?i)  
(.\*Rechtsextrem.\*)(?i)

In diesem Cluster wurden - anders als zuvor - zwei Topics gegenübergestellt. Um diese nicht zu vermischen und um die Ungenauigkeit möglichst niedrig zu halten, wurde jeweils nur ein Stichwort verwendet. Wären zusätzlich Begriffe wie .\*Extremismus.\* , .\*Antifa.\* oder .\*links.\* bzw. .\*rechts.\*

aufgenommen worden, hätte der Algorithmus zwar mehr Tweets gefunden, jedoch potenziell mit mehr Fehlern.

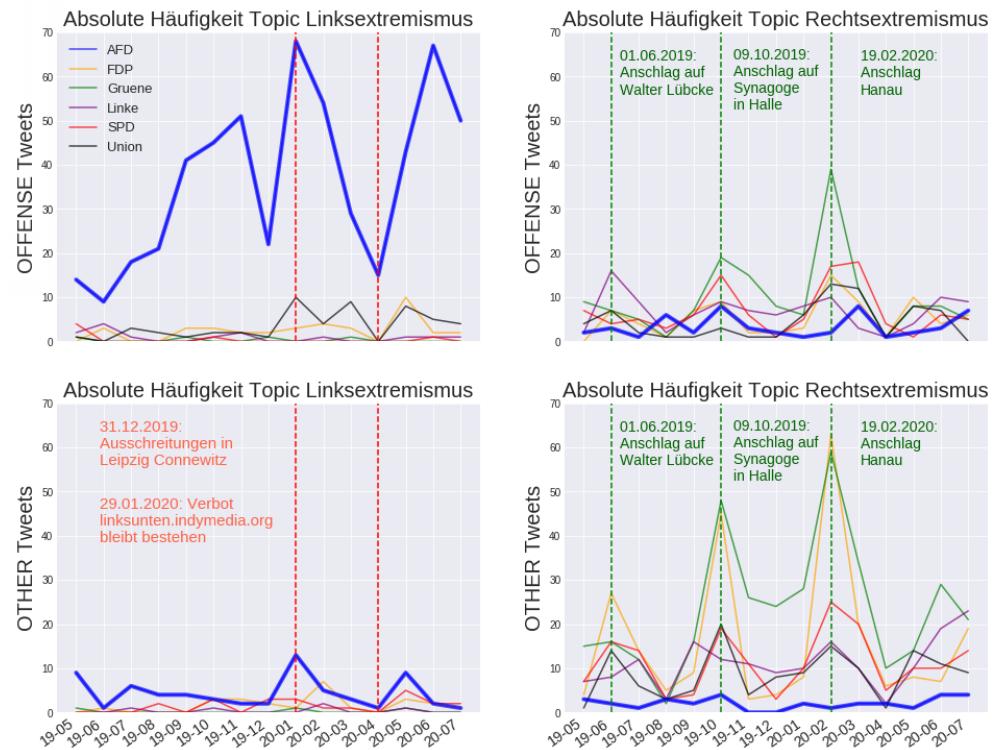


Abbildung 4.15: Tweets zu den Topics Links- und Rechtsextremismus

Die X und Y-Achsen (Monate) der vier Grafen sind gleich skaliert, wobei die oberen beiden die absolute Häufigkeit von OFFENSE-Tweets zeigt und die unteren die Tweets mit dem Label OTHER. Auf den ersten Blick auffällig sind die sehr niedrigen Zahlen bei OTHER Tweets zum Thema Linksextremismus. Anders als in den anderen drei Quadranten, durchbricht diese Linie fast nie die zehn Tweets pro Monat. Allgemein ist erkennbar, dass die AfD mit Abstand am meisten über das Topic Linksextremismus schreibt. Tweets mit dem Stichwort Rechtsextremismus kommen vorrangig von den Grünen und der FDP. Die Linke scheint diesen Begriff nicht immer zu verwenden sondern greift häufiger auf Wörter wie "Rassismus", "Nazis" und Faschismus zurück, sowie verschiedene Wortschöpfungen aus diesen.

Bei den Tweets über Rechtsextremismus lässt sich die Tendenz der Grünen erkennen, auch bei Gewalttaten nicht vorrangig OFFENSE-Tweets abzusetzen. Dies wurde bereits für das Cluster Hanau beschrieben und kann nun auch für den Mord am Kasseler Regierungspräsidenten Walter Lübke und den Anschlag auf die Synagoge in Halle beobachtet werden. Wie bei der Beschreibung der Abbildung 4.5 bereits erwähnt, handelte es sich bei letzterem um einen versuchten Anschlag auf eine Synagoge, bei der ein rechtsextremer Täter an der Tür scheiterte und anschließend zwei Menschen in der Nähe erschoss. Der Mord an Walter Lübke wurde von einem Mann verübt, der be-

reits zuvor durch einen rechtsterroristischen Anschlagsversuch aufgefallen war. Außerdem war Walter Lübke bereits mehrfach aufgrund seiner Flüchtlingspolitik bedroht worden.[69]

Bei Betrachtung der Tweets fällt auf, dass Grünen Politiker\*innen im Oktober 2019 bereits vor dem Anschlag in Halle zum Thema Rechtsextremismus twitterten, wie hier Renate Künast am 04.10.2019):

Hallo @Bundesregierung, ist das Euer Ernst!?

Keine Förderung mehr für Aussteiger aus dem #Rechtsextremismus?

@exitdeutschland @GrueneBundestag

Am selben Tag twitterte Konstantin Kuhle von der FDP über seine Anfrage bzgl. Verbindungen des Rechtsextremismus in die Kampfsportszene. Nach dem Anschlag positionierte die Partei sich klar gegen rechte Gewalt, viele mit dem Hinweis, dass ein Generalverdacht gegen Gamer oder Sportschützen nicht der richtige Ansatz in der Sache sei.

Die Spitzen der AfD Tweets beziehen sich zu einem großen Teil auf Vor kommisse aus dem Leipziger Stadtteil Connewitz. Im November twitterten die Politiker\*innen über den Überfall auf die Prokuristin einer Baufirma durch Vermummte in ihrer eigenen Wohnung. Ein Bekennerschreiben wurde auf der linken Plattform Indymedia veröffentlicht, genauso wie die Bekenntnisse zu einigen der teilweise sehr gefährlichen Brandanschläge aus dieser Zeit.[26] Das weiterhin gültige Verbot dieser Plattform führte zu der dritten Spitze der OFFENSE Tweets.[13] Zum größten Ausschlag kam es nach der Silvesternacht in der sich Linke und Polizist\*innen eine Straßenschlacht in Connewitz lieferten. Die Polizei musste sehr dramatische Darstellungen der Geschehnisse relativ bald zurücknehmen. Weder wurde der verletzte Polizist "notoperiert", noch konnte von einem "orchestrierten" Angriff gesprochen werden.[21] Bei der AfD schrieben Abgeordnete trotzdem von einem beinahe getöteten Polizisten und Martin Reichardt tweetete:

Der.. Beamte war bewusstlos, blutete stark, musste... bewusstlos, von der Straße gezogen und... erstversorgt werden."

Das soll zur Lapalie werden!

Es sind die linksextremen Netzwerke des Post-RAF-Establishments, die wie damals versuchen linken Terror zu verharmlosen!

Es lässt sich festhalten, dass die naheliegende These - Rechte twittern über Linksextremismus und linke bis liberale Parteien über Rechtsextremismus - nach betrachtung der Grafen bestätigt werden kann. Jedoch unterscheiden sich die beiden Seiten deutlich, wenn es um die Art der Tweets geht. Genauso wie im Zusammenhang mit der Linken oft von Mauermörder-Partei gesprochen wird, sind linke Gewalttaten sofort Teil eines "Post-RAF-Establishments". Terroristen, Schläger, Brandstifter und Kriminelle sind typische, emotional aufgeladene Bezeichnungen in Tweets der AfD.

#### 4.2.2.6 Öffentlich-Rechtliche

Die Tweets in diesem Cluster wurden ausgewählt, weil der folgende Reguläre Ausdruck im bereinigten Text einen oder mehrere Treffer ergab:

(.\*ARD.\*|.\*ZDF.\*|.\*WDR.\*|.\*MDR.\*|.\*GEZ.\*|.\*ÖRR.\*|.\*Rundfunk.\*|.\*Staatsfunk.\*)

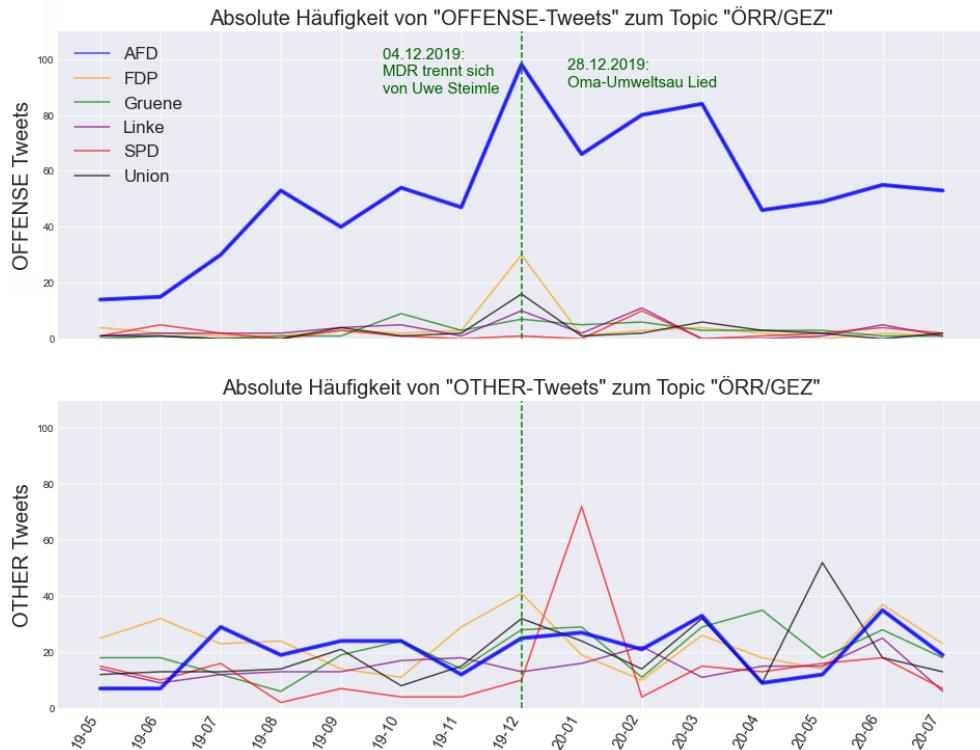


Abbildung 4.16: Tweets zum Topic Öffentlich-Rechtliche

Das Topic Öffentlich-Rechtliche wurde, wie alle Cluster in dieser Arbeit, zunächst testweise erstellt, nachdem in Tweets der Begriff "Staatsfunk" wiederholt zu finden war. Dabei stellte sich heraus, dass es sich nicht nur um vereinzelte Tweets handelte, die bei Unmut über ein konkretes Ereignis abgesetzt werden. Vielmehr scheint die AfD - ähnlich dem Topic Migration - in permanenten kleinen Angriffen die Öffentlich-Rechtlichen Medien diskreditieren zu wollen. So sieht man in Abbildung 4.16, dass im betrachteten Zeitraum zwischen knapp 20 und fast 100 OFFENSE-Tweets pro Monat versendet wurden.

Ende 2019 sorgten gleich zwei Ereignisse für ein besonders hohes Tweet-Aufkommen. Anfang Dezember trennte sich der MDR (Mitteldeutscher Rundfunk) von Uwe Steimle, einem sächsischen Komiker und Schauspieler. Dieser war wiederholt und verstärkt mit rechten Aussagen aufgefallen.[66]

Das Ereignis das Ende 2019 von verschiedenen Seiten besonders hochgekocht wurde, betraf ein satirisches Video auf Facebook. Hier sang ein Kinderchor im WDR (Westdeutscher Rundfunk) zur Melodie von "Meine fährt im Hühnerstall Motorrad" eine abgewandelte Version, in der unter anderem die Zeile "Meine Oma ist 'ne alte Umweltsau" vorkam.[70]

Im Laufe des Dezembers empörten sich AfD-Politiker\*innen vermehrt über vermeintliche Zensur im Öffentlich-Rechtlichen, wie z.B. Frank Pasemann am 04.12.2019:

Der #ÖRR #Staatsfunk räumt auf.

Uwe #SteimlesWelt passt nicht in die "bunte und weltoffene Welt" der @mdrde Haltungsideologen in der überbezahlten Chefetage.

Satiriker mit eigener, kritischer Meinung sind eben keine Hofnarren wie @janboehm.@AfDimBundestag

Nach Weihnachten vervielfachten sich diese Reaktionen bei der AfD. Regelmäßig wurde von "politischem Missbrauch von Kindern" getwittert und die Parallelen zu diversen totalitären Regimen aufgezeigt.

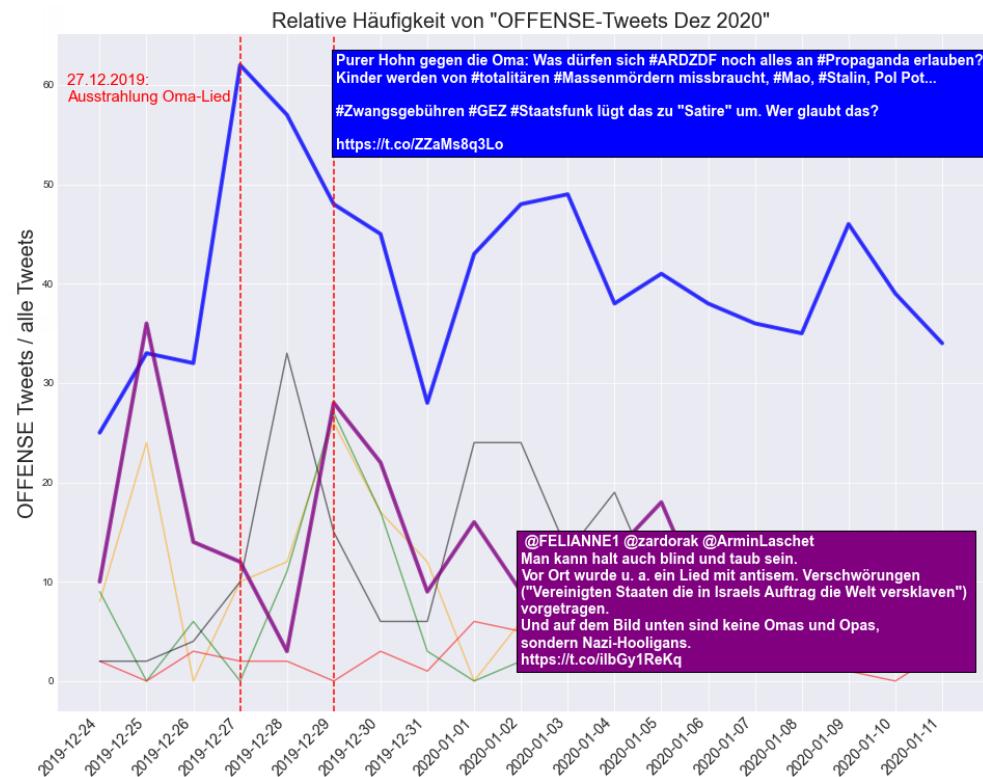


Abbildung 4.17: Tweets zum Jahreswechsel 2019/2020

Abbildung 4.17 zeigt die absolute Menge aller Tweets und nicht nur das Topic ÖRR. Dies ermöglicht in diesem Fall zusätzliche Einblicke, da zu dieser Affäre nicht mehr nur mit den oben genannten Schlagwörtern getwittert wurde. Ein Beispiel ist die Reaktion des Unionspolitikers Florian Hahn, der am 28.12.2019 schrieb:

Die #klimahysterie in diesem Land treibt nicht nur unsinnige Blüten, sondern sie gefährdet den Zusammenhalt zwischen Alt & Jung, Stadt & Land und Arm & Reich  
#versöhnenstattspalten #Klimaschutz mit #Verstand  
@CSU @csu\_bt @cduscubt

In den Tweets der Unions-Politiker\*innen wurde kurz nach der ersten Empörungswelle der AfD, ebenfalls von aufgehetzten Kindern, Klimahysterie und einem Fehlritt des WDR geschrieben. Leise wurde es hingegen von dieser Seite, als es vor dem WDR Gebäude zu Demonstrationen - unter anderem von Rechtsextremen kam. Über diese Ereignisse twitterten vorrangig linke und liberale Abgeordnete.[2]

#### 4.2.2.7 Hypothesentest - Twitter

In diesem Kapitel wurde für verschiedene Themen-Cluster gezeigt, wie sich die Häufigkeit von OTHER- und OFFENSE-Tweets unterscheidet. Dabei war auffällig, dass die AfD bei fast jedem Thema mehr OFFENSE-Tweets absetzt als andere Parteien. Ob dieser Unterschied für den gesamten betrachteten Zeitraum von 15 Monaten signifikant ist, wird mit dem anfangs beschriebenen Mann-Whitney-U-Test getestet. Die aufgestellte Nullhypothese lautete: H<sub>0</sub>: Die Mitglieder der AfD twittern genauso viele oder weniger OFFENSE-Tweets als die Mitglieder jeder anderen Partei.

Der Test wird einseitig durchgeführt, das heißt in der Gegenhypothese wird überprüft, ob die AfD tatsächlich mehr OFFENSE-Tweets absetzt als jede andere Partei. Entscheidend bei einseitigen Tests ist, dass der p-Wert durch zwei geteilt wird, bevor überprüft wird, ob er über dem Signifikanzniveau liegt. Ist dies der Fall, so wird die Nullhypothese nicht zurückgewiesen. In Tabelle 4.5, sowie in allen noch folgenden Tabellen, werden jedoch Ergebnisse von beidseitigen Tests aufgeführt. Das bedeutet, dass für den einseitigen Test der p-Wert noch halbiert werden muss. Alle anderen Werte sind bei ein- und zweiseitigen Tests identisch. Dies hat mit der besseren Nachvollziehbarkeit der Auswertung in Python zu tun.

In der ersten Spalte wurde die AfD testweise auch mit sich selbst verglichen, und wie zu erwarten war, konnte in diesem Fall die Nullhypothese nicht verworfen werden. Der p-Wert liegt bei rund 100%. Das bedeutet, dass die Wahrscheinlichkeit, die beobachtete Stichprobe zu erhalten, unter der Annahme, dass die Nullhypothese stimmt, 100% beträgt.

AFD	FDP	GRÜNE	LINKE	SPD	UNION
U: 2244.5	U: 0.000	U: 2.000	U: 10.000	U: 6.000	U: 0.000
p: 0.998	p: 0.000				
RBC: 0.0	RBC: 1.0	RBC: 0.99	RBC: 0.99	RBC: 0.99	RBC: 1.0
Gleich o. weniger	AfD hat mehr				

Tabelle 4.5: Wilcoxon-Mann-Whitney-Test der rel. OFFENSE-Tweet Häufigkeiten

Da es keinen Unterschied zwischen den verglichenen Stichproben gibt, ist auch der Effekt null, der durch die Rank-biserial correlation (RBC) angegeben wurde. Berechnet wird dieser Effekt, indem der Anteil der Paare die

nicht die Alternativhypothese unterstützen, von dem Anteil derer abgezogen wird, die sie stützen. Das bedeutet, dass bei einem RBC von null, bei 50% die Werte der einen Stichprobe größer waren und bei den anderen 50% die Werte der anderen Stichprobe.[47]

Für jede andere Partei konnte mit hoher Signifikanz ( $p < 0.001$ ) nachgewiesen werden, dass die AfD den höheren Anteil an OFFENSE-Tweets in den 67 betrachteten Wochen abgesetzt hatte. Die Effekte waren mit Werten zwischen 0.99 und 1.0 sehr groß. In fast jedem betrachteten Paar lag die AfD über dem Wert der anderen Partei.

#### 4.2.3 Corona Pandemie

Wie bereits zu Beginn dieses Kapitels erklärt wurde, unterscheidet sich das Topic Corona von den bisher beschriebenen. Als im März klar wurde, dass das Virus sich auch in Deutschland ausbreitet, zogen die Parteien im Bundestag an einem Strang, um notwendige Maßnahmen zum Seuchenschutz und zur ökonomischen Absicherung Betroffener zu beschließen.[38]

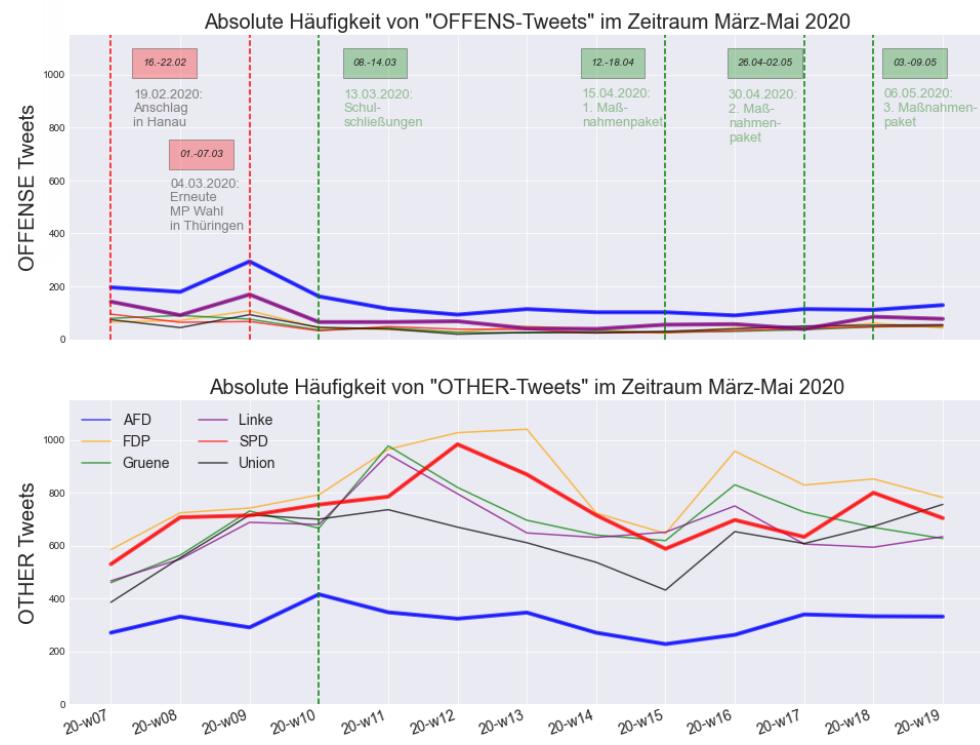


Abbildung 4.18: Tweets zum Zeitraum des Corona-Lockdowns

Es kann vermutet werden, dass durch die allgemeine Unsicherheit, keine Partei bereit war in dieser Zeit als Querulant aufzufallen. Das könnte erklären, dass es in den Monaten März und April zu keinen größeren Ausschlägen an OFFENSE-Tweets kam, wie in Abbildung 4.18 zu sehen ist. In den beiden Grafiken werden absolute Häufigkeiten von OFFENSE- und OTHER-Tweets gegenübergestellt, ohne bestimmte Stichwörter zu matchen. Die Achsen sind

gleich skaliert. Um dies zu ermöglichen und trotzdem Unterschiede sichtbar zu machen, wurden die Tweets von Johannes Kahrs (SPD) entfernt.

Auffällig ist außerdem, wie spät das Thema in den Tweets der Abgeordneten ankam, und welche Ausmaße es anschließend annahm. Betrachtet man die WordClouds, die im Appendix B.3 einzusehen sind, so fällt auf, dass verschiedene Schlagwörter zum Thema Corona die Abbildungen ab März 2020 beherrschen. Das gleiche wird in Abbildung 4.19 deutlich. In diesen Grafiken sind die Tweets nach dem Topic Corona ausgewählt, das bedeutet, dass der folgende Reguläre Ausdruck im bereinigten Text der Tweets einen oder mehrere Treffer ergab:

(.\*Corona.\*|.\*Covid.\*)((?i))

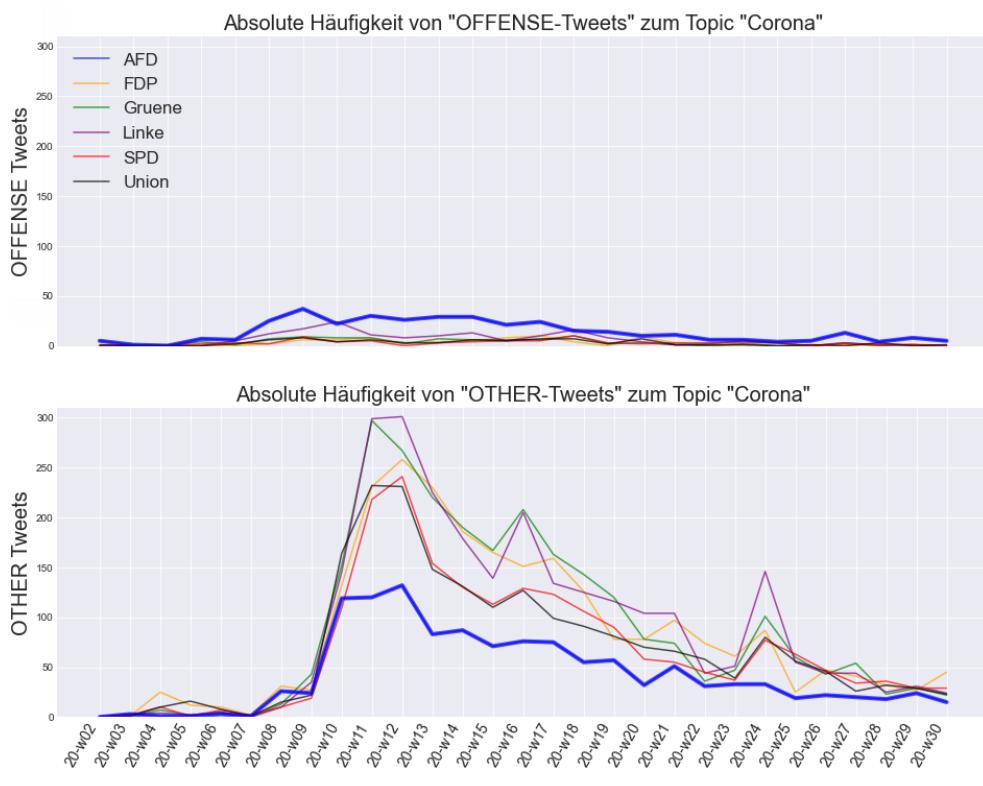


Abbildung 4.19: Tweets zum Topic Corona

Erst Anfang März tweeteten Abgeordnete vermehrt über dieses Thema und dann schnell mit bis zu 300 OTHER-Tweets pro Woche. Anschließend ebbte die Häufigkeit langsam ab. Die AfD war dabei die Partei, die bereits eine Woche vor den anderen ein erhöhtes Tweet-Aufkommen zu diesem Thema zeigte, zu einem großen Teil mit OFFENSE-Tweets. Inhaltlich handelten die Tweets von der Unfähigkeit der großen Koalition, eine solche Krise zu bewältigen und von notwendigen Grenzschießen.

Bei der Überprüfung der Hypothesen H<sub>02</sub>-H<sub>04</sub> geht es darum, den Effekt von Corona auf das Tweet-Verhalten der Abgeordneten zu analysieren. Es

wurde entschieden, sich, wie auch bei den anderen Tests, auf die Anteile der OFFENSE-Tweets an allen Tweets pro Partei, innerhalb einer Woche, zu beziehen.

Da es sich um einen Vorher-Nachher-Vergleich handelt, wird der am Anfang des Kapitels beschriebene Wilcoxon-Vorzeichen-Rang-Test verwendet. Die eine zentrale Voraussetzung für diesen Test ist die gleiche Größe der Stichproben, damit Paare gebildet werden können. Aus diesem Grund wurden für  $H_02$  und  $H_03$  die neun Wochen während des Lockdowns mit den neun Wochen davor ( $H_02$ ) und danach ( $H_03$ ) verglichen. Mit einem  $n = 9$  ist die Stichprobengröße zwar nicht sehr groß, jedoch ausreichend für den Wilcoxon-Vorzeichen-Rang-Test. Für  $H_04$  wurden schließlich die 13 beobachteten Wochen nach dem Lockdown mit den 13 Wochen davor verglichen.

Die Nullhypothese  $H_02$  lautete: Der Anteil von OFFENSE-Tweets vor dem Corona Lockdown ist genauso groß oder kleiner als während des Lockdowns. Die Ergebnisse des beidseitigen Tests sind in Tabelle 4.6 aufgelistet. Für jede Partei konnte festgestellt werden, dass vor dem Lockdown der Anteil an OFFENSE-Tweets größer war als während des Lockdowns. Für AfD, FDP, Grüne und Linke ist dieser Effekt sehr signifikant mit  $p/2 < 0.01$  und einer Effekt-Größe von 1. Dies deckt sich mit der Annahme, dass in normalen Zeiten Oppositionsparteien mehr kritisieren und während der Monate März und April eine große Unsicherheit herrschte, wie genau der richtige Umgang mit einer solchen Krise aussehen sollte. Auch Union ( $0.006 < 0.01$ ) und SPD ( $0.01 < 0.05$ ) versendeten signifikant weniger OFFENSE-Tweets, jedoch war dieser Anteil bereits zuvor bei den Regierungsparteien eher klein, und die Ergebnisse sind dadurch weniger eindeutig.

AFD	FDP	GRÜNE	LINKE	SPD	UNION
W: 0.000	W: 0.000	W: 0.000	W: 0.000	W: 3.000	W: 2.000
p: 0.004	p: 0.004	p: 0.004	p: 0.004	p: 0.020	p: 0.012
RBC: 1.0	RBC: 1.0	RBC: 1.0	RBC: 1.0	RBC: 0.87	RBC: 0.91
MEHR vor LD					

Tabelle 4.6: Wilcoxon-Rang-Test der rel. OFFENSE-Tweets in den neun Wochen vor und während dem Lockdown (LD)

Für kleine Stichprobengrößen kann darüber hinaus die Signifikanz durch den Vergleich mit dem kritischen Wert ermittelt werden. Bei  $n = 9$  und einem einseitigen Test liegt dieser Wert bei 8 (5%), 5 (2.5%), 3 (1%) und 1 (0.5%). Man kommt hierdurch zu den selben Ergebnissen wie mit dem p-Wert, mit dem Unterschied, dass hier auch halbe Prozent angegeben wurden. Beispielsweise liegt bei der SPD W = 3 noch unter dem kritischen Wert 5 und somit das Signifikanzniveau bei 2.5%.

Die Nullhypothese  $H_03$  lautete: Der Anteil von OFFENSE-Tweets nach dem Corona Lockdown ist genauso groß oder kleiner als während des Lockdowns. Demnach wird das neun Wochen Zeitfenster während des Lockdowns dieses mal mit den neun Wochen danach verglichen. Als Gegenhypothese wird vermutet, dass nach dem Lockdown auch der Anteil an OFFENSE-Tweets zugenommen hat.

Die Ergebnisse sind sehr ähnlich zu den unter  $H_02$  gerade beschriebenen. Die Nullhypothese konnte für alle Parteien verworfen werden, und bis auf die Union, für alle mit einer hohen Signifikanz. Betrachtet man den Verlauf der OFFENSE-Tweet Anteile in Abbildung 4.8, so fällt auf, dass die Unterschiede vor und nach dem Lockdown zwischen den Parteien verschieden groß sind. AfD und Linke weisen größere Ausschläge auf als die Grünen oder die SPD. Dieser Unterschied wird jedoch nicht in der Effekt-Größe angegeben. Letztere beschreibt nur den Anteil von Paaren, die für oder gegen die Hypothese sprechen. Die Frage ob beim Vergleich zweier Paare die Differenz des einen deutlich größer war, geht nicht in den RBC Wert mit ein.

AFD	FDP	GRÜNE	LINKE	SPD	UNION
W: 0.000	W: 0.000	W: 0.000	W: 0.000	W: 2.000	W: 6.000
p: 0.004	p: 0.004	p: 0.004	p: 0.004	p: 0.012	p: 0.055
RBC: 1.0	RBC: 1.0	RBC: 1.0	RBC: 1.0	RBC: 0.91	RBC: 0.73
MEHR nach LD					

Tabelle 4.7: Wilcoxon-Rang-Test der rel. OFFENSE-Tweets in den neun Wochen nach und während dem Lockdown (LD)

Die Nullhypothese  $H_04$  lautete: Der Anteil von OFFENSE-Tweets vor dem Corona Lockdown ist genauso groß oder kleiner als nach dem Lockdown. Anhand der Abbildung 4.8, lässt sich die Gegenhypothese aufstellen, dass vor dem Lockdown der Anteil an OFFENDE-Tweets größer war als danach. Dieser Unterschied erscheint weniger eindeutig als bei den beiden zuvor geprüften Hypothesen, was sich auch in den Ergebnissen in Tabelle 4.8 bestätigt.

AFD	FDP	GRÜNE	LINKE	SPD	UNION
W: 5.000	W: 9.000	W: 22.000	W: 11.000	W: 36.000	W: 15.000
p: 0.002	p: 0.008	p: 0.11	p: 0.013	p: 0.541	p: 0.033
RBC: 0.89	RBC: 0.80	RBC: 0.52	RBC: 0.76	RBC: 0.21	RBC: 0.67
Davor	Davor	Gleich o.	Davor	Gleich o.	Davor
MEHR	MEHR	weniger	MEHR	weniger	MEHR

Tabelle 4.8: Wilcoxon-Rang-Test der rel. OFFENSE-Tweets in den 13 Wochen vor und nach dem Lockdown (LD)

Bei 13 Beobachtungen pro Stichprobe sind die kritischen Werte für einen einseitigen Test: 21 (5%), 17 (2.5%), 12 (1%), 9 (0.5%), 7 (0.25%) und 2 (0.05%). Bei den Grünen und der SPD konnte die Nullhypothese nicht zurückgewiesen werden. Für die anderen Oppositionsparteien hingegen, konnte ein sehr signifikanter Unterschied ( $p/2 \leq 0.001$ ) festgestellt werden.

Insbesondere die AfD ist noch nicht bei dem Niveau an relativen OFFENSE-Tweet Häufigkeiten angekommen, das zuvor normal war. Über Gründe, die hierfür in Frage kommen, kann nur spekuliert werden. Sicher ist jedoch, dass das Niveau vor dem Lockdown sehr hoch war. Durch die Regierungskrise in Thüringen tweeteten viele Parteien anteilig besonders viele OFFENSE-Tweets. Ein derartiges Ereignis scheint sich seit dem Lockdown nicht ergeben zu haben. Die Krawallnächte in Stuttgart und Frankfurt, die BLM-Proteste in den USA oder der Wirecard-Skandal waren alle nicht so bestim mend und zu einem großen Teil mit OFFENSE-Tweets beschrieben wie die Regierungskrise oder das Oma-Lied zum Jahreswechsel (siehe Abbildung 4.8).

#### 4.2.4 Plenum Sentiments

Aus den Plenarprotokollen des Bundestages lassen sich vor allem zwei Arten von Texten auslesen, wie sich Abgeordnete im Bundestag äußern. Dies sind zum einen Reden und zum anderen Zurufe. Beides käme für eine Sentimentanalyse in Frage und wurde in dieser Arbeit mit den drei Methoden versucht. Dabei musste jedoch festgestellt werden, dass die vielversprechendste Methode - maschinelles Lernen bei den Redetexten kaum OFFENSE Sätze finden konnte. Dies ergibt natürlich Sinn, da in einer vorbereiteten Rede für gewöhnlich eine eher sachliche und distanzierte Sprache gewählt wird, und Angriffe demnach weniger aggressiv klingen als auf Twitter. Da der Algorithmus außerdem auf Tweets trainiert wurde, und demnach bereits die Anwendung auf diese andere Textart sehr experimentell war, wurde entschieden, diesen Ansatz nicht weiter zu verfolgen und hier nicht auszuführen. Das gleiche gilt für die beiden anderen Methoden TextBlob und Basis Emotionen.

Der Fokus liegt hingegen auf den Zurufen der Abgeordneten, deren absolute Häufigkeit bereits in Kapitel 3.4 analysiert wurde. Die Idee war, dass ein Zuruf einem Tweet nicht unähnlich ist. Häufig sind beide kurz und ohne viel darüber nachzudenken nach außen gedrungen. Entsprechend gut kann der zuvor verwendete Algorithmus auch auf diese Daten angewandt werden.

In Abbildung 4.20 sind die absoluten OTHER- und OFFENSE-Zurufe abgebildet. Dabei wurden die y-Achsen nicht auf das gleiche Niveau skaliert, damit auch für die deutlich seltener vorkommenden OFFENSE-Zurufe, Unterschiede erkennbar sind. Der Zeitraum wurde ähnlich gewählt wie zuvor für die Twitter Daten, von Mai 2019 bis Juli 2020. Anders als zuvor, wurden in dieser Abbildung jedoch nicht Wochen oder Monate abgebildet, sondern ein-

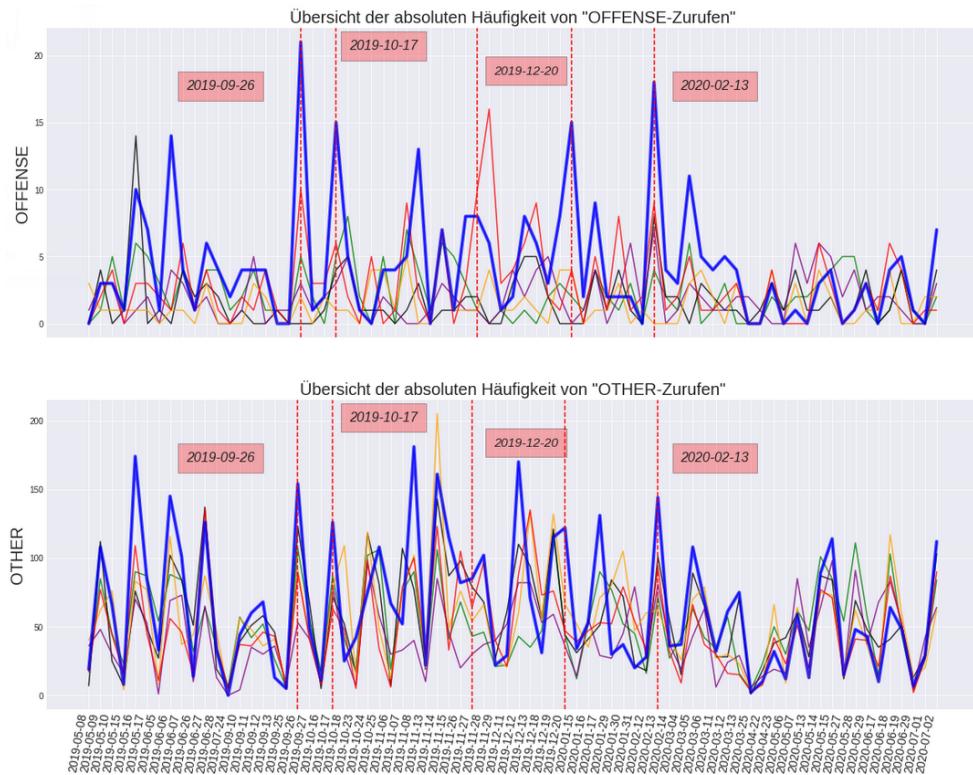


Abbildung 4.20: Übersicht der absoluten OFFENSE und OTHER Werte im Plenum

zelne Tage an denen Sitzungen stattgefunden haben. Da die Tagesordnung und somit die Reden, auf die Zurufe reagieren, sich nicht am Tagesgeschehen orientieren, ist es hier nicht möglich, bestimmte Ereignisse einzutragen, wie dies zuvor der Fall war. Das einzige tagesaktuelle Thema, das sich in dieser Grafik ablesen lässt, ist die geringere Anzahl an OFFENSE-Zurufen ab März 2020.

Um einen Eindruck davon zu bekommen, welche Themen besonders viele Zurufe provozieren, wurden in Abbildung 4.21 die acht Punkte aufgelistet, zu denen es die meisten OFFENSE-Zurufe gab. Dabei wird deutlich, dass dies exakt die Themen sind, die auch auf Twitter zu ähnlichen Reaktionen führen und entsprechend als Topic in dieser Arbeit aufgeführt wurden.

	OTHER	OFFENSE	Beschreibung2
2020-02-13	104.0	16.0	Aktuelle Stunde Nach der Wahl des Thüringer Ministerpräsidenten Thomas Kemmerich – Auswirkungen auf Demokratie und internationale Beziehungen
2019-03-21	93.0	15.0	Aktuelle Stunde Wirken der Bundesregierung im Fall Billy Six
2019-11-27	152.0	14.0	Einzelplan 04 Bundeskanzlerin und Bundeskanzleramt
2019-03-15	98.0	14.0	Aktuelle Stunde Haltung der Bundesregierung zu den Klimastreiks der Fridays-for-Future-Bewegung und der Petition Scientists for Future
2018-11-30	99.0	14.0	Aufforderung zur Abgabe einer Protokollerklärung zur völkerrechtlichen beziehungsweise rechtlichen Unverbindlichkeit des „Global Compact for Safe, Orderly and Regular Migration“ für die Bundesrepublik Deutschland durch die deutsche Bundesregierung bei der Unterzeichnung des Paktes im Dezember in Marrakesch – Die Bundesrepublik Deutschland als „permanent objector“
2019-12-20	82.0	13.0	Wohnungsnot substanzial bekämpfen – Migration als Ursache für Wohnungsnot benennen Anpassung des öffentlichen Baurechts zur Bekämpfung der Obdachlosigkeit
2019-09-26	46.0	13.0	Antifremdensthetischer Grundkonsens in Politik und Gesellschaft – Rechtsstaat und Demokratie schützen – Antifa ächten
2019-10-17	41.0	12.0	Bekämpfung des Antisemitismus nach dem Anschlag auf die Synagoge in Halle

Abbildung 4.21: Ranking der TOPs mit den meisten OFFENSE-Zurufen

Einige der Punkte aus Abbildung 4.21 wurden in der obenstehenden Grafik (Abbildung 4.20) eingetragen. Auch wenn an einem Sitzungstag noch weitere Themen besprochen werden, ist zu erkennen, dass die eingetragenen Daten genau die Spitzen an OFFENSE-Zurufen treffen.

Der größte Ausschlag ist am 26.09.2019 (115. Sitzung) zu erkennen. An diesem Tag wurde über einen Antrag der AfD Fraktion gesprochen, in dem es unter anderem um die Ächtung der Antifa gehen sollte. Es ist wenig überraschend, dass es bei diesem Thema viele OFFENSE-Zurufe gab. Interessant ist dafür, dass das Thema einige Monate später, am 29.06.2019 (167. Sitzung), im Bundestag erneut diskutiert wurde, und eine namentliche Abstimmung stattfand. Das Thema war durch eine Äußerung Trumps auch in Deutschland vermehrt in den Medien, wie bereits in Kapitel 4.1.4 beschrieben wurde. Die Zurufe hielten sich jedoch stark in Grenzen, obwohl auch bei diesem Termin Reden der verschiedenen Parteien im Bundestag gehalten wurden. Ob diese verhaltenen Reaktionen an der baldigen Sommerpause oder an Corona lagen, ist nicht klar. Es ist jedoch auffällig, dass seit dem Lockdown insbesondere die AfD weniger durch OFFENSE-Zurufe aufzufallen scheint.

Weitere Themen, die sowohl auf Twitter als auch im Plenum zu starken Reaktionen geführt haben, sind die Ministerpräsidenten Wahl in Thüringen, Klimaschutz, Migration und Antisemitismus. Ein besonders aufgeladener Tagesordnungspunkt war außerdem der Fall Billy Six. Es handelt sich hierbei um einen rechten Aktivisten der unter anderem für die Junge Freiheit schreibt, ein Blatt das in AfD Kreisen beliebt ist (siehe Abbildung 2.2). Mitte November 2018 wurde er in Venezuela festgenommen und saß bis Mitte März 2019 im Gefängnis. Die Diskussion im Bundestag (89. Sitzung), wenige Tage nach seiner Ankunft in Deutschland, drehte sich um das Thema, ob das Auswärtige Amt sich zu wenig für ihn eingesetzt hat. Obwohl er von der Deutschen Botschaft betreut und viermal im Gefängnis besucht wurde - was über übliche Unterstützung hinaus geht, argumentierte die AfD Fraktion, dass aufgrund seiner Gesinnung gar kein Interesse daran bestanden habe, ihm zu helfen.[71]

Nach dieser grafischen Analyse der Zurufe im Plenum sollen die drei anfangs benannten Hypothesen überprüft werden. In der ersten geht es um den Vergleich zwischen der AfD und den anderen Parteien. Die Nullhypothese lautete: Die Mitglieder der AfD rufen im Parlament zu einem genauso großen oder kleineren Anteil OFFENSE-Zurufe hinein, wie die Mitglieder jeder anderen Partei.

Es handelt sich hierbei um unverbundene Stichproben ( $n = 54$ ), da davon ausgegangen wird, dass die Zurufe der Parteien pro Woche sich untereinander nicht beeinflussen. Aus diesem Grund kann ein Mann-Whitney-U-Test durchgeführt werden. Die Verteilungsparameter können im Appendix in der Tabelle B.1 eingesehen werden, sowie eine Darstellung der dazugehörigen Histogramme. Da diese alle leicht bis stark rechtsschief sind und die Standardabweichungen ähnlich, sind die Voraussetzungen für den Test erfüllt.

Wie bereits für die Twitter Daten, kann auch im Bezug auf die Kommentare im Plenum festgestellt werden, dass die AfD einen signifikant höheren Anteil an OFFENSE-Zurufen als jede andere Partei zu verzeichnen hat. Aus den Ergebnissen in Tabelle 4.9 wird klar, dass es sich bei fast allen Parteien um eine hohe Signifikanz ( $p/2 < 0.001$ ) handelt. Jedoch ist die Effekt-Stärke mit Werten zwischen 0.31 und 0.8 geringer als für den Test mit Twitter Daten.

AFD	FDP	GRÜNE	LINKE	SPD	UNION
U: 1458.	U: 304.5	U: 645.0	U: 795.0	U: 999.0	U: 546.0
p: 0.998	p: 0.000	p: 0.000	p: 0.000	p: 0.005	p: 0.000
RBC: 0.00	RBC: 0.8	RBC: 0.56	RBC: 0.45	RBC: 0.31	RBC: 0.63
Gleich o. weniger	AfD hat mehr				

Tabelle 4.9: Mann-Whitney-U-Test der rel. OFFENSE-Zurufe zwischen AfD und jeder der anderen Parteien

Ho6: Die Mitglieder jeder Partei rufen im Parlament zu einem genauso großen oder größeren Anteil OFFENSE-Zurufe hinein, im Vergleich dazu wie groß ihr Anteil an OFFENSE-Tweets ist.

Auch bei der Überprüfung der Nullhypothese Ho6 handelt es sich um unverbundene Stichproben ( $n = 24$ ), da davon ausgegangen wird, dass die Zurufe der Parteien pro Woche nicht mit der Anzahl an Tweets verbunden ist. Aus diesem Grund wird ebenfalls ein Mann-Whitney-U-Test durchgeführt. Um vergleichbare Stichproben zu erhalten, wurden aus dem Beobachtungszeitraum Mai 2019 - Juli 2020 nur die Wochen ausgewählt, in denen Sitzungen stattgefunden haben. Die Verteilungsparameter für Twitter- und Plenar-Stichprobe können im Appendix in den Tabellen B.2 und B.3 eingesehen werden, sowie eine Darstellung der dazugehörigen Histogramme.

AFD	FDP	GRÜNE	LINKE	SPD	UNION
U: 0.0	U: 42.0	U: 110.5	U: 26.0	U: 287.0	U: 82.0
p: 0.000	p: 0.000	p: 0.000	p: 0.000	p: 0.05	p: 0.000
RBC: 1.00	RBC: 0.85	RBC: 0.62	RBC: 0.91	RBC: 0.00	RBC: 0.72
Mehr OFFENSE Twitter	Mehr OFFENSE Twitter	Mehr OFFENSE Twitter	Mehr OFFENSE Twitter	Gleich o. weniger	Mehr OFFENSE Twitter

Tabelle 4.10: Mann-Whitney-U-Test der wöchentlichen relativen OFFENSE-Zurufe und OFFENSE-Tweets

Es konnte festgestellt werden, dass alle Parteien außer der SPD, einen signifikant höheren OFFENSE-Anteil auf Twitter haben, als im Plenum. Dieses Ergebnis ist in soweit überraschend, als dass Zurufe noch direkter als Tweets geäußert werden - man könnte demnach erwarten, dass negative Emotionen auch deutlicher ausgedrückt werden. Die Faktoren, die dazu führen,

dass soziale Medien enthemmend wirken, sind an dieser Stelle nur teilweise erfüllt. Die Politiker\*innen sind nicht anonym und ein Tweet auf den ein Shitstorm folgt, kann problematisch sein. Eine mögliche Erklärung ist, dass einige OFFENSE-Zurufe nicht als solche erkannt werden, weil es nur eine Entgegnung auf eine Rede-Passage ist. Möglicherweise könnten durch einen eigens gelabelten Datensatz manche dieser Muster gelernt werden - teilweise dürfte es jedoch auch für Menschen schwer sein, zu unterscheiden, was als OFFENSE gelabelt werden kann.

Die letzte hier betrachtete Nullhypothese H<sub>0</sub>7 lautet: Der Anteil von OFFENSE-Zurufen vor Corona ist genauso groß oder kleiner als währenddessen. Die Tendenz konnte bereits in Abbildung 4.20 am Anfang des Kapitels beobachtet werden. In dieser Abbildung wurde OFFENSE- und OTHER-Zurufe mit absoluten Werten dargestellt, wobei unsicher ist, ob ein Rückgang auch durch weniger Zurufe insgesamt verursacht sein kann. Um dies auszuschließen, wird der Wilcoxon-Rang-Test, wie bereits zuvor, auf Basis der relativen OFFENSE-Zuruf-Häufigkeiten durchgeführt. Es handelt sich um verbundene Stichproben, weshalb beide die gleiche Anzahl Beobachtungen enthalten müssen. Im Gegensatz zu den bisher durchgeföhrten Test, werden an dieser Stelle Tage und nicht Wochen betrachtet, da andernfalls die Stichprobengröße zu klein werden würde. Es werden 18 Sitzungstage vor und ab dem 13.03.2019 gegenübergestellt.

AFD	FDP	GRÜNE	LINKE	SPD	UNION
U: 27.0	U: 48.0	U: 51.0	U: 69.0	U: 44.0	U: 76.0
p: 0.009	p: 0.301	p: 0.609	p: 0.723	p: 0.124	p: 0.702
RBC: 0.68	RBC: -0.3	RBC: 0.15	RBC: -0.1	RBC: 0.42	RBC: 0.11
MEHR vor LD	Gleich o. weniger				

Tabelle 4.11: Wilcoxon-Rang-Test der relativen OFFENSE-Zurufe an 18 Sitzungstagen vor und während Corona

Es konnte nachgewiesen werden, dass die AfD seit Corona einen signifikant ( $p/2 < 0.01$ ) kleineren Anteil an OFFENSE-Zurufen aufweist. Für die anderen Parteien war hingegen kein Unterschied nachweisbar.

## FAZIT UND AUSBLICK

---

Immer mehr Abgeordnete des deutschen Bundestages kommunizieren per Twitter, und es konnte gezeigt werden, dass sich hier entlang der Parteilinien deutliche Unterschiede ergeben. Die Regierungsparteien Union und SPD, haben den geringsten Anteil an Twitternutzer\*innen und außerdem tendieren sie nicht dazu, OFFENSE-Tweets zu versenden. Dies tun vermehrt die Parteien an den Rändern - Die Linke und insbesondere die AfD. Vergleicht man den durchschnittlichen Anteil von OFFENSE-Tweets an allen Tweets einer Partei, so lag die AfD mehr als zweieinhalfach über dem Niveau der Linken. Es wurde nachgewiesen, dass diese Unterschiede zwischen der AfD und jeder anderen Partei im betrachteten Zeitraum Mai 2019 bis Juli 2020, hoch signifikant waren.

Betrachtet man typische Themen der AfD wie Migration, Linksextremismus, oder Öffentlich-Rechtliche, so fällt hier der besonders hohe Anteil an OFFENSE-Tweets auf. Ganz anders verhält es sich beispielsweise bei den Grünen, die zwar besonders viel über das Klima tweeten, jedoch ohne die gleiche aggressive Wortwahl. Diesen Unterschied in Wortwahl und Fokus der Parteien konnte man besonders gut bei traurigen Anlässen wie den Anschlägen in Hanau und Halle beobachten. Grüne und SPD kommunizieren Mitgefühl und Zusammenhalt gegen Gewalt. Die Linke twittert gegen die AfD, während diese das Versagen der Institutionen beklagt.

Das Thema, das ganz besonders für Empörung gesorgt hat, war die Regierungskrise in Thüringen Anfang 2020. Kein anderes Thema hat zu so vielen OFFENSE-Tweets der verschiedenen Parteien geführt wie dieses. Dabei liegt außerdem die Schlussfolgerung nahe, dass Themen wie eine Wahl zu deutlich stärkeren Resonanzen bei den Politiker\*innen führen, als beispielsweise wirtschaftliche Themen. Das ist auf der einen Seite nachvollziehbar, schließlich ist ersteres das zentrale Element der Demokratie und die Basis, auf der Politiker\*innen ihre Arbeit ausführen. Gleichzeitig ist es überraschend, wenn man den CumEx- oder Wirecard-Skandal fast nicht auf der OFFENSE-Tweet Grafik erkennt.

Es konnte außerdem gezeigt werden, dass die gleichen Themen, die auch auf Twitter zu höheren OFFENSE-Anteilen führen, dies ebenso im Parlament tun. Die AfD verzeichnet auch hier einen signifikant höheren Anteil an OFFENSE-Zurufen als jede andere Partei.

Besonders interessant waren in diesem Zusammenhang die Ergebnisse zu den Auswirkungen der Corona Pandemie. Es wurde überprüft, ob die Parteien während des Lockdowns zurückhaltender tweeten als zuvor, und ob nach dem Lockdown der Anteil an OFFENSE-Tweets wieder anstieg. Dies konnte jeweils mit hoher Signifikanz bewiesen werden. Weniger eindeutig

war das Bild hingegen im Parlament, hier war nur der AfD nachzuweisen, dass signifikant weniger OFFENSE-Zurufe als vor der Pandemie aus der Fraktion kamen.

Neben diesen Ergebnissen haben sich während der Auswertung der Plenar- und Twitter Daten neue Fragestellungen ergeben, die viel Potenzial für weitere spannende Forschungsarbeiten bieten. Dieses Potenzial kann grob unterteilt werden, in "Verbesserung und Erweiterung des bestehenden Ansatzes" auf der einen, und "Ausweitung der Forschung auf neue Datenquellen" auf der anderen Seite.

Wie zuvor beschrieben, wurde bei der Erstellung des Trainingsdatensatzes darauf geachtet, möglichst keinen Bias einfließen zu lassen. Allerdings war der Fokus von GermEval nicht exakt deckungsgleich mit dieser Arbeit. Aus diesem Grund könnte es sich lohnen, ein ähnliches Vorgehen mit Tweets von Politiker\*innen zu wählen und dabei zum Beispiel eine genauere Unterscheidung von Labels zu definieren. Drohungen und krasse Beleidigungen sind bei Abgeordneten sehr selten, und daher ist die detaillierte Differenzierung von GermEval hier wenig hilfreich. Dagegen könnte die Emotion Angst als Label interessant sein, um abzubilden, dass AfD-Politiker\*innen diese scheinbar besonders oft durch ihre Wortwahl anfachen. Zu diesem Ergebnis kam Christina Schönborn in ihrer Arbeit mit der Methode der Basis Emotionen und es wäre interessant, diese Ergebnisse mit maschinellem Lernen zu überprüfen.<sup>[53]</sup> Der auffällige und gezielte Einsatz bestimmter Wörter wie Staatsfunk, Mauermörderpartei oder Altparteien, ist dabei ebenfalls ein wichtiges Thema. Es muss natürlich vermieden werden, dass nur anhand dieser Wörter zum Beispiel negative Label vergeben werden. Gleichzeitig könnte eine Analyse dieses Einsatzes von Wortschöpfungen bestimmter Politiker\*innen weitere interessante Einblicke in die Kommunikation von Abgeordneten bieten.

Noch größere Vorteile dürfte eine Verbesserung der Trainingsdaten bei der Analyse von Plenarprotokollen bieten. Wie bereits zuvor beschrieben, sind Tweets den Zurufen im Bundestag nicht ganz unähnlich, und dieser Ansatz konnte in dieser Arbeit brauchbare Ergebnisse liefern. Jedoch ist zu erwarten, dass ein Trainingsdatensatz, bestehend aus Zurufen mit speziellen Labels, noch genauere Resultate liefern würde. Ob ein eigener Trainingsdatensatz für die Analyse von Reden ausreicht, oder ob vielmehr eine andere Methode notwendig wäre, sollte ebenfalls geprüft werden. Die mehrfach erwähnten Recherchen der Süddeutschen Zeitung und auch der Zeit, konzentrierten sich im ersten Halbjahr 2020 auf die Reden in Plenarprotokollen. Dabei stand jedoch die Häufigkeit einzelner Worte und deren Verbindung untereinander im Fokus, eine echte Herausarbeitung von Emotionen (Sentiment Analyse) wurde nicht veröffentlicht.<sup>[54][9]</sup>

Die hier verwendeten Methode auf Basis von vortrainierten Word2Vec Word Embeddings und einer Logistischen Regression als Klassifizierer war nur eine von vielen vielversprechenden Ansätzen der Teilnehmer von GermEval 2018. Andere Gruppen setzten stärker auf Neuronale Netze wie CNNs oder LSTMs und erreichten ähnlich gute Ergebnisse. Sowohl die Adaption einer dieser Methoden als auch Experimente mit Kombinationen der verschiedenen Ansätze, könnte zu spannenden neuen Erkenntnissen führen.

Gerade der Fokus auf die Ministerpräsidentenwahl in Thüringen hat die Notwendigkeit gezeigt, sich auch auf Landesebene mit diesem Thema auseinander zusetzen. Eine solche Untersuchung könnte zeigen, ob die Kommunikation sich verändert, wenn das Parlament stärker polarisiert ist. Hier dürfte die Auswertung jedoch deutlich schwieriger werden, da die Landesparlamente sehr heterogene Protokollformate zur Verfügung stellen.

Ähnlich spannend und potenziell schwerer zugänglich als Tweets sind andere soziale Medien. Facebook wurde hier bereits häufig als Quelle genutzt, anders steht es mit relativ neuen Kanälen wie TikTok[7]. Noch dürfte die Anzahl der vertretenen Politiker\*innen bei diesem Dienst gering sein, jedoch gerade bei der Ansprache junger Wähler, könnte dieser Dienst zukünftig interessanter werden.

Während in dieser Arbeit der Fokus auf Aggression im Parlament und auf Twitter lag, interessiert bei politischen Entscheidungsträgern natürlich insbesondere das Ergebnis von Abstimmungen. Wenn Abgeordnete starke Verbindungen in bestimmte Branchen der Privatwirtschaft haben, ist zu vermuten, dass sich diese in Reden, Kommentaren und in Abstimmungen abbilden. Da entsprechende Register weiterhin nicht ausreichend detailliert gepflegt sind, wäre auch bei diesem Ansatz, die Erstellung des Datensatzes stand heute sehr schwer. Zum Zeitpunkt des Abschlusses dieser Arbeit, Ende September 2020, wird im Bundestag über die konkrete Ausgestaltung eines Lobbyregisters diskutiert. Trotz berechtigter Sorge von abgeordnetenwatch.de und LobbyControl ist zu hoffen, dass die Lösung am Ende alle notwendigen Informationen enthalten wird. Im besten Fall werden diese Daten in maschinenlesbaren Formaten veröffentlicht.[36]

Teil II

APPENDIX

# A

## WEITERE CODE LISTINGS

---

Listing A.1: Duplikate entfernen

```
db.Twitter_mdp_extend.aggregate([
  {
    "$group": {
      _id: {id: "$id"},
      dups: { $addToSet: "$_id" } ,
      count: { $sum : 1 }
    }
  },
  {
    "$match": {
      count: { "$gt": 1 }
    }
  }
],{
  allowDiskUse : true,
}).forEach(function(doc) {
  doc.dups.shift();
  db.Twitter_mdp_extend.remove({
    _id: {$in: doc.dups}
  });
})
```

Listing A.2: Umformatieren des Felds created\_at in datetime Format

```
db.Twitter_mdp_extend.aggregate([
  {
    '$addFields': {
      'created_at_datetime': {
        '$toDate': '$created_at'
      }
    }
  },
  {
    '$out': 'Twitter_mdp_extend_datetime'
  }
])
```

Listing A.3: Entschachteln von Collection und Selektion von Feldern

```
db.Twitter_mdp_extend_datetime.aggregate([
  {
    $project: {
      _id: 1, id: 1, created_at: 1, created_at_datetime: 1, full_
      text: 1, is_quote_status: 1, lang: 1, retweet_count: 1,
```

```

        user_id: "$user.id", user_name: "$user.name", user_
        screen_name: "$user.screen_name", user_location: "$user.
        location", user_description: "$user.description", user_
        followers_count: "$user.followers_count", user_friends_
        count: "$user.friends_count", user_created_at: "$user.
        created_at", retweeted_full_text: "$retweeted_status.
        full_text", retweeted_id: "$retweeted_status.id",
        retweeted_user_screen_name: "$retweeted_status.user.
        screen_name", retweeted_user_id: "$retweeted_status.user
        .id (http://retweeted_status.user.id)", retweeted_
        created_at: "$retweeted_status.created_at",
    }
}, {
    $out: 'twitter_mdp_ex_date_proj'
}
])

```

Listing A.4: Feld 'user\_party' für jeden Tweet hinzufügen

```

db.twitter_mdp_ex_date_proj.aggregate(
[{
    $match: {
        "user_party": {
            $exists: false
        }
    }
}, {
    $lookup: {
        from: 'parteizuordnung',
        localField: 'user_screen_name',
        foreignField: 'Name',
        as: 'partei'
    }
}, {
    $unwind: {
        path: "$partei",
        preserveNullAndEmptyArrays: true
    }
}, {
    $addFields: {
        user_party: "$partei.Partei"
    }
}]
).forEach(function (x){db.twitter_mdp_ex_date_proj.save(x)})

```

Listing A.5: Backup und übertragen

```

mongodump -d Twitter -o "/home/lisa/Darmstadt/Master Arbeit/05_Data/API/
    Backup"
mongorestore -d Twitter -c twitter_mdp_ex_date_proj '/home/lisa/
    Darmstadt/Master Arbeit/05_Data/API/Backup/Twitter/twitter_mdp_ex_
    date_proj.bson'

```

## ZUSÄTZLICHE GRAFIKEN

### B.1 NACHSTELLEN DER SZ STUDIE

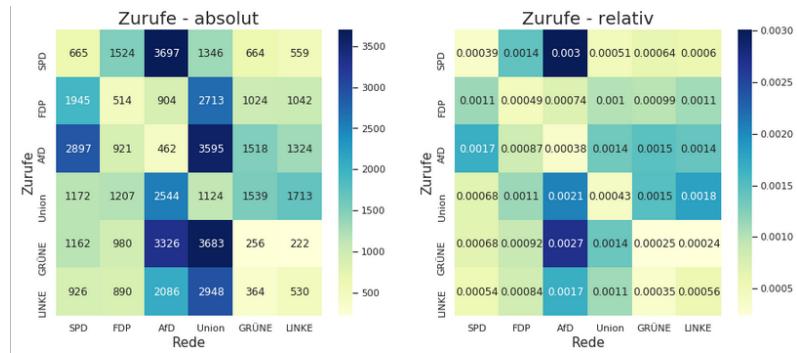


Abbildung B.1: Absolute/relative Darstellung von Zurufen

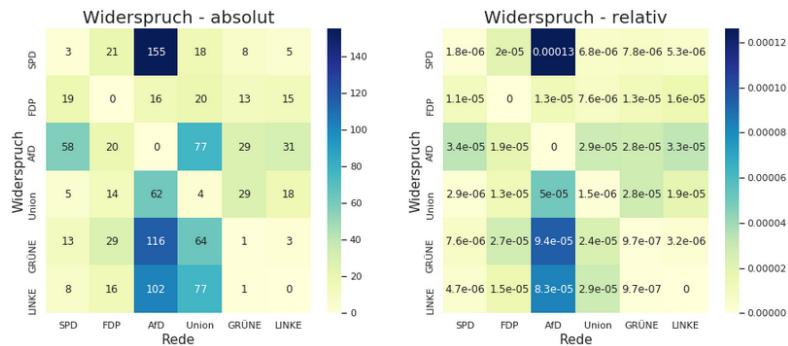


Abbildung B.2: Absolute/relative Darstellung von Widerspruch

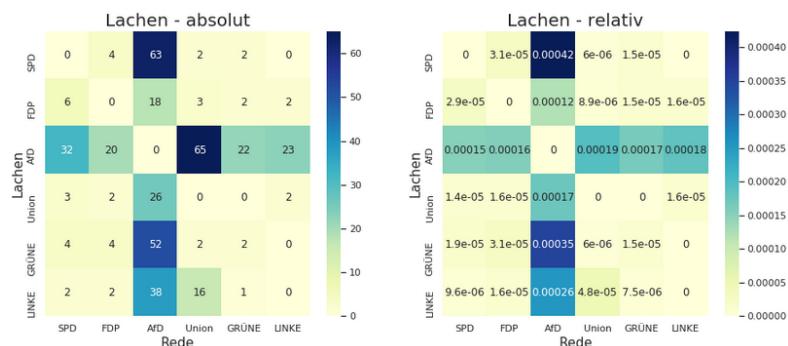


Abbildung B.3: Absolute/relative Darstellung von Lachen im ersten halben Jahr



Abbildung B.4: Häufigkeiten der Reaktionen im ersten halben Jahr

### Wer lacht für wen?

Je dunkler die Farbe, desto häufiger wurde gelacht.

1-10 ■ 11-23 ■ 24-34 ■ 35-48 ■ 49-68

Diese Fraktionen lachen über die Redner

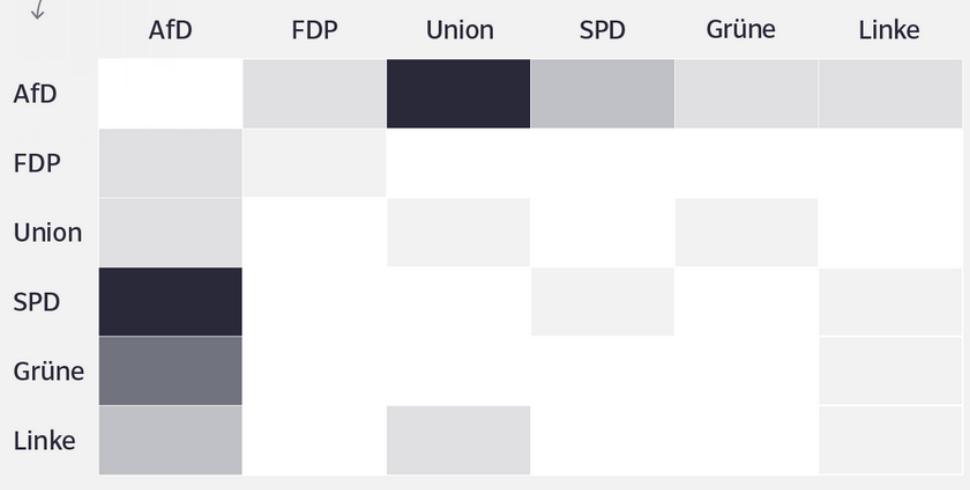


Abbildung B.5: Lachen als Mittel sich über das Gesagte lustig zu machen[31]

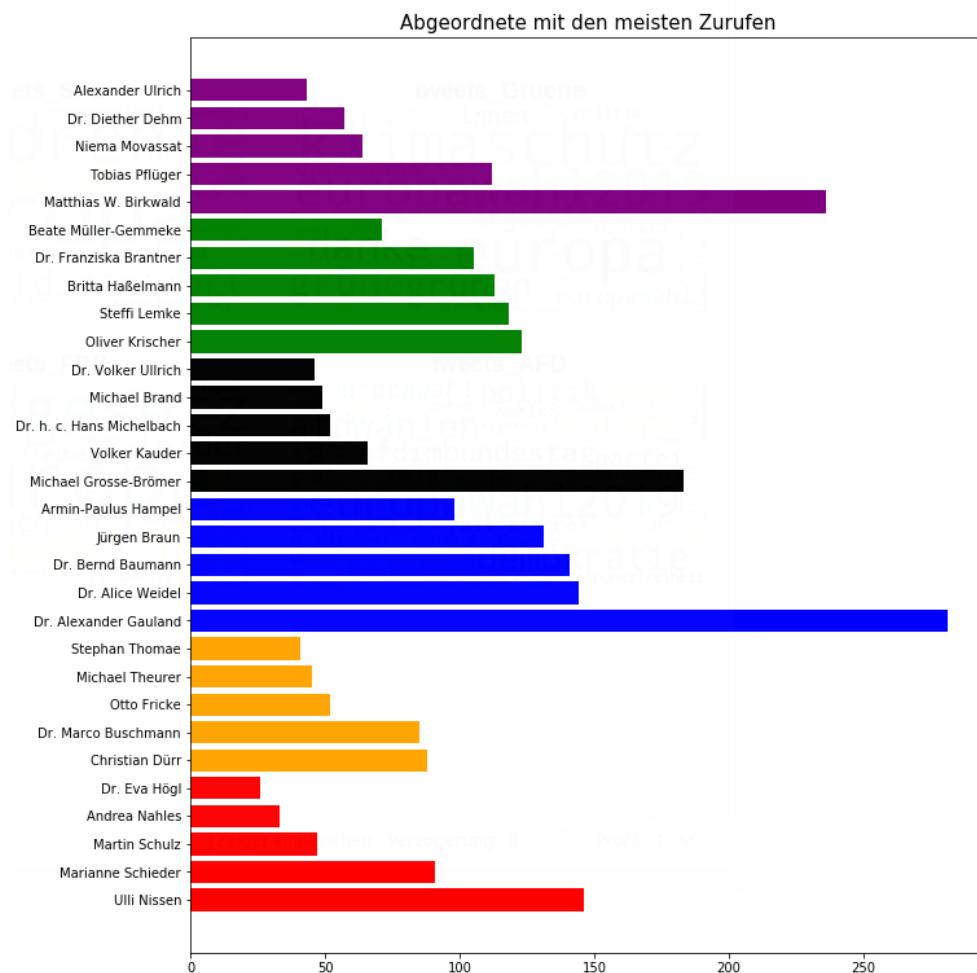


Abbildung B.6: Abgeordneten mit den meisten Zurufen - eigene Darstellung



Abbildung B.7: Abgeordneten mit den meisten Zurufen[31]

## B.2 SENTIMENT ANALYSE ERGEBNISSE

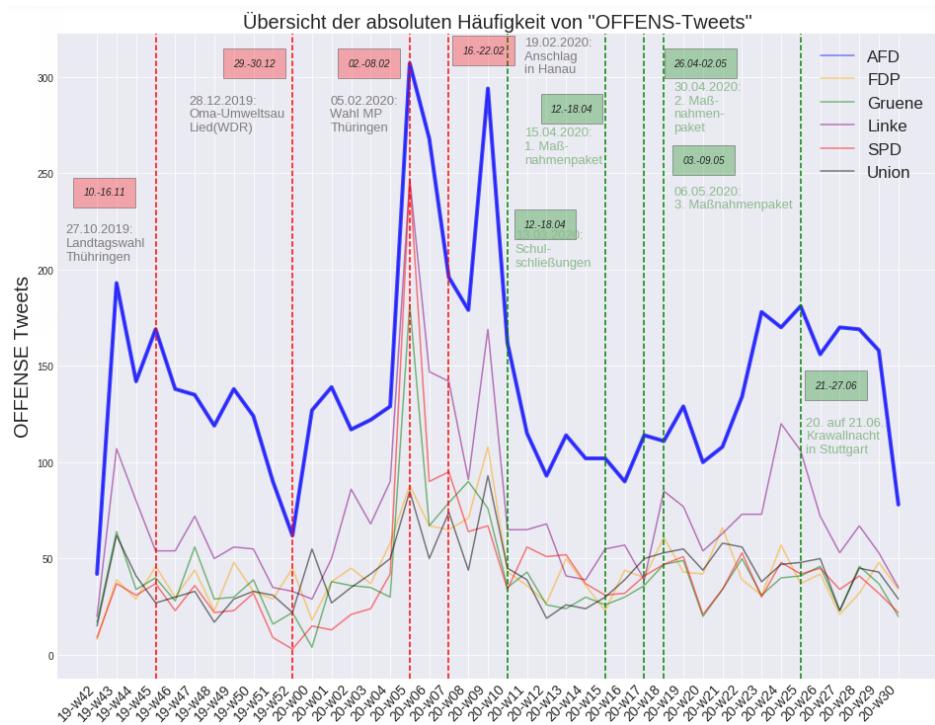


Abbildung B.8: Absolute Häufigkeit von OFFENSE-Tweets

date	full_text_processed	User	Partei	predict	Polarity	Eke	Fre	Fur	Tra	Übe	Ver	Wut
2020-01-21	diese un-entscheidung darf nicht maßgeblich für deutsche politik gesetzgebung werden wir können keine weiteren asylbewerber aus kaum beweis-/ kalkulierbaren erwägungen behalten sondern müssen vor ort helfen schliess mit der aufweichung des asylrechts	Martin_Hess_AfD	AFD	OTHER	0.350000	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2019-10-27	wenn aktivisten in den redaktionsstuben das kommando übernehmen bleibt der journalismus eben auf der strecke hauptsache die gesinnung stimmt gensing relotius	GtzFrmming	AFD	OFFENSE	0.000000	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2020-05-27	aber ganz knapp ☺	StBrandner	AFD	OTHER	0.000000	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2020-05-29	eine verhöhnung der bundeswehr evahögl ist nun wehrbeauftragte ohne jegliche qualifikation für das amt kollege geroldotten wurde abgelehnt obwohl er als offizier kpilot etc hochqualifiziert ist der groko geht es nicht um unser land / q	TobiasMPeterka	AFD	OFFENSE	-1.000000	0.0	0.0	0.0	0.0	0.0	1.0	0.0
2019-06-17	die ekd-oberen drehen offenbar langsam durch wenn jemand sagt ich bin zuerst deutscher und dann christ dann ist das ketzerle schlichtweg peinlich solche dummen sprüche	JuergenBraunAfD	AFD	OFFENSE	-0.800000	0.0	0.0	0.0	0.0	0.0	3.0	0.0
2019-07-02	ich hoffe immer noch ein wenig dass die briten in der eu bleiben aber diese aktion im parlament zeigt dass viele sich einfach nur wie verzogene kleine kinder benehmen und wenn der brexit doch kommt die freundschaft mit den briten werden wir bewahren 🇬🇧	SteinekeCDU	Union	OFFENSE	0.350000	0.0	0.0	0.0	0.0	0.0	2.0	0.0
2020-04-21	interessante analyse über robert habeck und die grünen	SteinekeCDU	Union	OFFENSE	1.000000	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2019-11-11	dagatagermany baks_sprecher	RKliesewetter	Union	OTHER	0.000000	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2019-11-25	reg_nerd winfriedveil lopalasi malteengeler cdu tschipanski hansjoerg_durz nadineschoen schau doch einfach in den beschluss	tj_tweets	Union	OTHER	0.700000	0.0	0.0	1.0	0.0	0.0	1.0	0.0
2020-03-21	ich stehe im ständigen austausch ua mit der dt hauptstelle für suchtfragen klar ist diese corona ausnahmesituation ist gerade auch für suchtkranke extrem belastend umso wichtiger dass unterstützungsangebote jetzt nicht unter die räder kommen	DaniLudwigMdB	Union	OTHER	0.233333	0.0	0.0	0.0	0.0	0.0	1.0	1.0

Abbildung B.9: Zufällige Auswahl gelabelter Tweets von Union und AfD

date	full_text_processed	User	Partei	predict	Polarity	Eke	Fre	Fur	Tra	Übe	Ver	Wut
2020-02-01	herzlichen glückwunsch an amica zum diesjährigen göttinger friedenspreis	JTrittin Gruene	OTHER	1.000000	0.0	2.0	0.0	0.0	0.0	0.0	0.0	0.0
2019-08-06	dass schwere suvs als plug-in-hybride mit e-kennzeichen herumfahren ist reiner etikettenschwindel mit mini-elektrischen reichweiten ist der umweltvorteil in praxis kaum vorhanden bringen elektromobilität in misskredit kaufprämie nicht gerechtfertigt	Stephankuehn Gruene	OTHER	-0.250000	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2019-10-15	die bundesregierung muss tunenien jetzt ausreichend unterstützung zur verfügung stellen sein noch junges demokratiscs system weiter zu stabilisieren auf keinen fall dürfen reformen zu einem rückfall in autoritäre verhältnisse führen wahl	nouripour Gruene	OTHER	0.133333	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2020-05-06	wir wiederlich antidemokratisch	DJanecek Gruene	OFFENSE	-1.000000	1.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0
2019-10-16	keine klare aussage der breg zu den rüstungsexporten in die türkei wir brauchen einen kompletten stopp doch das kanzleramt hbraun kann sich nicht mal durchringen die aussage v helikomaas zu unterstützen1/zrojava	Katdro Gruene	OTHER	-0.500000	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2019-09-20	hat die groko etwa angst zum heutigen klimastreik ihr scheitern in der klimakrise einzugestehen ehrlich wär's denn alle versprechungen waren bisher nur heiße luft systemchangenotclimatechange allefuersklima fridaysforfuture climatestrike	NicoleGohlike Linke	OTHER	1.000000	0.0	0.0	1.0	1.0	0.0	0.0	0.0	0.0
2019-07-03	danke an franziska und kevin vom drk_rdmh drk rettungsdienst mittelhessen ich habe heute sehr viel gelernt und bin tief beeindruckt von eurem ruhigen und warmherzigen engagement für menschen in akuten notsituationen	AchimKesslerMdB Linke	OTHER	0.000000	0.0	1.0	0.0	0.0	1.0	0.0	0.0	0.0
2019-10-07	eindrucksvolle doku zum mietenwahnsinn zur besten sendezzeit der wohnungs'markt wird mit regierungshilfe für die mega-rendite von anonymen geldsäcken geflutet mietet entretet vertrieben was tun mietendeckel preisregulierung öffentlicher sektor	victorperli Linke	OFFENSE	1.000000	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
2020-03-13	unbedingt gerade auch für viele kreative in halle existenziell wichtig ich hoffe dass tatsächlich konkret etwas von dem geld bei den betroffenen ankommt	Petra_Sitte_MdB Linke	OTHER	0.175000	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0
2019-05-28	cos_meyer linksfaktion für alleinerziehende wollen wir einen anspruch auf 24 monate elterngeld mehr zu unserem konzept nicht so klar	Katrin_Werner Linke	OTHER	0.000000	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0

Abbildung B.10: Zufällige Auswahl gelabelter Tweets der Grünen und der Linken

## B.3 WORDCLOUDS



Abbildung B.11: Wordclouds der AfD Tweets nach Monaten unterteilt

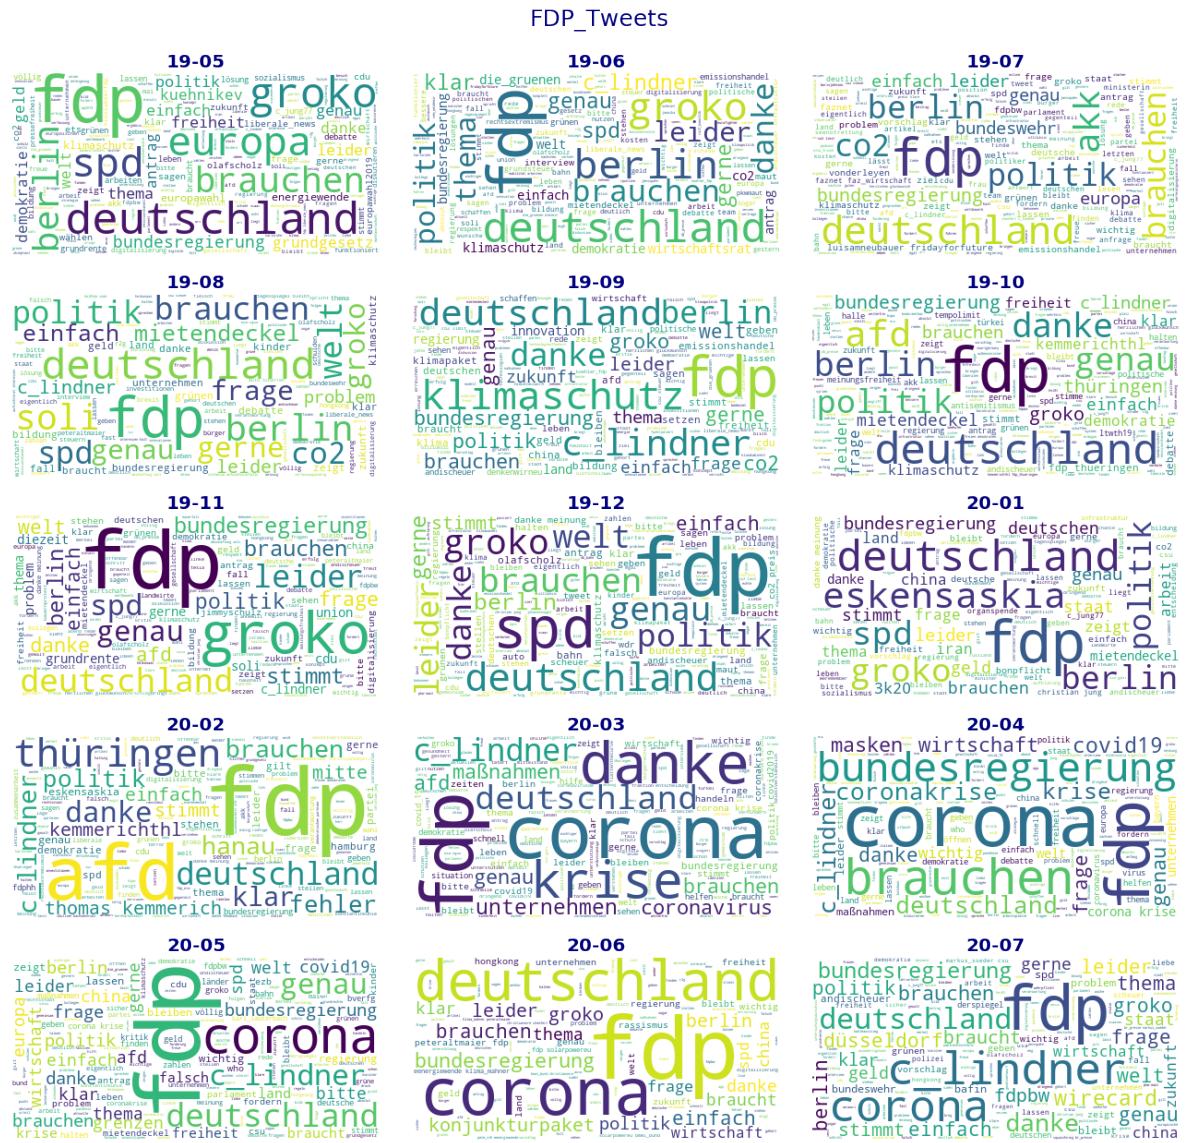


Abbildung B.12: Wordclouds der FDP Tweets nach Monaten unterteilt

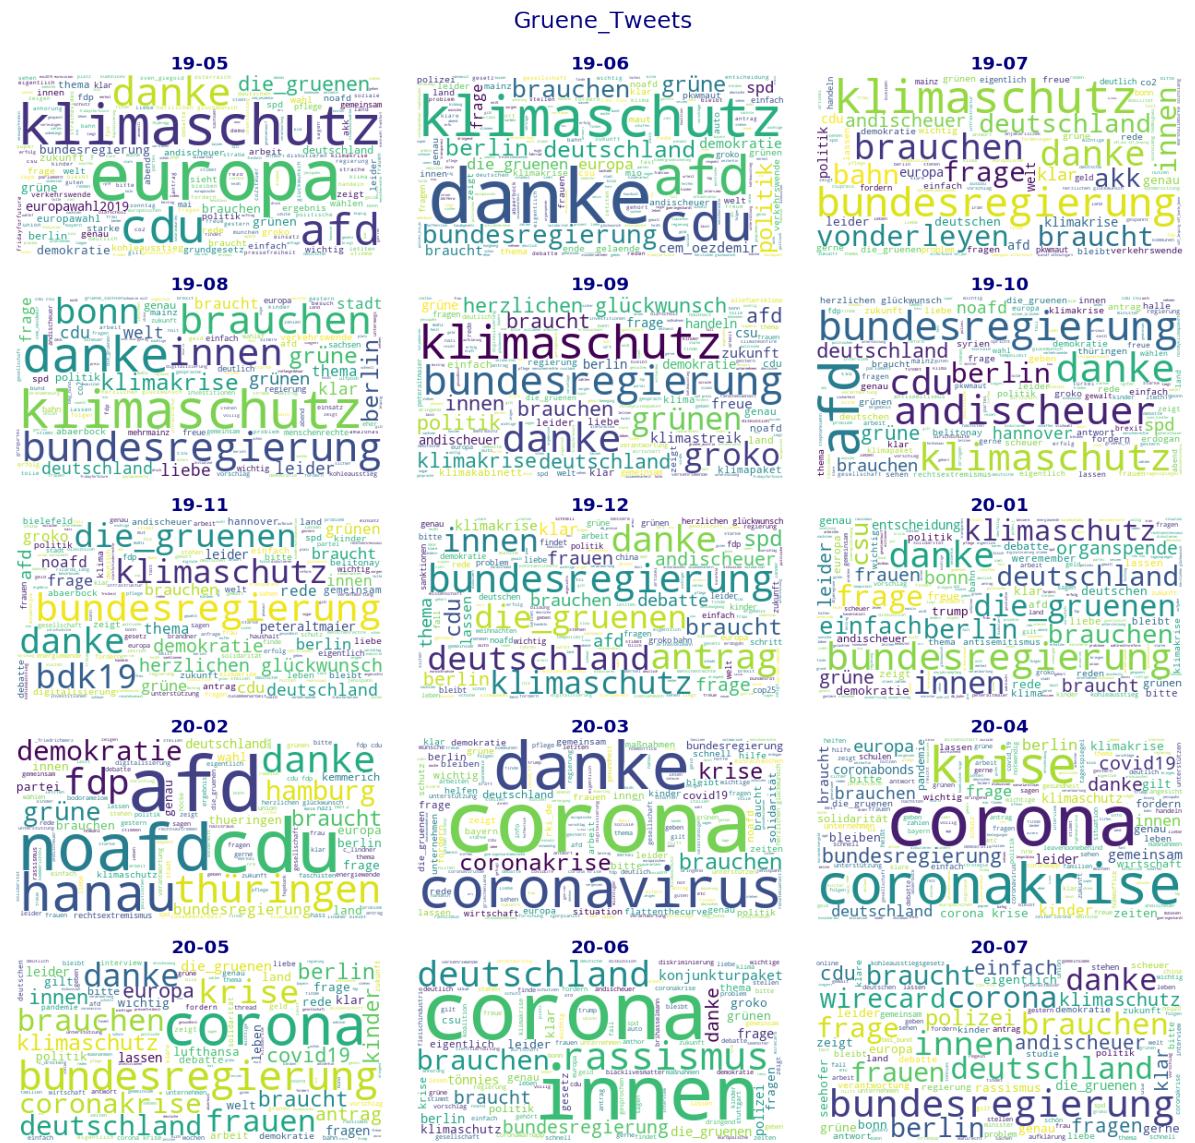


Abbildung B.13: Wordclouds der Grünen Tweets nach Monaten unterteilt



Abbildung B.14: Wordclouds der Linken Tweets nach Monaten unterteilt

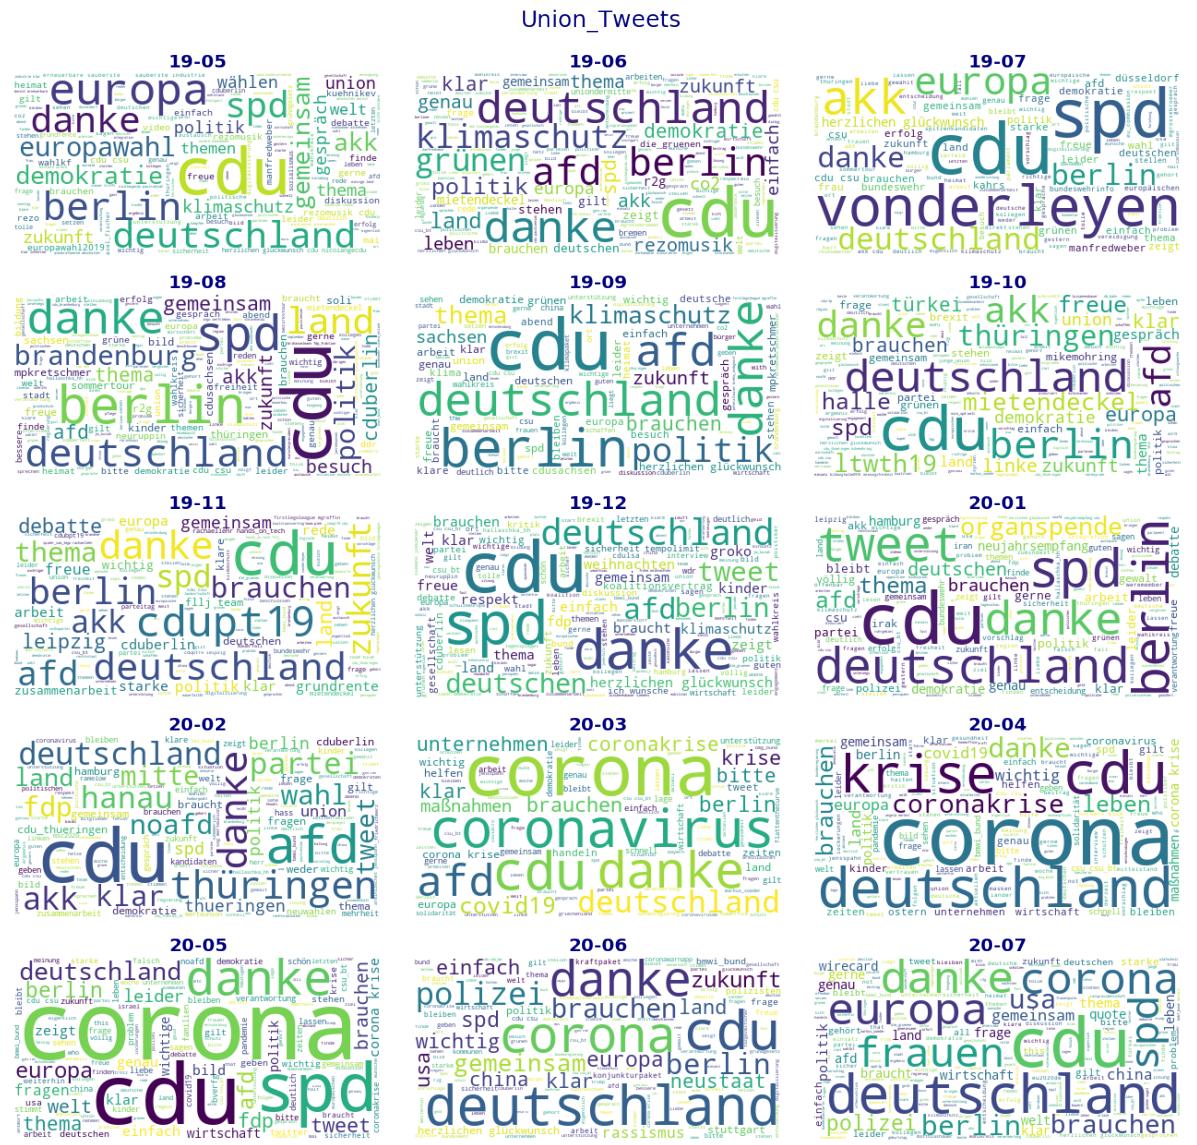


Abbildung B.15: Wordclouds der Union Tweets nach Monaten unterteilt

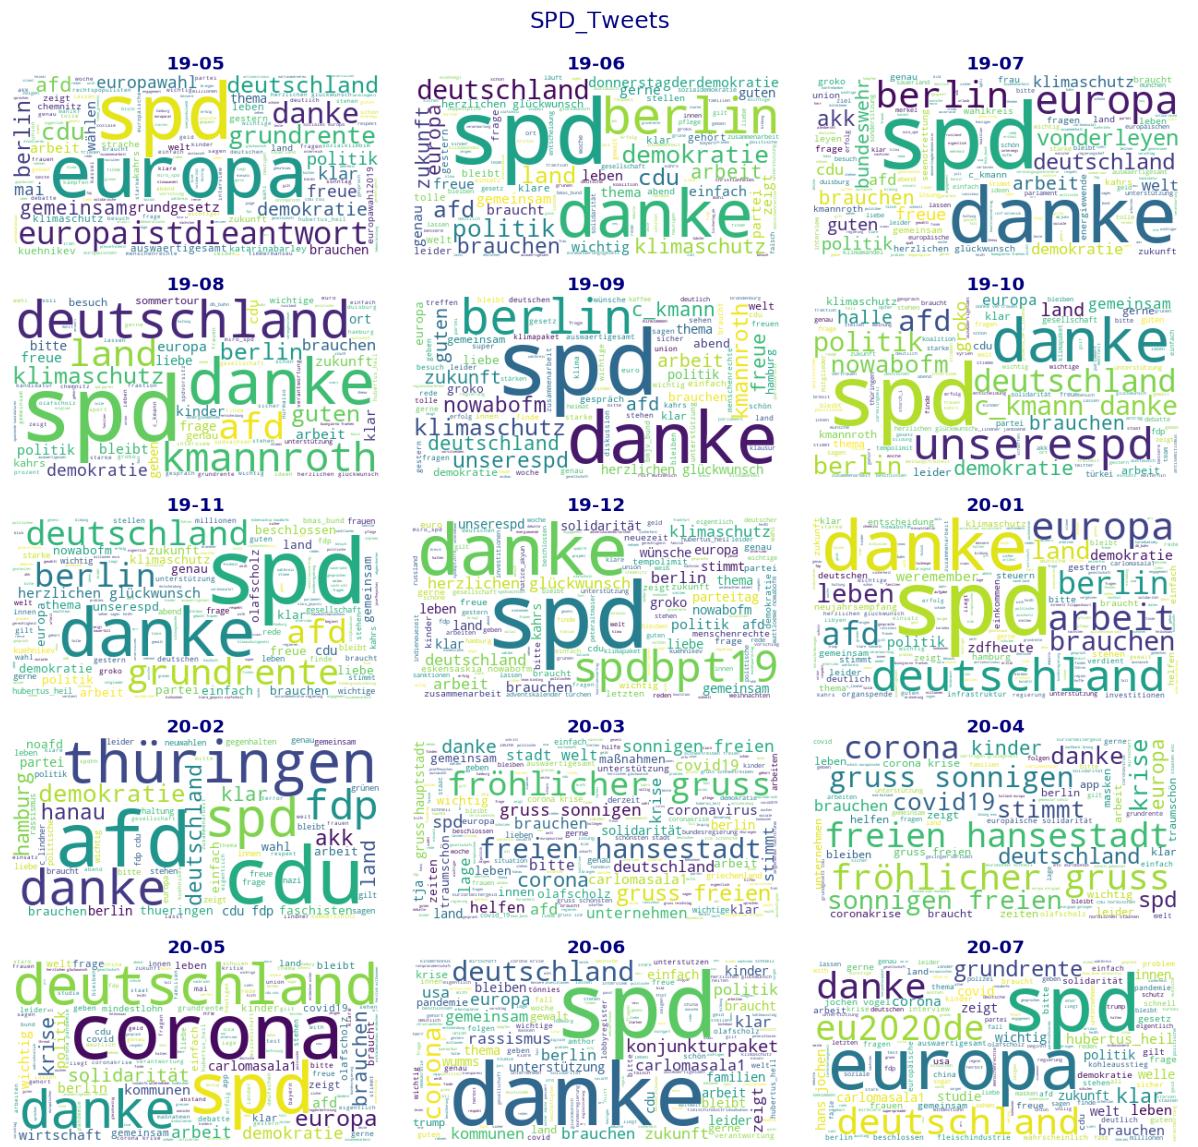


Abbildung B.16: Wordclouds der SPD Tweets nach Monaten unterteilt

## B.4 HYPOTHESENTESTS

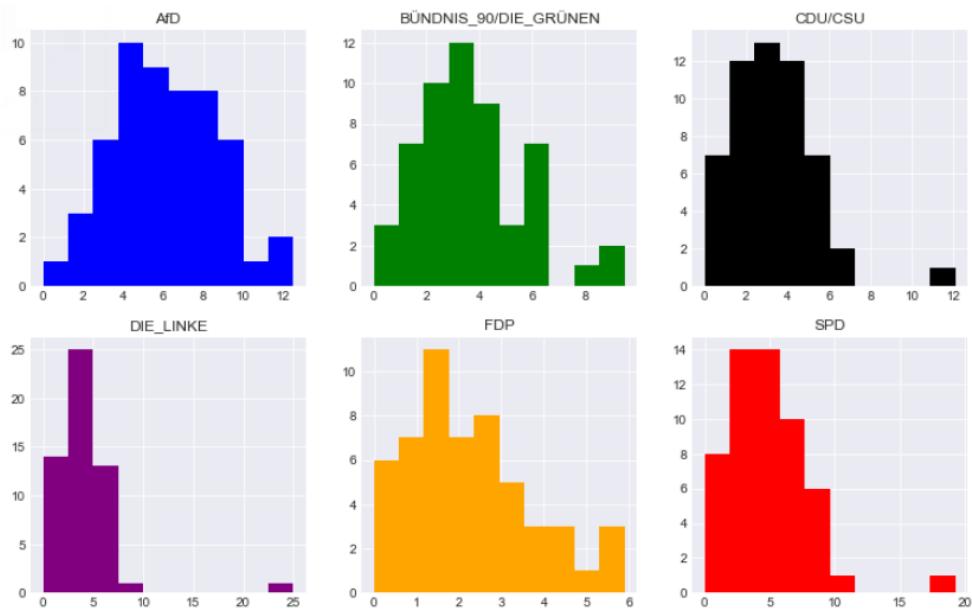


Abbildung B.17: Histogramme der relativen OFFENSE-Zuruf Häufigkeit pro Woche

	AFD	FDP	GRÜNE	LINKE	SPD	UNION
Mean	6.143	2.261	3.676	4.426	4.82	3.347
Std.	2.624	1.515	2.016	3.419	3.162	2.047

Shapiro Wilk Test	W: 0.994, p: 0.995 Gaussian	W: 0.956, p: 0.046 NOT Gaussian	W: 0.950, p: 0.026 NOT Gaussian	W: 0.650, p: 0.000 NOT Gaussian	W: 0.883, p: 0.000 NOT Gaussian	W: 0.909, p: 0.001 NOT Gaussian
----------------------	-----------------------------------	---------------------------------------	---------------------------------------	---------------------------------------	---------------------------------------	---------------------------------------

Tabelle B.1: Verteilungsparameter und Test auf Normalverteilung - Plenum

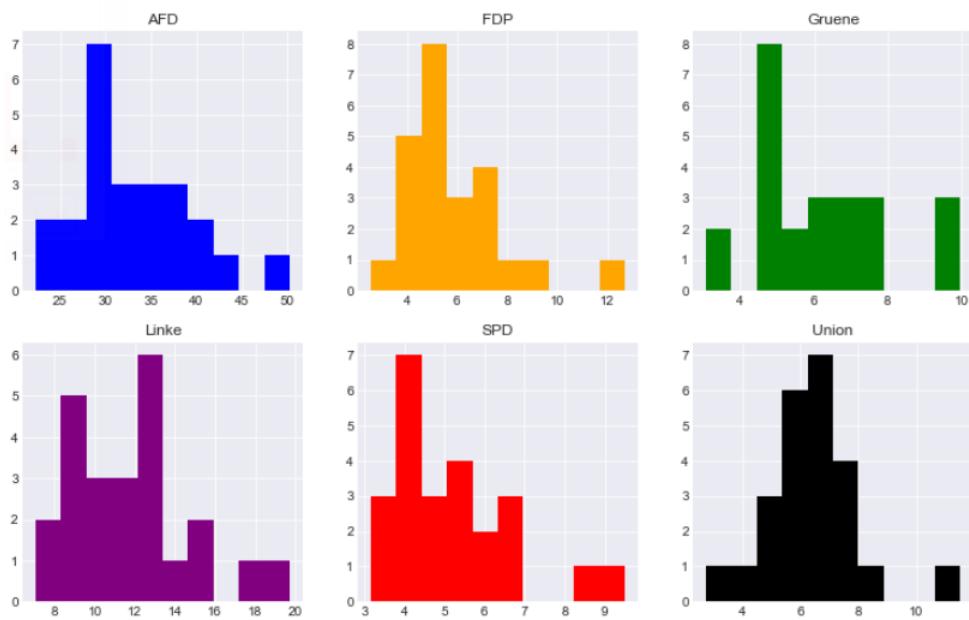


Abbildung B.18: Histogramme der relativen OFFENSE-Tweet Häufigkeit pro Woche (24 Wochen)

	AFD	FDP	GRÜNE	LINKE	SPD	UNION
Mean	$\bar{X}: 32.967$	$\bar{X}: 5.847$	$\bar{X}: 6.112$	$\bar{X}: 11.761$	$\bar{X}: 5.212$	$\bar{X}: 6.34$
Std.	$S: 6.362$	$S: 1.959$	$S: 1.784$	$S: 3.078$	$S: 1.538$	$S: 1.62$
Shapiro Wilk Test	W: 0.960, p: 0.435 Gaussian	W: 0.860, p: 0.003 NOT Gaussian	W: 0.929, p: 0.091 Gaussian	W: 0.951, p: 0.287 Gaussian	W: 0.903, p: 0.025 NOT Gaussian	W: 0.926, p: 0.077 Gaussian

Tabelle B.2: Verteilung und Test auf Normalverteilung - Twitter (24 Wochen)

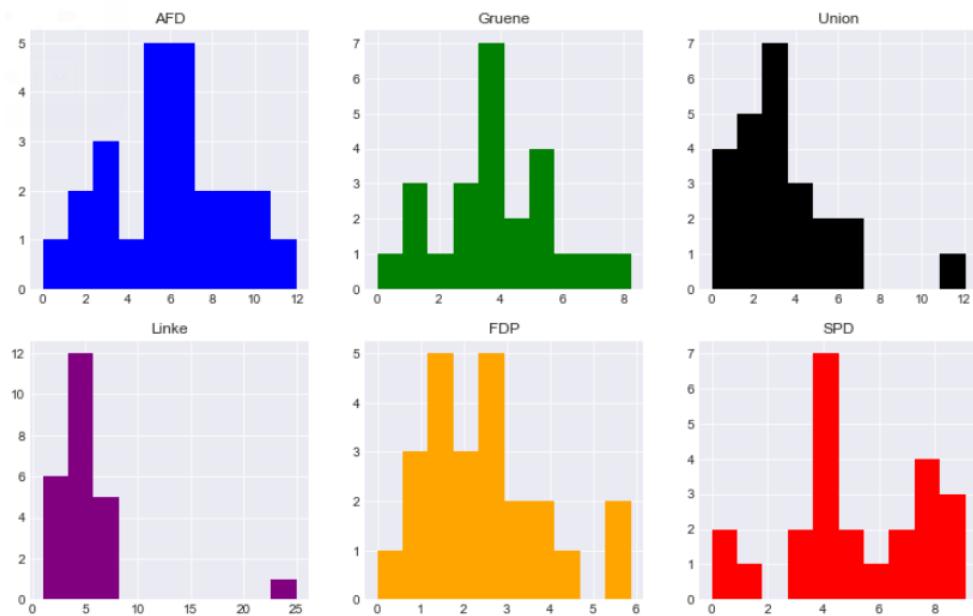


Abbildung B.19: Histogramme der relativen OFFENSE-Zuruf Häufigkeit pro Woche (24 Wochen)

	AFD	FDP	GRÜNE	LINKE	SPD	UNION
Mean	$\bar{X}: 5.886$	$\bar{X}: 2.483$	$\bar{X}: 3.811$	$\bar{X}: 5.339$	$\bar{X}: 5.137$	$\bar{X}: 3.429$
Std.	$S: 2.876$	$S: 1.442$	$S: 1.941$	$S: 4.397$	$S: 2.52$	$S: 2.619$
Shapiro Wilk Test	W: 0.983, p: 0.947 Gaussian	W: 0.965, p: 0.546 Gaussian	W: 0.986, p: 0.975 Gaussian	W: 0.553, p: 0.000 NOT Gaussian	W: 0.903, p: 0.025 NOT Gaussian	W: 0.944, p: 0.197 Gaussian

Tabelle B.3: Verteilung und Test auf Normalverteilung - Plenum (24 Wochen)

## LITERATUR

---

- [1] "Reiche erschossen": Heftige Diskussion über Äußerung auf Linke-Strategiegipfel | ZEIT ONLINE. 2020. URL: <https://www.zeit.de/news/2020-03/03/heftige-diskussion-ueber-aeusserung-auf-linke-strategiegipfel> (besucht am 14.09.2020).
- [2] "Umweltsau": Rechtsradikale klettern auf WDR-Funkhaus und entrollen Banner | ZEIT ONLINE. 2020. URL: <https://www.zeit.de/politik/deutschland/2020-01/wdr-umweltsau-koeln-rechtsradikale-protest> (besucht am 14.09.2020).
- [3] (20) Donald J. Trump on Twitter: "...As proven last week during a Congressional tour, the Border is clean, efficient & well run, just very crowded. Cumming District is a disgusting, rat and rodent infested mess. If he spent more time in Baltimore, ma. 2019. URL: [https://twitter.comrealDonaldTrump/status/1155073965880172544?ref%7B%5C\\_%7Dsrc=twsrc%7B%5C%7D5Etfw%7B%5C%7D7Ctwcamp%7B%5C%7D5Etweetembed%7B%5C%7D7Ctwterm%7B%5C%7D5E1155073965880172544%7B%5C%7D7Ctwgr%7B%5C%7D5Eshare%7B%5C\\_%7D3%7B%5C&%7Dref%7B%5C\\_%7Durl=https%7B%5C%7D3A%7B%5C%7D2F%7B%5C%7D2Fwww.theroot.com%7B%5C%7D2Fajax%7B%5C%7D2Finset%7B%5C%7D2Fiframe%7B%5C%7D3Fid%7B%5C%7D3Dtwitter-1155073965880172544autosi](https://twitter.comrealDonaldTrump/status/1155073965880172544?ref%7B%5C_%7Dsrc=twsrc%7B%5C%7D5Etfw%7B%5C%7D7Ctwcamp%7B%5C%7D5Etweetembed%7B%5C%7D7Ctwterm%7B%5C%7D5E1155073965880172544%7B%5C%7D7Ctwgr%7B%5C%7D5Eshare%7B%5C_%7D3%7B%5C&%7Dref%7B%5C_%7Durl=https%7B%5C%7D3A%7B%5C%7D2F%7B%5C%7D2Fwww.theroot.com%7B%5C%7D2Fajax%7B%5C%7D2Finset%7B%5C%7D2Fiframe%7B%5C%7D3Fid%7B%5C%7D3Dtwitter-1155073965880172544autosi) (besucht am 13.09.2020).
- [4] #saytheirnames Hanau: Warum diese Opfer Namen brauchen · Dlf Nova. 2020. URL: <https://www.deutschlandfunknova.de/beitrag/saytheirnames-hanau-warum-diese-opfer-ein-gesicht-brauchen> (besucht am 14.09.2020).
- [5] Aaron Schumacher. *TextBlob Sentiment: Calculating Polarity and Subjectivity*. 2015. URL: [https://planspace.org/20150607-textblob%7B%5C\\_%7Dsentiment/](https://planspace.org/20150607-textblob%7B%5C_%7Dsentiment/).
- [6] Pierpaolo Basile, Valerio Basile, Malvina Nissim, Nicole Novielli, Vivenza Patti, Bari Aldo Moro, Université Côte und Sophia Antipolis. *Encyclopedia of Social Network Analysis and Mining*. Hrsg. von Reda Alhajj und Jon Rokne. New York, NY: Springer New York, 2017. ISBN: 978-1-4614-7163-9. doi: [10 . 1007 / 978 - 1 - 4614 - 7163 - 9](https://doi.org/10.1007/978-1-4614-7163-9). URL: <http://link.springer.com/10.1007/978-1-4614-7163-9>.
- [7] Jonas Bayer. *HAMBURGER WAHLBEZOCHTER: TikTok: Wie ich als Politiker das neue Videoportal entdecke*. 2020. URL: <http://www.hamburger-wahlbeobachter.de/2020/03/tiktok-wie-ich-als-politiker-das-neue.html> (besucht am 14.09.2020).

- [8] Kai Biermann. *Schüsse vor Synagoge: Was wir über den Anschlag in Halle wissen* | ZEIT ONLINE. 2019. URL: <https://www.zeit.de/gesellschaft/zeitgeschehen/2019-10/schuesse-halle-tote-synagoge-sachsen-anhalt> (besucht am 14.09.2020).
- [9] Kai Biermann. *70 Jahre Bundestag: Dariüber spricht der Bundestag* | ZEIT ONLINE. 2020. URL: <https://www.zeit.de/politik/deutschland/2019-09/bundestag-jubilaeum-70-jahre-parlament-reden-woerter-sprache-wandel-%7B%5C#%7Ds=dm%7B%5C%7D2Ceuro> (besucht am 14.09.2020).
- [10] *Bundestag: Das gehetzte Parlament - SZ.de.* URL: <https://projekte.sueddeutsche.de/artikel/politik/bundestag-das-gehetzte-parlament-e953507/> (besucht am 14.09.2020).
- [11] *Bundestag: Wie aus Plenarprotokollen Daten werden - Politik - SZ.de.* URL: <https://www.sueddeutsche.de/politik/bundestag-analyse-plenarprotokolle-1.3944784> (besucht am 23.09.2020).
- [12] *Bundestag: Wie aus Plenarprotokollen Daten werden - Politik - SZ.de.* URL: <https://www.sueddeutsche.de/politik/bundestag-analyse-plenarprotokolle-1.3944784> (besucht am 23.09.2020).
- [13] *Bundesverwaltungsgericht: Gericht weist Klage gegen Verbot von "Linksunten.Indymediaäb* | ZEIT ONLINE. 2020. URL: <https://www.zeit.de/politik/deutschland/2020-01/indymedia-prozess-bundesverwaltungsgericht> (besucht am 14.09.2020).
- [14] *Duden | Hyponym | Rechtschreibung, Bedeutung, Definition, Herkunft.* URL: <https://www.duden.de/rechtschreibung/Hyponym> (besucht am 14.09.2020).
- [15] *Duden | Taxonomie | Rechtschreibung, Bedeutung, Definition, Herkunft.* URL: <https://www.duden.de/rechtschreibung/Taxonomie> (besucht am 14.09.2020).
- [16] Duncan Grubbs. *Towards Data Sciense: Understanding Political Twitter.* 2020. URL: <https://towardsdatascience.com/understanding-political-twitter-ce3476a38377>.
- [17] Paul Ekman. *Basic Emotions.* 1999. DOI: <https://doi.org/10.1002/0470013494.ch3>. URL: <https://www.paulekman.com/wp-content/uploads/2013/07/Basic-Emotions.pdf>.
- [18] *Energie | Umwelt | Klima - Alternative für Deutschland.* URL: <https://www.afd.de/energie-umwelt-klima/> (besucht am 14.09.2020).
- [19] Fellbaum C (ed). *Wordnet: an electronic lexical database.* 1998.
- [20] Maria et al Fiedler. *So twittert die AfD* | DIGITAL PRESENT. URL: <https://digitalpresent.tagesspiegel.de/afd> (besucht am 14.09.2020).
- [21] Christian Fuchs. *Leipzig: Angriff in Connewitz war offenbar nicht orchestriert* | ZEIT ONLINE. 2020. URL: <https://www.zeit.de/gesellschaft/zeitgeschehen/2020-01/leipzig-connewitz-silvester-angriffe-polizist-video> (besucht am 14.09.2020).

- [22] Googletrans: Free and Unlimited Google translate API for Python — Googletrans 2.4.0 documentation. URL: <https://py-googletrans.readthedocs.io/en/latest/> (besucht am 14.09.2020).
- [23] Sören Götz. Andreas Scheuer: #nixgeheim? | ZEIT ONLINE. 2019. URL: <https://www.zeit.de/mobilitaet/2019-10/andreas-scheuer-pkw-mautbetreiber-transparenz> (besucht am 14.09.2020).
- [24] Ileana Grabitz. Klimastreik: Weltweit Hunderttausende auf den Straßen | ZEIT ONLINE. 2019. URL: <https://www.zeit.de/politik/2019-09/klimastreik-fridays-for-future-klimaschutz-live> (besucht am 14.09.2020).
- [25] Greg Rafferty. Towards Data Sciense: Sentiment Analysis on the Texts of Harry Potter. 2018. URL: <https://towardsdatascience.com/basic-nlp-on-the-texts-of-harry-potter-sentiment-analysis-1b474b13651d>.
- [26] D. Reinhard H. Merker. Extremismus: Sachsen schaut nach links | ZEIT ONLINE. 2019. URL: <https://www.zeit.de/politik/deutschland/2019-11/extremismus-linksextremismus-soko-linx-anschlaege-gewalt-ermittlungen> (besucht am 14.09.2020).
- [27] Hanau: Was über den Anschlag bekannt ist - DER SPIEGEL. 2020. URL: <https://www.spiegel.de/panorama/justiz/hanau-was-ueber-den-anenschlag-in-hessen-benutzen-a-9c8b703a-b144-480d-ba80-66fdd65cb8e6> (besucht am 14.09.2020).
- [28] Uni Hildesheim. Wahlkampf in (a)sozialen Netzwerken – Politische Online-Kommunikation und Diskursverhalten im Kontext des Bundestagswahlkampfs 2017. URL: <https://www.uni-hildesheim.de/wahlkampfanalyse/> (besucht am 14.09.2020).
- [29] Bernhard G. Humm u. a. “Current trends in applied machine intelligence”. In: *Informatik Spektrum* 42.1 (Feb. 2019), S. 28–37. ISSN: 0170-6012. DOI: [10.1007/s00287-018-01127-0](https://doi.org/10.1007/s00287-018-01127-0). URL: <http://link.springer.com/10.1007/s00287-018-01127-0>.
- [30] Bernhard Humm, Hermann Bense, Jürgen Bock, Mario Classen, Oren Halvani, Christian Herta, Thomas Hoppe, Oliver Juwig und Melanie Siegel. “Applying machine intelligence in practice”. In: *Informatik Spektrum* 43.2 (2020), S. 137–144. ISSN: 0170-6012. DOI: [10.1007/s00287-020-01259-2](https://doi.org/10.1007/s00287-020-01259-2). URL: <http://link.springer.com/10.1007/s00287-020-01259-2>.
- [31] M. Schories K. Brunner, S. Ebisch. SZ: So aktiv sind die Parteien im Parlament. 2018. URL: <https://www.sueddeutsche.de/politik/sz-datenanalyse-neuer-bundestag-alte-fronten-1.3950836>.
- [32] Camilla Kohrs. Thüringen: Landtag will Ministerpräsidenten wählen - Politik - SZ.de. 2020. URL: <https://www.sueddeutsche.de/politik/thueringen-wahl-ministerpraesident-ramelow-hoecke-1.4830615> (besucht am 14.09.2020).
- [33] Kosinus-Ähnlichkeit – Wikipedia. URL: <https://de.wikipedia.org/wiki/Kosinus-%7B%5C%22%7BA%7D%7Dhnlichkeit> (besucht am 22.09.2020).

- [34] *Landtagswahl Thüringen 2019*. 2019. URL: <https://wahl.tagesschau.de/wahlen/2019-10-27-LT-DE-TH/index.shtml> (besucht am 14.09.2020).
- [35] Thomas Laschyk. *Fake: Die LINKE will Reiche NICHT erschießen Irreführende Schlagzeilen - Volksverpetzer*. 2020. URL: <https://www.volksverpetzer.de/analyse/reiche-erschiessen/> (besucht am 14.09.2020).
- [36] *Lobbyregister: Offener Brief gegen nutzlose Schmalspurlösung* | abgeordnetenwatch.de. 2020. URL: <https://www.abgeordnetenwatch.de/lobbyregister-offener-brief-gegen-nutzlose-schmalspurloesung> (besucht am 14.09.2020).
- [37] Caterina Lobenstein. *Corona auf Lesbos: Ich kann gar nicht ermessen, was uns dann drohen würde* ZEIT ONLINE. 2020. URL: <https://www.zeit.de/politik/ausland/2020-03/corona-lesbos-fluechtlinge-moria-medizinische-versorgung> (besucht am 14.09.2020).
- [38] Maria Fiedler. (1) *Mit voller Kraft gegen den Lockdown: Wie die AfD versucht, aus dem Corona-Tief zu kommen* - Politik - Tagesspiegel. 2020. URL: <https://www.tagesspiegel.de/politik/mit-voller-kraft-gegen-den-lockdown-wie-die-afd-versucht-aus-dem-corona-tief-zu-kommen/25808282.html> (besucht am 14.09.2020).
- [39] *Migrationspaket: "Das ist eine Zäsur in unserer Migrationspolitik* ZEIT ONLINE. 2019. URL: <https://www.zeit.de/politik/deutschland/2019-06/migrationspolitik-bundestag-migrationspaket-gesetze-asyl-abschiebungen%7B%5C%7Dwerden-demnaechst-mehr-auslaender-abgeschoben> (besucht am 14.09.2020).
- [40] Saif M. Mohammad und Peter D. Turney. "Crowdsourcing a word-emotion association lexicon". In: *Computational Intelligence*. Bd. 29. 3. 2013, S. 436–465. DOI: [10.1111/j.1467-8640.2012.00460.x](https://doi.org/10.1111/j.1467-8640.2012.00460.x). arXiv: [1308.6297](https://arxiv.org/abs/1308.6297). URL: <https://saifmohammad.com/WebPages/NRC-Emotion-Lexicon.htm>.
- [41] P. Schueller Montani, J. P. "TUWienKBS at GermEval 2018 : German Abusive Tweet Detection". In: Konvens (2018).
- [42] *Nach Tod von George Floyd: Die USA in Aufruhr: Proteste und Gewalt in vielen Städten* | ZEIT ONLINE. 2020. URL: <https://www.zeit.de/news/2020-05/31/ausschreitungen-in-us-grossstaedten-dauern-an> (besucht am 14.09.2020).
- [43] *Natural Language Toolkit — NLTK 3.5 documentation*. URL: <https://www.nltk.org/> (besucht am 14.09.2020).
- [44] Enno Park. *Ünd was ist mit ...? Perfider Trick aus der Mottenkiste der Rhetorik (Archiv)*. 2017. URL: <https://www.deutschlandfunkkultur.de/und-was-ist-mit-perfider-trick-aus-der-mottenkiste-der.1005.de.html?dram:article%7B%5C%7Did=384660> (besucht am 14.09.2020).
- [45] L. Schulz R. Faus. *Hamburger Wahlbeobachter: Wie informieren sich Bundestagsabgeordnete bei Twitter?* 2018. URL: <http://www.hamburger-wahlbeobachter.de/2018/07/twitter-analyse-wie-informieren-sich.html>.

- [46] Surayya Samat Suliya R. Klinger. *german-emotion-dictionary*. 2016. URL: <https://bitbucket.org/rklinger/german-emotion-dictionary/src/master/>.
- [47] *Rank correlation - Wikipedia*. URL: [https://en.wikipedia.org/wiki/Rank\\_correlation#Rank-biserial\\_correlation](https://en.wikipedia.org/wiki/Rank_correlation#Rank-biserial_correlation) (besucht am 14.09.2020).
- [48] Recep Tayyip Erdogan: Türkischer Präsident droht mit neuer Offensive in Nordsyrien | ZEIT ONLINE. 2019. URL: <https://www.zeit.de/politik/ausland/2019-10/nordsyrien-recep-tayyip-erdogan-offensive-kurden-rueckzug> (besucht am 14.09.2020).
- [49] Markus Reuter. *Netzpolitik: Fälschen, züchten und verstärken: Fragwürdige Twitter-Tricks bei der AfD*. 2019. URL: <https://netzpolitik.org/2019/faelschen-zuechten-und-verstaerken-fragwuerdige-twitter-tricks-bei-der-afd/>.
- [50] Markus Netzpolitik Reuter. *Twitter-Datenanalyse bei der AfD: Die falsche Balleryna*. URL: <https://netzpolitik.org/2017/twitter-datenanalyse-bei-der-afd-die-falsche-balleryna/> (besucht am 14.09.2020).
- [51] L. Ickstadt (Uni Mainz) S. Storks (Pollytix). *Hamburger Wahlbeobachter: Wie nutzen Bundestagsabgeordnete Twitter zur Vernetzung?* 2019. URL: <http://www.hamburger-wahlbeobachter.de/2019/10/twitter-analyse-wie-nutzen.html>.
- [52] Christina Schönborn. "Sentiment Analysis politischer Tweets". In: (2018).
- [53] Christina Schönborn. *INNOQ: Sentiment Analysis in der Praxis*. 2019. URL: <https://www.innoq.com/de/blog/sentiment-analysis-tweets/>.
- [54] Martina Schories. *Word2Vec: Using Word Embeddings as a Method for Journalistic Research | Towards Data Science*. 2020. URL: <https://towardsdatascience.com/using-word-embeddings-as-a-method-for-journalistic-research-ae82ffea7a62> (besucht am 14.09.2020).
- [55] *Shapiro-Wilk-Test – Wikipedia*. URL: <https://de.wikipedia.org/wiki/Shapiro-Wilk-Test> (besucht am 14.09.2020).
- [56] Jasmin Siebert. *Profil - Luisa Neubauer - Politik - SZ.de*. 2019. URL: <https://www.sueddeutsche.de/politik/profil-luisa-neubauer-1.4326529> (besucht am 14.09.2020).
- [57] Melanie Siegel. "The Role of Ontologies in Sentiment Analysis". In: *Semantic Applications*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2018, S. 87–94. ISBN: 978-3-662-55433-3. DOI: [10.1007/978-3-662-55433-3\\_7](https://doi.org/10.1007/978-3-662-55433-3_7). URL: <http://link.springer.com/10.1007/978-3-662-55433-3%7B%5C%7D7>.
- [58] Tilman Steffen. *Ministerpräsidentenwahl in Thüringen: "Neuwahlen sind keine Option* ZEIT ONLINE. 2020. URL: <https://www.zeit.de/politik/deutschland/2020-02/ministerpraesidentenwahl-thueringen-bodo-ramelow-liveblog> (besucht am 14.09.2020).

- [59] Carlo Strapparava und Rada Mihalcea. "Learning to identify emotions in text". In: *Proceedings of the 2008 ACM symposium on Applied computing - SAC '08* (2008), S. 1556. DOI: [10.1145/1363686.1364052](https://doi.org/10.1145/1363686.1364052). URL: <http://portal.acm.org/citation.cfm?doid=1363686.1364052>.
- [60] *Synset – Wikipedia*. URL: [https://de.wikipedia.org/wiki/Synset%7B%5C#%7Dcite%7B%5C\\_%7Dnote-1](https://de.wikipedia.org/wiki/Synset%7B%5C#%7Dcite%7B%5C_%7Dnote-1) (besucht am 14.09.2020).
- [61] S. Weiland T. Lehmann. *Flüchtlinge: Berlin und Thüringen drängen, Horst Seehofer bremst - DER SPIEGEL*. 2020. URL: <https://www.spiegel.de/politik/deutschland/fluechtlinge-berlin-und-thueringen-draengen-horst-seehofer-bremst-a-9f1c0784-c014-479f-9d4b-cac86d9fa0d0> (besucht am 14.09.2020).
- [62] *Thüringen: Bodo Ramelow zum Ministerpräsidenten gewählt | ZEIT ONLINE*. 2020. URL: <https://www.zeit.de/politik/deutschland/2020-03/bodo-ramelow-zum-thueringer-ministerpraesidenten-gewaehlt> (besucht am 14.09.2020).
- [63] *Türkei: Recep Tayyip Erdogan droht mit Militäreinsatz in Syrien | ZEIT ONLINE*. 2019. URL: <https://www.zeit.de/politik/ausland/2019-10/tuerkei-recep-tayyip-erdogan-syrien-militaereinsatz-usa-sicherheitszone> (besucht am 14.09.2020).
- [64] *Umweltschutz: Bundesrat stimmt Klimapaket zu | ZEIT ONLINE*. 2019. URL: <https://www.zeit.de/politik/deutschland/2019-12/bundesrat-stimmt-klimapaket-zu> (besucht am 14.09.2020).
- [65] *US-Präsident: Empörung nach Trumps Twitter-Tirade | tagesschau.de*. 2020. URL: <https://www.tagesschau.de/ausland/trump-cummings-103.html> (besucht am 13.09.2020).
- [66] *Uwe Steimle: MDR trennt sich von umstrittenem Kabarettisten - DER SPIEGEL*. 2019. URL: <https://www.spiegel.de/kultur/tv/uwe-steimle-mdr-trennt-sich-von-umstrittenem-kabarettisten-a-1299690.html> (besucht am 14.09.2020).
- [67] F. Kliche W. Schünemann, S. Steiger. *Netzpolitik: Die Angst vor Echo-kamern*. 2019. URL: <https://netzpolitik.org/2019/die-angst-vor-echokammern-ist-uebertrieben-ein-rueckblick-auf-den-wahlkampf-2017-im-netz/>.
- [68] *Wahlverhalten: Merkel-Enttäuschte und Nichtwähler machen die AfD stark | ZEIT ONLINE*. 2017. URL: <https://www.zeit.de/politik/deutschland/2017-09/wahlverhalten-bundestagswahl-wahlbeteiligung-waehlerwanderung> (besucht am 13.09.2020).
- [69] *Walter Lübcke: Der Mord am Kasseler Regierungspräsidenten | ZEIT ONLINE*. 2019. URL: <https://www.zeit.de/thema/walter-luebcke> (besucht am 14.09.2020).
- [70] *WDR: Sender zieht satirisches Video zurück | ZEIT ONLINE*. 2019. URL: <https://www.zeit.de/gesellschaft/2019-12/wdr-westdeutscher-rundfunk-kinderchor-video> (besucht am 14.09.2020).

- [71] Severin Weiland. *AfD und Venezuela: Der Kampf um Billy Six - DER SPIEGEL*. 2019. URL: <https://www.spiegel.de/politik/deutschland/afd-und-venezuela-der-kampf-um-billy-six-a-1257411.html> (besucht am 14.09.2020).
- [72] Michael Wiegand u. a. *Proceedings of the GermEval 2018 Workshop*. Techn. Ber. 2018. URL: <https://projects.fzai.h-da.de/iggsa/>.
- [73] *Wilcoxon-Mann-Whitney-Test – Wikipedia*. URL: <https://de.wikipedia.org/wiki/Wilcoxon-Mann-Whitney-Test> (besucht am 14.09.2020).
- [74] *Wilcoxon-Vorzeichen-Rang-Test – Wikipedia*. URL: <https://de.wikipedia.org/wiki/Wilcoxon-Vorzeichen-Rang-Test> (besucht am 14.09.2020).
- [75] *Wirbel um Wehrbeauftragten-Amt: Kahrs verlässt Bundestag nach innerparteilicher Niederlage* | ZEIT ONLINE. 2020. URL: <https://www.zeit.de/news/2020-05/05/kahrs-verlaesst-bundestag-nach-innerparteilicher-niederlage> (besucht am 14.09.2020).
- [76] *Wirecard: Verschwundene Milliarden* | ZEIT ONLINE. 2020. URL: <https://www.zeit.de/thema/wirecard> (besucht am 14.09.2020).